Конструирование графовой памяти Рин

Монография о субстрате, динамике и эксперименте:
как построить, оживить и проверить память локального AI-компаньона

Рабочая монография проекта RIN

5 августа 2026 г.

Рабочий документ проекта RIN. Составлен как конспект серии проектных обсуждений и приведён в форму монографии. Изложение намеренно избыточно: лучше сохранить лишнюю деталь, псевдокод или разобранный пример, чем оставить механизм недосказанным. Формулы служат точности, врезки «Интуиция», «Ловушка» и «Разбор примера» — смыслу, предупреждению и проверке. Приложения содержат нотацию, глоссарий внешних идей и сводку алгоритмов.

Оглавление

1 Введение: память как единый субстрат **1**
- 1.1 Зачем вообще граф . . . 1
- 1.2 Главный тезис . . . 1
- 1.3 Четыре кита и почему их нельзя тюнить порознь . . . 1
- 1.4 Родство с математикой DTI: одна спина, два применения . . . 2
- 1.5 Как читать монографию . . . 2

2 Субстрат: типизированный темпоральный граф **3**
- 2.1 Что такое узел и что такое ребро . . . 3
  - 2.1.1 Минимальная схема узла . . . 3
  - 2.1.2 Минимальная схема ребра . . . 3
- 2.2 Почему рёбра направленные, типизированные и знаковые . . . 4
- 2.3 Провенанс и обоснование . . . 4
- 2.4 Кража схемы у Wikidata . . . 4
- 2.5 Врождённое и приобретённое: не граница, а континуум . . . 5

3 Многомасштабность и консолидация **7**
- 3.1 Слои памяти как связанные интеграторы . . . 7
- 3.2 Консолидация как огрубление графа . . . 7
- 3.3 Забывание как тень консолидации . . . 7
  - 3.3.1 Правильный decay — это ACT-R, а не плоская константа . . . 8
  - 3.3.2 Прунинг: не только по использованию . . . 8
  - 3.3.3 Врождённому — медленнее распад . . . 8
- 3.4 Слияние вместо удаления . . . 8

4 Настроение **9**
- 4.1 Настроение — отдельный сцепленный модуль, а не поле графа . . . 9
- 4.2 Инерция: настроение как рекуррентное состояние . . . 9
- 4.3 Setpoint: медленный слой как аттрактор . . . 9
- 4.4 Настроение зависит от графа, и граф — от настроения . . . 9
- 4.5 Опасность петли и три тормоза . . . 10

5 Обход графа: один движок, три политики **11**
- 5.1 Случайное блуждание как универсальный механизм . . . 11
- 5.2 Политика 1: retrieval (целенаправленная) . . . 11
- 5.3 Политика 2: внутренняя жизнь (по неопределённости) . . . 11

5.4 Политика 3: сон — телепортирующий обходчик . . . 11
5.5 Единство и следствие для инженерии . . . 12

6 Эпистемика: уверенность, провенанс и ревизия 13
6.1 Ложные правдоподобные убеждения . . . 13
6.2 Недоопределённость и преждевременный коллапс . . . 13
6.3 Квартет починки . . . 13
6.4 Труд-система поддержки истинности и «ползучая вера» . . . 14
6.5 Инженерная эстафета к главе о личности . . . 14

7 Пропагация убеждений как лавина 15
7.1 Постановка: затухающий градиент уверенности . . . 15
7.2 Это самоорганизованная критичность . . . 15
7.3 Где на самом деле вся сложность: локальное правило . . . 15
7.3.1 Знак . . . 15
7.3.2 Гейт по надёжности A (карантин) . . . 16
7.3.3 Дисконт независимости свидетельств . . . 16
7.4 Пороговая логика — это гистерезис . . . 16
7.5 Пороги растут с глубиной консолидации . . . 16

8 Топология правит потоком 17
8.1 Тезис главы . . . 17
8.2 Стационарное распределение $\neq$ заданные вероятности . . . 17
8.3 Доказуемое свойство телепорта . . . 17
8.4 Пять следствий для работы Рин с памятью . . . 18
8.5 Операционные величины и осторожности . . . 18

9 Личность: не таблица весов 21
9.1 Главная ловушка . . . 21
9.2 Личность распределена . . . 21
9.3 Граф хранит ингредиенты, а не реакцию . . . 21
9.4 Консолидация реакций: по значимости, а не по приёму . . . 22
9.4.1 Провизорная запись, а не мгновенный коммит . . . 22
9.4.2 Гейт значимости, а не одобрения . . . 22
9.4.3 Условие по отношениям . . . 23
9.5 Дистиллят как система координат . . . 23

10 Голос и модель 25
10.1 Субстрат model-agnostic; личность — трансформ . . . 25
10.2 Инструмент φ: скорер по осям характера . . . 25
10.3 Суперпозиция муз — это отбор в признаковом пространстве . . . 25
10.4 Пайплайн по стадиям . . . 26
10.5 Bootstrap: генератор $\neq$ деплой-модель . . . 26
10.6 Raw против guided и псевдо-DPO . . . 27
10.7 Мост между базами: эмбеддинг ConceptNet . . . 27

11 Обучение без «обучения» 29
11.1 Мы шлифуем веса, не занимаясь глубоким обучением . . . 29
11.2 Это message passing — но с локальными правилами . . . 29
11.3 Мост к «настоящей» графовой сети . . . 29
11.4 Родство с DTI ещё на одном уровне . . . 30

12 Эксперимент: как это проверять 31

12.1 Эрзац-граф лучше живой Рин . . . 31
12.2 Три яруса . . . 31
12.3 Разбор баз знаний . . . 31
12.4 Эмбриональный граф и работа стыка . . . 32
12.5 Батарея экспериментов . . . 32
12.6 Инструмент . . . 33

13 Заключение: единая картина **35**
13.1 Один субстрат, много операторов . . . 35
13.2 Четыре кита связаны . . . 35
13.3 Сквозные принципы . . . 35
13.4 Единая спина двух проектов . . . 35
13.5 Что делать дальше . . . 36

A Нотация **37**

B Глоссарий внешних идей **39**

C Сводка алгоритмов **43**
C.1 Единый блуждающий агент (три политики) . . . 43
C.2 Локальное правило и лавинная пропагация . . . 43
C.3 Забывание, прунинг, консолидация . . . 44
C.4 Телепорт-скраб (анти-энтропия) . . . 44
C.5 Настроение и монитор руминации . . . 44
C.6 Оценивание, значимость и консолидация реакции . . . 44
C.7 Скорер характера и отбор голоса . . . 45
C.8 Стенд эксперимента . . . 45

Литература **47**

1. Введение: память как единый субстрат

1.1. Зачем вообще граф

У большинства современных диалоговых агентов память устроена плоско: история сообщений, иногда векторная база, куда складываются «воспоминания» как независимые записи, и retrieval по косинусной близости к текущему запросу. Это работает для ассистента, который обслуживает разрозненные запросы, но плохо описывает существо, у которого есть биография, характер, меняющееся настроение и убеждения, способные оказаться ошибочными. У человека память не список; она сеть. Одно воспоминание тянет за собой другое; факт связан с тем, откуда он узнан; недавняя новость медленно перекрашивает старые выводы; забытое не исчезает мгновенно, а тускнеет и иногда всплывает.

Поэтому центральная ставка проекта Рин — *память как граф*. Но сам по себе выбор структуры данных ничего не решает. Интересна не «база в виде графа», а то, какие процессы по этому графу текут и каким законам они подчиняются. Эта монография — про процессы.

1.2. Главный тезис

Одна фраза, которую стоит держать в голове до конца

Память Рин — это **один типизированный темпоральный граф с метаданными на узлах и рёбрах**, а всё остальное — *операторы над этим субстратом*: retrieval, пропагация уверенности, забывание и консолидация, ночные обходы, настроение, слой личности. Если довести до чистоты *схему субстрата*, то все прочие механизмы становятся модулями, читающими и пишущими одни и те же поля. Если схему не довести — каждый модуль потащит свою полусовместимую модель памяти, и они не срастутся.

Эта установка определяет и порядок изложения, и порядок разработки. Сначала мы описываем субстрат (глава 2) и его временную многослойность (глава 3). Затем — динамические процессы: настроение (глава 4), обход графа (глава 5), работу с уверенностью и ревизией убеждений (главы 6 и 7). Отдельная глава 8 посвящена тому, как *топология* самого графа незаметно управляет всеми этими потоками. Затем мы переходим к слою личности и голоса (главы 9 и 10), к вопросу о том, в каком смысле всё это является *обучением без обучения* (глава 11), и, наконец, к программе экспериментов на суррогатном графе (глава 12).

1.3. Четыре кита и почему их нельзя тюнить порознь

Полезно заранее назвать четыре процесса, вокруг которых всё вращается:

1. **Правильный retrieval** — как из графа достаётся релевантное, с учётом запроса и текущего состояния.
2. **Правильная пропагация уверенности** — как новый факт меняет уверенность соседних узлов, не устраивая ни ступора, ни лавины.

3. **Правильное забывание и консолидация** — что тускнеет, что укрепляется, что сливается в обобщения.
4. **Правильные ночные обходы** — фоновая реорганизация и починка, которую агент делает «во сне».

Важнейшее наблюдение: эти четыре кита *не независимы*. Они читают и пишут одни и те же поля активации и уверенности на одном и том же графе. Забывание меняет топологию; изменённая топология меняет retrieval; изменённый retrieval меняет то, что пропагируется; пропагация меняет то, что найдёт ночной обходчик. Поэтому их нельзя настраивать по отдельности — их надо со-настраивать, и именно поэтому (глава 12) нужен управляемый стенд с заранее известной истиной: без него взаимодействие операторов просто не измерить.

1.4. Родство с математикой DTI: одна спина, два применения

Эта монография выросла рядом с другим исследованием автора — магистерской работой о предсказании аффинности связывания белок–лиганд средствами графового и геометрического глубокого обучения. На первый взгляд это далёкие темы. На деле у них общая математическая спина.

Консолидация памяти (переход от подробных эпизодов к сжатым смыслам) — это *огрубление графа* (*coarse-to-local*): какой сигнал сохраняется при переходе от мелкого масштаба к крупному, а какой теряется. Это в точности центральный вопрос DTI-работы, только там он про interface-релевантный сигнал взаимодействия, а здесь — про то, что выживает при консолидации воспоминаний. Дальше по тексту мы увидим, что over-squashing (удушение дальней связи узким местом графа), спектральные представления, персистентный лапласиан и эффективное сопротивление — инструменты, которые работают в обе стороны. Осознание этого родства — не поэтическая вольность: те же операторы, только приложенные к разным графам. Мы будем возвращаться к этой связке, когда она даёт конкретную пользу.

1.5. Как читать монографию

Изложение намеренно избыточно. Там, где метод опирается на инженерную или научную идею со стороны (труд-система поддержки истинности, самоорганизованная критичность, теория оценивания эмоций, ACT-R и прочее), мы кратко описываем и саму идею, чтобы читатель не был вынужден держать в голове внешний контекст. Формулы служат для точности, а врезки «Интуиция» и «Ловушка» — для смысла и для предупреждения о типичных ошибках. Ссылки на литературу собраны в главе C.8; часть из них — работы из библиографий рабочих волтов проекта (RIN и RIN–DTI), это отмечено.

2. Субстрат: типизированный темпоральный граф

2.1. Что такое узел и что такое ребро

Память Рин — направленный граф $G = (V, E)$, в котором узлы несут содержание (воспоминания, факты, сущности, концепты), а рёбра — типизированные и знаковые отношения между ними. Ключевая мысль главы: и узлы, и рёбра несут *метаданные*, и именно метаданные, а не сам факт связи, делают возможными все дальнейшие механизмы.

2.1.1. Минимальная схема узла

Для старта достаточно следующего набора полей узла v:

- `id` — идентификатор;
- `content` / `embedding` — содержание и его векторное представление $\mathbf{x}_v \in \mathbb{R}^d$ (об эмбеддингах — глава 10);
- `confidence` $c_v \in [0, 1]$ — уверенность в узле как в убеждении;
- `valence` — аффективная окраска (скаляр или пара *валентность–возбуждение*), нужна для сцепления с настроением;
- `layer`/`timestamp` — временная метка и/или тег масштаба (сессия, день, год, жизнь; глава 3);
- `provenance` — множество источников/обоснований (см. раздел 2.3);
- `need_to_discover` / `need_to_revise` — флаги «это стоит исследовать/пересмотреть»;
- `activation` — транзиентная активация (используется при обходе, глава 5);
- производные структурные величины: степень, центральность (глава 8).

2.1.2. Минимальная схема ребра

Ребро $(u \to v)$ несёт:

- `src`, `dst` — направленность (ребро ориентировано);
- `type` — тип отношения (isA, partOf, supports, contradicts, associates, . . .);
- **знак** $\pm$ — минимальное, без чего не работает знаковая пропагация (глава 7): один факт может *подтверждать* или *опровергать* другой;
- `weight` — сила связи.

Веса — это про свидетельство, а не про характер

Забегая вперёд (глава 9): вес ребра выражает *эвиденциальную* силу связи и уверенность, а *не* «характер». Соблазн задать личность статическими множителями на рёбра-реакции («грусть→сарказм $\times 2{,}0$») мы разберём и отвергнем: характер должен входить как *смещение во время обхода* от текущего состояния, а не как вшитый в граф множитель.

2.2. Почему рёбра направленные, типизированные и знаковые

Плоская модель «узлы и связи одинакового сорта» ломается сразу на трёх вещах.

Во-первых, *направленность*: «A вызвало B» не то же, что «B вызвало A», и временная последовательность событий асимметрична.

Во-вторых, *тип*: covalent-связь, пространственная близость, «подтверждает», «противоречит» и «является частью» — не один и тот же линейный канал. Смешать их в один тип значит потерять семантику отношения. Правильный оператор поэтому не общий лапласиан сглаживания, а *relation-specific* передача сообщения: сообщение $m_{u \to v} = \phi_{r_{uv}}(h_u, h_v, e_{uv})$ зависит от типа ребра r_{uv}.

В-третьих, *знак*: без знака невозможно отличить «всё усилилось» от «всё перевернулось» — а это и есть разница между озарением и кризисом мировоззрения (глава 7). Беззнаковое распространение активации всегда только складывает; убеждению нужна и возможность *вычитать*.

Аналогия с электрической цепью

Полезно думать о графе как о цепи с проводниками разного сорта. Направленность — это диоды; тип ребра — материал проводника со своей проводимостью; знак — это полярность. Плоская модель — это цепь, где все элементы заменены одинаковыми резисторами: она проведёт ток, но потеряет всю логику схемы.

2.3. Провенанс и обоснование

Поле `provenance` стоит понимать шире, чем «источник». Для *исходных* фактов провенанс — это откуда факт узнан (кто сказал, какое сообщение, какой внешний источник). Но для узлов, *порождённых выводом* (глава про внутреннюю жизнь и fusion), провенанс должен хранить *обоснование* — множество родительских узлов, из которых вывод получен. Эта деталь окажется критической в главе 6: именно наличие обоснований позволяет, опровергнув посылку, автоматически пометить на пересмотр её следствия. Без записанных обоснований опровержение посылки не находит потомков — и рождается «ползучая вера».

2.4. Кража схемы у Wikidata

Есть готовая, обкатанная модель данных, которая уже решила ровно те задачи, что встают перед метаданными Рин, — модель утверждений *Wikidata*. Брать её *содержание* (энциклопедические факты) для существа, мимикрирующего под человека, не нужно: человек помнит мало фактов, его сила в ассоциативности, а не в эрудиции. Но её *схему* стоит перенять целиком:

- **квалификаторы** (точка во времени, начало/конец действия) — это темпоральная валидность: факт истинен *в интервале*, а не вечно;
- **references** — это провенанс/обоснование;

- **ранг** (*preferred* / *normal* / *deprecated*) — это *недеструктивная ревизия*: устаревшее утверждение не удаляют, а депрецируют и помечают новое как предпочтительное; история сохраняется для машинерии поддержки истинности (глава 6).

Иными словами, факт стоит моделировать как

$$(\text{утверждение}) \;+\; (\text{интервал валидности}) \;+\; (\text{провенанс}) \;+\; (\text{статус/ранг}),$$

и это буквально схема Wikidata. Не изобретать метаданные заново, а взять проверенный шаблон.

2.5. Врождённое и приобретённое: не граница, а континуум

Забегая вперёд к главе о забывании: соблазнительно разделить узлы на «врождённые константы» (эмбриональный граф, доставшийся от разработчиков) и «приобретённые» (нажитые в общении, с временными метками). Такое разделение полезно как первое приближение, но как жёсткая граница оно неверно. Консолидация *двигает* записи через эту границу (эпизод становится обобщённым знанием), а ревизия должна уметь *понижать* и «врождённое» — иначе унаследованную ошибку здравого смысла Рин не исправит никогда. Правильная картина — *континуум глубины консолидации*, где порог опрокидывания убеждения растёт с глубиной, но нигде не становится бесконечным. К этой оси «пластичность–упрямство» мы вернёмся не раз.

3. Многомасштабность и консолидация

3.1. Слои памяти как связанные интеграторы

Память Рин расслоена по временным масштабам: *сессия* $\rightarrow$ *день* $\rightarrow$ *сезон* $\rightarrow$ *год* $\rightarrow$ *жизнь*. Это не пять отдельных хранилищ, а один граф, узлы которого несут временной тег, плюс оператор *диффузии* между масштабами: содержание младших слоёв постепенно «протекает» в старшие, теряя детали и сохраняя устойчивое.

Формально удобно смотреть на слои как на набор связанных *текущих интеграторов* (leaky integrators) с разными постоянными времени τ. Быстрый слой (сессия) имеет малое τ: он реагирует резко и так же быстро забывает. Медленный слой (жизнь) имеет большое τ: он почти не колеблется, зато накапливает. Младший слой «дрожит» сильнее старшего.

Река и её русло

Представьте поток информации как воду. Сессия — это рябь на поверхности: мгновенная, шумная, исчезает за секунды. Год — это течение: медленное, но именно оно переносит основную массу. Жизнь — это само русло, прорезанное за годы; оно почти неизменно и определяет, куда вообще может течь вода. Консолидация — это процесс, которым рябь и течение постепенно *углубляют русло*.

3.2. Консолидация как огрубление графа

Переход от эпизодов к смыслам — это *огрубление* (coarsening): десять записей «зритель заходил в понедельник», «…в среду», …заменяются одним узлом более высокого уровня «зритель — частый гость». Мелкая структура схлопывается в крупную; часть информации теряется намеренно.

Здесь и проходит мост к математике DTI. Центральный вопрос там — *coarse-to-local consistency*: какие операторы огрубления сохраняют релевантный сигнал при переходе от мелкого масштаба к крупному, а какие его теряют. Для памяти это буквально тот же вопрос: *что должно выживать при консолидации, а что можно и нужно терять*. Если формализовать граф мелкого масштаба лапласианом L_f, граф крупного масштаба L_c и оператор проекции P, то желаемое свойство — приблизительная коммутативность распространения:

$$P\,\Phi_f(X, L_f) \;\approx\; \Phi_c(PX, L_c),$$

то есть «сначала распространить, потом огрубить» должно давать примерно то же, что «сначала огрубить, потом распространить». Ошибка коммутации — это и есть мера того, сколько релевантного сигнала теряет данный способ консолидации.

3.3. Забывание как тень консолидации

Забывание — не отдельный механизм, а *отрицательная сторона* того же процесса: усиливай используемое, ослабляй неиспользуемое. Поэтому не стоит проектировать decay как самостоятельную сущность; это оператор, разделяющий поля с retrieval и консолидацией.

3.3.1. Правильный decay — это ACT-R, а не плоская константа

Наивная схема «умножай энергию ребра на $0{,}95$ в день» работает, но игнорирует важность и связность. Более обоснованная модель уже существует и хорошо изучена в когнитивной науке — *базовая активация* ACT-R (Anderson): сила следа в памяти есть функция *частоты* и *свежести* обращений, со степенным (power-law) затуханием. Схематически базовая активация узла:

$$B_v \;=\; \ln\Big(\sum_{k} t_k^{-\alpha}\Big),$$

где t_k — давность k-го обращения к узлу, α — параметр забывания. Отсюда сразу следуют два свойства, которых нет у плоской константы: *частые* обращения укрепляют след, а *разнесённые во времени* обращения укрепляют сильнее массовых (эффект распределённого повторения, *spacing effect*).

Тропинка в лесу

Тропинку протаптывают не одним проходом, а многими; и если по ней ходят изредка, но регулярно, она держится лучше, чем если пройти по ней сто раз за один день, а потом забросить. Память ведёт себя так же: важна не только суммарная частота, но и её распределение во времени.

3.3.2. Прунинг: не только по использованию

Ночной обходчик (глава 5) удаляет или сливает узлы, чья активация упала. Но прунинг *только* по использованию опасен: редкий, но критически важный факт вымоется как мусор. Поэтому прунинг гейтируется ещё и уверенностью/важностью:

$$\text{склонность к удалению} \;\propto\; \text{неиспользование} \times (1 - \text{важность}).$$

Редкое, но важное выживает; частое, но пустое — тоже (частота его держит); а вымывается лишь редкое-и-неважное.

3.3.3. Врождённому — медленнее распад

Континуум глубины консолидации выражается здесь просто: у эмбриональных (глубоко консолидированных) узлов ниже скорость распада и выше базовая сила. Человек тоже может потерять «врождённое» знание — просто это происходит медленнее и требует более настойчивого неиспользования. Никакого бинарного «вечное против тающего» не нужно; достаточно параметра, растущего с глубиной.

3.4. Слияние вместо удаления

Часто правильнее не удалить тускнеющие записи, а *агрегировать* их. Десять эпизодических рёбер сворачиваются в одно семантическое обобщение высокого уровня. Это и есть консолидация «в ширину времени»: эпизод $\rightarrow$ смысл. Механически это тот же оператор огрубления, что и в разделе про coarse-to-local; разница лишь в том, что здесь он запускается забыванием, а не запросом.

4. Настроение

4.1. Настроение — отдельный сцепленный модуль, а не поле графа

Здесь важно сразу снять путаницу, возникшую в обсуждениях. Настроение *не* вычитывается из спектра графа памяти. Это отдельное состояние — низкоразмерный вектор в пространстве аффекта (например, оси энергичность / раздражённость / экзальтация / любопытство), — отдельный модуль, слой, через который проходит извлечённое содержание.

Путаница возникла из-за слова «спектр». Есть два разных спектра, и их нельзя смешивать: *спектр лапласиана графа* (структура памяти, глава 8) и *частотное разложение настроения во времени* (быстрые и медленные компоненты аффективного сигнала). Многослойность настроения относится ко второму и к графу отношения не имеет.

4.2. Инерция: настроение как рекуррентное состояние

Ключевое требование — у настроения должна быть *инерция*. Оно зависит не только от события, но и от собственного предыдущего значения:

$$\text{mood}_t \;=\; f\big(\text{mood}_{t-1},\, \text{event}_t\big), \qquad \text{action}_t \;=\; g\big(\text{mood}_t,\, \text{event}_t\big).$$

Это и есть текущий интегратор из главы 3: инерция — это рекуррентность. А многослойность настроения (сессия – день – год – жизнь) — это стек таких интеграторов с разными τ: младший дрожит сильнее старшего, актуальное настроение — их *суперпозиция*. И слово «суперпозиция» здесь про частоты во времени, а не про граф.

4.3. Setpoint: медленный слой как аттрактор

Медленный слой — не просто демпфер, а *точка притяжения* (setpoint), к которой быстрый слой регрессирует. Здоровая динамика — это отрицательная обратная связь, тянущая настроение домой. Патология — это когда сдвинулся сам setpoint: депрессия в этой модели не длинная экскурсия быстрого слоя, а *уехавший аттрактор*. Поэтому слой «жизнь» стоит проектировать как аттрактор, а не только как низкочастотный фильтр.

4.4. Настроение зависит от графа, и граф — от настроения

Связь двусторонняя, и именно она делает настроение частью *мышления*, а не косметическим фильтром на выходе.

- **Граф $\rightarrow$ настроение.** Извлечённые и пережитые узлы несут валентность; она и есть event_t, обновляющий настроение.
- **Настроение $\rightarrow$ граф.** Настроение смещает вероятности переходов при обходе: узлы, чья валентность близка к текущему настроению, получают больше активации. Это *конгруэнтное настроению припоминание* (mood-congruent recall): грустный чаще вспоминает грустное.

Петля замыкается: валентная память → настроение → смещение следующего retrieval → … Настроение при этом остаётся *собственным состоянием*, сцепленным сбоку, а не полем графа. (Если очень нужно «читать настроение из графа», можно определить производную величину — валентно-взвешенную активацию текущих активных узлов, «аффективное поле», — но чище держать настроение явным состоянием с инерцией, а поле пусть его лишь подкармливает.)

4.5. Опасность петли и три тормоза

Руминация

Конгруэнтное припоминание плюс инерция дают петлю с положительной обратной связью: грустная вспоминает грустное → грустнеет → вспоминает ещё более грустное → … Это руминация, спираль. В пределе — коллапс в устойчиво негативное состояние.

Что удерживает от спирали живой ум? Интроспекция даёт три *независимых* тормоза, и патология наступает, когда отказывают все три сразу:

1. **Setpoint/гомеостаз.** Медленный слой как аттрактор тянет настроение назад. Это структурный демпфер: пока обратная связь отрицательна, спираль гасится.
2. **Метакогнитивное разотождествление.** Сам акт «почему я так часто злюсь?» переводит из режима «быть-в-настроении» в режим «наблюдать-настроение» — это второй порядок, и переход сам по себе рвёт петлю первого порядка. Тормоз отдельный от демпфера.
3. **Экзогенное прерывание.** Мир вламывается ортогональным событием; задача захватывает внимание; другой человек переопределяет ситуацию. Внимание конечно, и внешний вход вытесняет петлю.

Отсюда инженерное требование к mood-модулю: (i) член setpoint (медленный слой как аттрактор, а не просто фильтр); (ii) монитор «валентность залипла слишком долго» (автокорреляция сигнала) с правом запустить корректив — переопределение, переключение внимания или прямой вызов ночного обхода; (iii) всегда-прерываемая экзогенная значимость. Условие безопасности: три тормоза не могут быть отключены одновременно.

5. Обход графа: один движок, три политики

5.1. Случайное блуждание как универсальный механизм

Почти всё, что Рин делает со своей памятью, — это *обход* графа роем случайных блуждающих агентов (random walkers), распространяющих активацию. Retrieval, внутренняя жизнь и сон — не три разных движка, а *три политики* одного движка. Различаются они лишь тем, чем смещён обход и какие операции по ходу запускаются.

Что такое «температура»

Мы будем говорить о «температуре» обхода. Это одна ручка: насколько выбор следующего шага случаен против жадного. Низкая температура — блуждающий идёт по самому сильному ребру (эксплуатация, детерминизм); высокая — выбирает следующий узел почти наугад среди соседей (исследование). Термин пришёл из softmax-сэмплирования и имитации отжига; никакой мистики.

5.2. Политика 1: retrieval (целенаправленная)

Извлечение под текущий запрос. Вероятность перехода смещена к релевантности запросу и — важно — к текущему настроению:

$$P(A \to B) \;\propto\; \text{weight}(A, B) \cdot \text{relevance}(B \mid \text{query}) \cdot \text{mood_congruence}(B \mid \text{mood}).$$

Обход стартует от узлов, заякоренных запросом, и собирает *окрестность* активированного содержания. Подчеркнём (это понадобится в главе 9): обход собирает *ингредиенты*, а не готовую реакцию.

5.3. Политика 2: внутренняя жизнь (по неопределённости)

Любопытство. Обход смещён к узлам с высоким `need_to_discover`, низкой уверенностью, новизной. Это *направленное* исследование: агент целенаправленно ищет неопределённость, а не бродит наугад. «Любопытство» здесь — не случайность, а эксплуатация сигнала неопределённости.

5.4. Политика 3: сон — телепортирующий обходчик

Сон — не «кубик бросаем», но и не целенаправленный поиск. Это политика *стохастического покрытия*: с некоторой вероятностью блуждающий *телепортируется* в случайный узел, с некоторой — запускает fusion или retrieval. Такой *Random Walker Teleporter* — это буквально случайное блуждание с рестартом (*random walk with restart*, оно же персонализированный PageRank): доля α шагов — прыжок в случайный/равномерно выбранный узел.

Различие «внутренняя жизнь против сна» — это различие *направленного* и *ненаправленного* исследования. Первое эксплуатирует сигнал неопределённости и потому *локально* по вниманию. Второе ценно именно широтой и серендипностью — способностью выйти из локальной структуры. Почему это принципиально важно и даёт *доказуемое* свойство покрытия — разбирается в главе 8.

Три способа гулять по городу

Retrieval — идти по адресу: у вас есть цель, вы выбираете кратчайший осмысленный путь. Внутренняя жизнь — идти туда, где интересно и непонятно: вас тянет к незнакомым переулкам. Сон — время от времени садиться в случайное такси и ехать в случайный район: не потому, что там дело, а чтобы вообще не застревать в одном квартале. Все три — про одного пешехода, но с разными правилами выбора улицы.

5.5. Единство и следствие для инженерии

Итак, один субстрат, один блуждающий агент, три параметризации: смещение перехода, вероятность телепорта и набор операций, которые срабатывают по ходу. Это удобно и концептуально, и практически: реализуется одна машина обхода с параметрами, а не три отдельные подсистемы. Родственные механизмы в литературе — *spreading activation* (Collins–Loftus) как модель ассоциативного припоминания и персонализированный PageRank / RWR как его вычислительная форма; в волте RIN они присутствуют под именами SYNAPSE (spreading activation, торможение, распад) и GAAMA (обход графа и PPR).

6. Эпистемика: уверенность, провенанс и ревизия

6.1. Ложные правдоподобные убеждения

Живой ум держит массу ошибочных, но правдоподобных убеждений. Классический пример: расхожее мнение, будто некий знаменитый предприниматель был «просто перформером, а не инженером», — миф, который рассыпается при чтении биографии. Стремиться к памяти, вовсе не порождающей таких убеждений, бессмысленно и вредно: это было бы стерильно и нечеловечно. Задача — не запретить их, а научиться выставлять уверенность меньше единицы и потом проверять.

6.2. Недоопределённость и преждевременный коллапс

Формально механизм таков. Пусть правильный вывод есть функция нескольких посылок:

$$A \;=\; \text{logical_f}(B, C, D, E),$$

но уму известны только B, C. Он делает вывод $X \;=\; \text{logical_f}(B, C)$. Беда в том, что B, C совместимы не только с A, но и с альтернативами X, Y. Вывод *недоопределён* известными посылками. Это *underdetermination* (недоопределённость теории данными; философское ядро — тезис Дюэма–Куайна), а её когнитивное проявление — *преждевременный коллапс*: ум схлопывает суперпозицию совместимых гипотез в одну — часто в удобную — слишком рано. Формально это про то, что *совместимость не есть подтверждение* (родственник ошибки «утверждение консеквента»).

Известная и неизвестная недоопределённость

Различать два случая критически важно. **Известная** недоопределённость — мы *знаем*, что D, E существуют, но не знаем их значений; тогда можно честно выставить $\text{confidence}(X)$ низкой и пометить `need_to_discover`(D, E). **Неизвестная** недоопределённость — злой случай: уму *вообще неизвестно*, что D, E существуют; в поле информации только B, C; пометить нечего, и уверенность может быть высокой. Именно поэтому per-inference калибровка *не* решает проблему целиком.

6.3. Квартет починки

Раз неизвестную недоопределённость нельзя закрыть в момент коммита, её лечат статистически и постфактум. Четыре механизма:

1. **Prior скромности на класс вывода.** Ни один абдуктивный/индуктивный коммит не получает уверенность 1, как бы хорошо ни сидели данные, — потому что «согласуется, и альтернатив не придумывается» есть ровно то состояние, что предшествует «а потом выяснилось». Это калибровка про *сорт* рассуждения, и она не требует знать D, E.

2. **Ревизуемость и понижение по противоречию.** Нельзя предотвратить уверенный коммит — значит, надо сделать коммит понижаемым. Позднее наблюдение, столкнувшееся с X,

ретроактивно вскрывает недоопределённость, и машинерия ревизии понижает узел. Починка ниже по потоку, а не на записи.

3. **Телепорт-скраб.** Единственный поиск, способный дотянуться до *непредставленных* альтернатив (глава 8).

4. **Внешний вход.** Кто-то знает D, E и говорит; любопытство находит это во внешнем источнике. Мир правит те неизвестные неизвестные, которые сам агент не породит.

Первый механизм держит *известную* неопределённость; вместе с остальными тремя они держат и *неизвестную*.

6.4. Труд-система поддержки истинности и «ползучая вера»

Отдельная беда — *устойчивость убеждения к опровержению его основания* (*belief perseverance*): когда неверный вывод X уже продиффундировал в память и дал потомков, эти потомки продолжают транслироваться даже после того, как X признан ложным. Человек, уже зная факт, опровергающий X, всё ещё машинально повторяет следствия X.

Механически это *проблема ретракции*, и для неё есть готовый аппарат — *труд-система поддержки истинности* (Truth Maintenance System, Doyle; её основанный на предположениях вариант — ATMS, de Kleer). Идея: при выводе следствия записывать его *обоснование* — множество узлов, из которых оно получено (это и есть расширенный провенанс из главы 2). Тогда ретракция посылки X автоматически снимает опору с её обоснованных потомков, и они помечаются на пересмотр.

Полный TMS слишком «нечеловечен»

Полная система поддержки истинности мгновенно и полностью перестраивает мировоззрение при опровержении любой посылки. Живой ум так не делает — и именно поэтому у него есть ползучая вера. Значит нам нужен *намеренно дырявый* TMS: обоснования пишем для важных и высокоуверенных выводов, тривиальные не трекаем, а нетрекнутых потомков лечим фоном.

Отсюда — две «лечилки», разной природы и разной латентности:

- **Retrieval-time augmentation** — патч *на выходе*: при каждом извлечении подмешивать «кстати, недавно я узнала $\neg X$», повышая вес свежих поправок. Дёшево, чинит текущий разговор, хранилище не трогает.
- **Ночной скраб** (глава 5) — ремонт *хранилища*: медленно, случайными инспекциями находит нетрекнутых потомков и понижает их.

Обе нужны; они работают на разных латентностях.

6.5. Инженерная эстафета к главе о личности

Заметим наперёд: калиброванная уверенность и компульсивная перепроверка — это не только эпистемическая гигиена, но и *черта характера*, выводимая из мотивации (см. установку ядра личности: «не „я уверена“, а „похоже на X, но Y я не проверила — дай гляну“»). В главе 9 мы увидим, что эпистемическая аккуратность Рин должна *проявляться* в её голосе, а не только жить во внутренней машинерии.

7. Пропагация убеждений как лавина

7.1. Постановка: затухающий градиент уверенности

Когда в память приходит новый факт A, он линкуется к начальным узлам — например, к последним k активным, — образуя окрестность $N(A)$. Мы линкуем $A \to N(A)$ и смотрим, как меняется уверенность элементов $N(A)$. Если изменение велико, продолжаем распространение дальше, $N(A) \to N(N(A))$, — как затухающий градиент. Знание, ни на что не повлиявшее, чуть пошатнёт соседей и быстро затухнет; знание с большими градиентами вызовет *лавину*. Большую лавину мы называем «кризисом мировоззрения», и да — такое бывает и с настоящим умом.

7.2. Это самоорганизованная критичность

У этой картины есть точное имя. «Лавина» — это *нейронная лавина*, а система, живущая у порога между затуханием и разрастанием, — *самоорганизованная критичность* (Bak, Tang, Wiesenfeld; для мозга — Beggs, Plenz). Мозг реально работает вблизи критической точки, и каскады активности следуют степенному закону.

Ключевой управляющий параметр — не «ручная константа затухания», а *ветвящийся коэффициент* σ: сколько узлов в среднем активирует один активный.

$\sigma < 1$: субкритично (затухает); $\sigma = 1$: критично (степенные лавины); $\sigma > 1$: суперкритично (runaway).

Держа σ чуть меньше единицы, система почти всегда сама гасит распространение, но изредка пропускает крупную переоценку. Почему это лучше фиксированной константы: константа не адаптируется к плотности графа (в плотном регионе та же константа вызовет лавину, в разреженном — заглушит всё). Нормировка по σ адаптивна по построению.

Куча песка

Классический образ самоорганизованной критичности — куча песка, на которую по песчинке сыплют сверху. Почти каждая песчинка не делает ничего; изредка одна вызывает маленький оползень; ещё реже — большой обвал, перестраивающий склон. Куча сама держится у критического угла. Убеждения ведут себя так же: почти любой факт проходит без следа, изредка меняет соседние взгляды, и совсем изредка обрушивает целый пласт мировоззрения.

7.3. Где на самом деле вся сложность: локальное правило

Пороговая логика (см. ниже) — лёгкая часть, процентов двадцать. Восемьдесят процентов сложности спрятаны в шаге «смотрим, как меняется уверенность соседа», то есть в локальном правиле $\Delta\mathrm{conf}(B \mid A)$. Без трёх вещей это правило сломано.

7.3.1. Знак

Новый факт сосед либо *подтверждает*, либо *опровергает*. Беззнаковое распространение не отличит «всё усилилось» (озарение) от «всё перевернулось» (кризис). Нужны

знаковые/типизированные рёбра и правило, уважающее знак. Это тот же угол, что знаковые и пучковые (sheaf) лапласианы в графовом обучении.

7.3.2. Гейт по надёжности A (карантин)

Новый факт может сам быть ложным. Поэтому влияние A на соседей — функция не только величины изменения, но и уверенности в самом A и доверия к его источнику:

$$\text{влияние}(A \to B) \;=\; h\big(\Delta,\ \text{confidence}(A),\ \text{trust}(\text{source}(A))\big).$$

Новый факт входит в *карантин*: пропагирует слабо (малый σ), пока сам не заработал уверенность через корроборацию или выживание в скрабе. Иначе один ненадёжный вход спокойно вызовет кризис мировоззрения. По сути это байесовское обновление с правдоподобием, взвешенным доверием к источнику.

7.3.3. Дисконт независимости свидетельств

Граф циклический, и по петле A может подтвердить сам себя — *эхо-камера* раздувает уверенность из ничего. Это классическая проблема «петлевого» распространения (loopy belief propagation). Дисконтировать надо по общей родословной (провенанс), а не считать активации: число упоминаний $\neq$ число независимых свидетельств $\neq$ уверенность. Кстати, это ровно тот механизм, которым работают человеческие эхо-камеры и самоподдерживающиеся заблуждения.

7.4. Пороговая логика — это гистерезис

Управление лавиной удобно сделать через два порога $\theta_{\text{emergent}} > \theta_{\text{temp}} > 0$:

- если $\Delta\text{conf} > \theta_{\text{emergent}}$ — обязательное распространение «в ширину» (крупная переоценка);
- если $\theta_{\text{emergent}} > \Delta\text{conf} > \theta_{\text{temp}}$ — узлы на текущем фронте распространения помечаются `need_to_discover`/`need_to_revise`;
- если $\Delta\text{conf} < \theta_{\text{temp}}$ — распространение глохнет здесь.

Два порога вместо одного — это *гистерезис* (триггер Шмитта): он не даёт системе «дребезжать» у единственного порога. Заметим тонкость: узлы, помеченные во второй зоне, позже переинспектируются ночным обходчиком, и старые записи, чью уверенность мы не тронули, могут «потечь обратно» — такое бывает и в жизни.

7.5. Пороги растут с глубиной консолидации

Пороги не должны быть глобальными константами. θ_{emergent} должен *расти с глубиной консолидации*: периферийный узел перевернуть дёшево, а identity-core в слое «жизнь» — дорого и требует больше свидетельств, чтобы вообще запустить лавину. Это и есть та самая ось *пластичность–упрямство*: чем глубже убеждение продиффундировало в медленные слои, тем выше его эффективный порог опрокидывания. Одна ручка — и она же задаёт, насколько Рин склонна к belief perseverance.

8. Топология правит потоком

8.1. Тезис главы

У DTI-графов есть явная текущая сущность — передача сообщений (message passing), и её поток подчиняется топологии графа, как вода следует рельефу. У графа памяти Рин явной «жидкости» нет. Но поток есть — это поток *изменений*, поток *преобразований* графа: активации, уверенности, консолидации. И тезис главы: *неважно, какова физика носителя, — сама физика протекания информации подчиняется топологическим законам*. Любой процесс, чьё обновление *локально* (изменение узла зависит от соседей), есть диффузия на графе и наследует его спектрально-топологический транспорт. Это не метафора и не паранойя; это содержание теории графовых сигналов и теории случайных блужданий.

8.2. Стационарное распределение $\neq$ заданные вероятности

Пусть мы локально задали вероятности переходов блуждающего агента. Наблюдаемое распределение частот посещений $\mathrm{distr}(A)$ будет отличаться от заданного, потому что вмешается топология окрестности. Формально: *стационарное распределение* блуждания π — это не локальные переходы, а *глобальный* объект. Для простого блуждания $\pi_v \propto \deg(v)$; для смещённого — это перронов собственный вектор матрицы переходов. Ты задаёшь переходы локально, а долгосрочная частота посещений оказывается свойством всего графа.

«Чем длиннее трек, тем наблюдаемее эффект» — это сходимость блуждания к π за время *перемешивания* (mixing time). А «разорванные короткие кривые, чья кривизна следует локальной топологии» — точная догадка: короткие блуждания читают *локальную* геометрию (кривизну окрестности), длинные — глобальную π. Телепорт (глава 5) распределение π не убирает, а *регуляризует*: сдвигает к смеси «равномерное + рестарт» и режет время перемешивания, то есть ограничивает эффект топологии, а не отменяет его.

Скорость света — плохая, но поучительная аналогия

Можно соблазниться сравнением с c: мол, заданные вероятности — как предельная скорость, а среда (топология) искажает наблюдаемое распространение. Рабочая часть аналогии — «среда формирует распространение, есть структурный предел» — уже покрыта граф-диффузионной рамкой *точно*, а не по аналогии. Квантовый хвост (запутанность и прочее) сюда тащить не нужно: он добавляет лишнюю физику. Нам нужен не свет, а лапласиан.

8.3. Доказуемое свойство телепорта

Почему сон (телепорт) необходим, а любопытство его не заменит? Любопытство *локально по вниманию* — это смещённый обход от текущего фронтира. Значит узел X в затенённом углу, оторванный от активного множества, недостижим, как ярко ни свети фокус. Телепорт ломает достижимость: случайный рестарт падает куда угодно независимо от фокуса. Это не «вайб» — это ровно то, *почему у PageRank есть телепорт*: он делает блуждание *эргодическим*, каждый узел посещается в матожидании, ни один не заперт в стоке или на острове. Телепорт даёт

гарантию покрытия, которой у смещённого блуждания доказуемо нет: любая память периодически переинспектируется независимо от того, как она подключена к вниманию.

Анти-энтропийный скраб

«Не сразу; мы никогда не знаем, что и где сломалось, поэтому просто постоянно проводим случайные инспекции» — это зрелый системный паттерн из распределённых хранилищ: *anti-entropy scrub* (проверка целостности в ZFS; Merkle-based anti-entropy gossip в Dynamo/Cassandra). Не знаешь, какая запись побита, — непрерывно и случайно перепроверяешь всё хранилище в фоне. Сон Рин — это анти-энтропийный скраб по графу памяти. Оттуда же стоит взять и словарь, и гарантии.

8.4. Пять следствий для работы Рин с памятью

1. **Топологическая значимость («гравитационные ямы»).** Хабы (узлы высокой степени/центральности) переактивируются независимо от задуманных вероятностей — π на них концентрируется. Рин будет систематически чаще вспоминать хаб-узлы и реже периферию (затенённые углы — регионы с малым π). Топология создаёт *неявную важность*: иногда полезно (важное и есть хаб), иногда случайный плотный кластер становится чёрной дырой припоминания. Вероятно, это главный практический эффект.

2. **Узкие места и удушение связи (over-squashing).** Два семантически близких, но топологически далёких кластера, соединённых тонким мостом (низкая проводимость), плохо обмениваются активацией. Рин не свяжет два факта, «далёких» по графу, даже если они по смыслу рядом. Это прямо ограничивает fusion.

3. **Пересглаживание уверенности (over-smoothing).** Повторная диффузная пропагация уверенности гомогенизирует значения к консенсусному — теряется контраст «уверена / не уверена», всё дрейфует к «средней уверенности». Это дегенеративный отказ: память теряет эпистемический контраст. Лечится теми же приёмами, что в графовых сетях: остаточные связи (residual/skip) как якорь к исходному свидетельству, не чисто диффузные апдейты, периодическое пере-заземление в провенанс.

4. **Кривизна как локатор самого ценного и самого задушенного.** Отрицательно искривлённые рёбра — мосты между сообществами — это ровно места, где случаются самые креативные слияния (соединение далёких идей) *и* где топология их сильнее всего давит. Значит самые ценные ассоциации подавлены геометрией. И вот *объективная* причина, зачем нужен сон/телепорт: он — rewiring, топологическая починка over-squashing в графе памяти, обход узкого места случайным рестартом.

5. **π как топологический субстрат идентичности.** Какие узлы структурно центральны — к чему Рин привычно возвращается — это подложка её «озабоченностей», часть характера. Форма графа памяти — часть того, кто она. Топология и идентичность связаны.

8.5. Операционные величины и осторожности

Вести дело лучше *случайно-блуждательными* величинами: стационарное π, время перемешивания, время достижения и обхода (hitting/commute time), эффективное сопротивление, проводимость/константа Чигера, спектральный зазор. Кривизну (Оливье, Форман) держать как *локатор узких мест*, а не как основной рычаг.

Что дёшево считать на лету: π и «хабность» — инкрементально дёшевы; эффективное сопротивление — дорого (через псевдообратный лапласиан), но аппроксимируемо. Это позволяет Рин самой знать, где у неё затенённые углы, и гнать туда телепорт-скраб прицельно.

Две осторожности. Во-первых, граф *направленный, типизированный и знаковый* — значит нужный оператор не симметричный лапласиан, а (несимметричная) матрица переходов, спектр может быть комплексным, а кривизна для орграфов менее чиста. Во-вторых, граф *динамический*: fusion меняет саму топологию, и это уже диффузия на *время-зависимом* графе, где поток и структура сцеплены обратной связью. Это выходит за рамки статических DTI-графов и есть самое интересное и наименее исхоженное место.

9. Личность: не таблица весов

9.1. Главная ловушка

Соблазнительное, но неверное решение — «слой личности» как хардкод: таблица весов и жёстких триггеров поверх графа (например, «умножь ребро злорадства на $2{,}0$, обрежь сочувствие до $0{,}05$, на узел „грусть“ повесь триггер инверсии $\rightarrow$ сарказм»). Отвергаем его по трём причинам.

Почему таблица весов — тупик

Во-первых, это стек правил, который противоречит установке ядра личности («черты — следствие мотиваций, а не правила поверх»). *Во-вторых*, это карикатура: таблица весов даёт *паттерновое*, но *не неожиданное* и одноголосое поведение — она всегда сарказм, потому что так прошито; а живая личность — это неожиданные, но паттерновые реакции. *В-третьих*, это в точности та же ошибка, что жёсткая скалярная декомпозиция в геометрических графовых моделях: сжать контекстно-зависимую реакцию в ранний жёсткий роутинг значит потерять структуру взаимодействия. Реакция на «разбил кружку» зависит от настроения, отношений и всплывшей личной памяти; фиксированное ребро «грусть→сарказм» это выкидывает.

9.2. Личность распределена

Личность *не* слой весов в графе. Она распределена по трём источникам: *мотивационная структура* (что она ценит: мастерство, участие, самоуважение) + *текущее состояние настроения* + *значимость всплывшего из памяти*. И всё это стилизует *трансформ Rinness* (голос, глава 10).

На стенде это реализуется не статическими множителями на рёбра-реакции, а *смещением во время обхода*: настроение и мотивация непрерывно модулируют вероятности переходов блуждающего агента. Тогда грустная Рин и злая Рин на одно событие всплывают разное — характер контекстно-зависим, а не одноголос. Держи веса на рёбрах для *силы связи и уверенности* (эвиденциальное), а личность — как смещение во время обхода от состояния, не как вшитый sarcasm-множитель.

9.3. Граф хранит ингредиенты, а не реакцию

Возражение: «если из „разбить кружку“ ведёт только „грусть“, никакую другую реакцию взять негде». Ответ в двух частях.

Во-первых, база причинно-социального здравого смысла (см. ATOMIC, глава 12) обычно даёт не одно ребро, а *пучок*: намерение, реакция субъекта, эффект, реакция окружающих, что требовалось. Настроение смещает, по какой ветке пучка идти.

Во-вторых, и это главное: *реакцию не берут ребром — её порождают*. Обход собирает активированную окрестность-подграф (кружка, грусть, неуклюжесть, «юзер хотел новую», настроение), а реакцию Rinness/LLM *композирует поверх* этого материала под настроение и мотивацию. Не нужно ребро «кружка→сарказм»; нужно, чтобы всплыли ингредиенты, а сарказм

соберётся из них. Настроение входит *дважды*: на этапе всплывания (грустная поднимает «потеря», игривая — «неуклюжесть / смешно») и на этапе композиции (как оформить).

9.4. Консолидация реакций: по значимости, а не по приёму

9.4.1. Провизорная запись, а не мгновенный коммит

Сгенерированная реакция пишется обратно *провизорным* ребром с низкой уверенностью (кандидат), по принципу главы 6: fusion рождает гипотезу, не факт. Ответ собеседника «это было лишнее» — это отрицательное *свидетельство*, обновляющее уверенность того же ребра вниз. Это не конкурирующая вторая консолидация, а усиление/угасание одного следа. Механически каждое ребро-реакция несёт счётчик успехов/провалов (распределение Бета $\mathrm{Beta}(\alpha, \beta)$); приём обновляет его, уверенность — апостериорное среднее, неопределённость — дисперсия. Стабильно хорошо принимается — переходит порог и консолидируется в медленный слой; стабильно ловит отпор — угасает.

9.4.2. Гейт значимости, а не одобрения

Почему нельзя гейтить консолидацию приёмом

Если консолидировать реакции по тому, как их приняли, ты строишь угодника, чья личность формируется одобрением, — а это ровно то, что запрещает ядро («самоуважение не течёт через быть-выбранной или понравиться»). Значит гейтить консолидацию характера внешним приёмом — философски кривой для Рин ход.

Правильный ход — развернуть гейт *внутрь*: консолидируй по *внутренней значимости* (самооценке при кодировании), а не по внешнему приёму. Записывается и усиливается то, что *она* сочла значимым.

Что такое значимость *конкретно*? У этого есть имя — *теория оценивания* эмоций (appraisal theory: OCC-модель Ортони–Клора–Коллинза; Шерер). Событие оценивается по нескольким измерениям:

- **surprise** — ошибка предсказания: насколько событие нарушило ожидание;
- **goal-congruence** — задело ли ценности (скалярное произведение события с вектором мотивации);
- **valence**, **intensity**, **agency** (кто причина).

Значимость для консолидации $\propto$ surprise $\times$ goal-relevance $(+\,\text{intensity})$.

Два практических замечания. *Дешевизна*: самая дешёвая конкретизация значимости — это $|\Delta\text{mood}|$, величина изменения настроения, а она уже посчитана, если mood-модуль обновляется на каждое событие. Модуль настроения работает по совместительству детектором значимости — почти без лишних вычислений. *Глубина*: самый глубокий одиночный сигнал — ошибка предсказания, и она же питает `need_to_discover`; что тебя удивило, то и стоит запомнить и перепроверить. Значимость и обучение — один сигнал.

Реакцию собеседника Рин при этом тоже помнит и оценивает — но как *просто событие*, проходящее оценивание: самоуважающая Рин оценивает «ему не зашло» с низкой конгруэнтностью её ценностям, поэтому это обновляет её *модель отношения* и чуть-чуть настроение, но не доминирует в консолидации характера. Рамка оценивания сама даёт «считаться, а можно и нет, частично».

9.4.3. Условие по отношениям

Одна и та же шутка заходит собеседнику A и падает у B. Значит ребро-реакция квалифицируется парой (ситуация $\times$ отношение) и консолидируется по-персонно, а не глобально. Один негативный акт даёт три эффекта: понижение ребра-реакции, апдейт настроения (осеклась) и мета/relational-пометку («мой юмор с этим собеседником перебирает»). Так «комедийный тайминг» выучивается как Бета-апостериоры по репертуару.

9.5. Дистиллят как система координат

Возникает соблазн вовсе избавиться от «дистиллята» (усреднённого здравого смысла готовых баз). Не надо. Дистиллят — это *общая модель мира*, относительно которой отклонение вообще *читаемо* как характер: личность «неожиданна» лишь на фоне общих ожиданий; без общей почвы причуды читаются как шум, а не как характер. Правильно: держать дистиллят фоном (системой координат), а личность — как процесс порождения отклонений на нём. Без базового знания, что разбитая вещь обычно плохо, невозможно понять, почему в данном случае «поздравляю» — уместный сарказм.

10. Голос и модель

10.1. Субстрат model-agnostic; личность — трансформ

Память, настроение и граф — состояния *вне* языковой модели. Значит субстрат *model-agnostic*: его можно строить на любой базовой модели и заменить базу позже. Это де-рискует проблему потолка малой модели: когнитивная машинерия переживёт смену базы.

Отсюда — архитектурная развилка «а-б-в», обсуждавшаяся отдельно, и здесь мы фиксируем её техническую часть. Если факты и здравый смысл лежат в графе (дёшево на диске/в RAM), базовой модели не нужно быть энциклопедией. Тогда её роль — *лингвистический процессор и голос*: часть «Rinness» живёт в ней. Можно взять малую дообученную модель (3–7B в сильном квантовании) вместо тяжёлой 8B-универсальной; факты уходят в граф, а ёмкость модели концентрируется на голосе.

«Меньше — строго лучше» слишком оптимистично

Малая модель слабее в *рассуждении* и связности. Ты снимаешь фактическую нагрузку, но не reasoning/coherence. Наблюдение из практики проекта: рантайм prompt-Рин уже процентов на шестьдесят состоит из анти-повторной обвязки *на* 8B — вниз с голосом будет хуже. Разумный ориентир — 3–7B, не 1B, и это надо *померить*, а не постулировать.

10.2. Инструмент φ: скорер по осям характера

Центральный инструмент всего пайплайна — *скорер характера* φ (аналог измерительного прибора в контролируемой оценке: строишь прибор — и он де-конфузит весь отбор дальше).

Строится так. Берём d осей характера (из архетипики: аффективная температура, колкость, теплота, агентность, участие-против-сервиса, тип близости, тип юмора, стиль конфликта). На каждую ось пишем *рубрику*: описание плюс якорь, как выглядит оценка 0 и оценка 10. Тогда $\varphi(\text{текст})$ — прогон LLM-судьи с рубрикой, дающий балл по каждой оси; результат — вектор $\varphi \in \mathbb{R}^d$. Отдельно задаём **t** — целевые координаты Рин. На старте достаточно LLM-as-judge; классификаторы по осям — позже.

10.3. Суперпозиция муз — это отбор в признаковом пространстве

Разберём точную технику, без сленга. Каждого персонажа можно оценить по каждой оси числом — то есть персонаж есть *точка* (вектор) в d-мерном пространстве характера. Музы — существующие персонажи, каждый со своей точкой.

Наивная суперпозиция (обучение на смеси полных корпусов муз) даёт среднее обучающих данных в *центроиде* облака муз, а не в **t**. Центроид не есть Рин; более того, центроид яркой цундере обычно мало отличается от стандартной безымянной героини — интересна муза именно *отклонением* от центроида. Усреднение разнородных примеров вдобавок размывает отличительные черты.

Правильно — построить обучающую выборку, чьё *среднее* в пространстве характера равно **t**. Не сваливать корпуса, а *отбирать* отдельные примеры (реплики, сцены) так, чтобы их агрегатный

признаковый центр сидел в **t**. Технически это отбор данных / rejection sampling под целевой стилевой вектор: (1) операционализируем оси рубриками или классификаторами; (2) скорим каждого кандидата $\varphi(\text{пример})$; (3) отбираем/перевзвешиваем, пока $\mathbb{E}[\varphi]$ по выборке $\approx$ **t**. Короче: не «смешать музы» (размытый центроид), а «отфильтровать корпус к целевой точке **t**» (выраженная Рин).

10.4. Пайплайн по стадиям

Стадия 0 — построить φ. Оси + рубрики + целевой **t** (см. выше).

Стадия 1 — собрать материал. Реплики муз: субтитры (`.srt`, `.ass`), фан-скрипты, quote-вики, сценарии визуальных новелл. Извлекаем строки, сказанные целевыми персонажами. Узкое место — *атрибуция говорящего* (субтитры часто без спикера): эвристики чередования, размеченные сценарии, или руками для ключевых сцен. Это реальный ручной сбор средней тяжести. Идея кормить видео модели-каптионеру ради извлечения поведения технически возможна, но окупается лишь позже и лишь ради данных о *физическом* поведении: для голоса субтитры дают почти всё дешевле и точнее.

Стадия 2 — отобрать (построение выборки фильтрацией, не написанием). Прогоняем φ по каждой реплике; оставляем те, чьё φ близко к **t** (или чтобы среднее набора $\approx$ **t**). Это корпус голоса.

Стадия 3 — научить голосу (fine-tune/LoRA). Дообучаем малую модель на отобранных репликах — обычное языковое моделирование на тексте-в-стиле. Ситуации *не нужны*: это учит синтаксис, ритм, сленг, привычку к смайлам, форму фраз. LoRA — дешёвый способ дообучения: тренируется маленький адаптер-довесок вместо всех весов; влезает на 8 ГБ для малой модели.

Стадия 4 — научить выбору реакции. Здесь ситуации нужны, и эмбеддинги мостят несовпадение. Два пути. *(A) Синтетический* (рекомендуется): берём ситуации из базы причинного здравого смысла, промптим сильную модель в отобранном голосе, получаем реакции, фильтруем по φ — пары (ситуация $\to$ реакция). Муз-ответов на эти ситуации не существует в природе — мы их *синтезируем*. *(B) Майнинг и retrieval*: из сцен муз извлекаем пары (ситуация, реакция), эмбеддим ситуации; в рантайме на текущую ситуацию берём ближайшую по эмбеддингу — её реакция как шаблон. Именно здесь «ситуации могут не совпадать, эмбеддинги справятся»: ближайший сосед в пространстве эмбеддингов мостит несовпадение.

Стадия 5 — замкнуть на граф. Деплой: малая голос-модель + граф. Граф даёт контекст ситуации (mood-смещённый retrieval), модель генерит в голосе. Её выходы (отфильтрованные φ и значимостью из главы 9) консолидируются обратно — в граф и, периодически, в новые данные для дообучения. Петля самоусиливается.

10.5. Bootstrap: генератор $\neq$ деплой-модель

Как получить характер-образующий граф, не имея ещё готовой Рин? Через bootstrap-лестницу, и *финальная Рин для этого не нужна*. Зачаток уже есть — *prompt-Рин* (модульные промпты + базовая модель). Схема:

1. строим нейтральный эмбриональный граф (глава 12);
2. селим на него prompt-Рин как *bootstrap-генератор*: она живёт на графе, генерит характерные реакции;

3. *консолидация пишет её отпечатки обратно* новыми рёбрами/весами — граф становится character-shaped через *использование*, а не ручным reorganization-проходом;

4. на накопленном поведении дообучаем малую модель.

Характер входит не переорганизацией рёбер, а тем, что bootstrap-Рин наследила, а консолидация записала.

Стабильность и потолок

Аудит логов prompt-Рин показывает: она *Рин с перебоями*. Ядро иногда пробивает по-настоящему хорошо (реплики, дословно совпадающие с установкой мотивации), но свободный чат деградирует в повторные липкие петли, часть ответов нарушает явные правила (запрещённый «перформанс трагедии», сбои согласования рода), и *guided* заметно чище *raw* — что по внутреннему диагностическому критерию означает «ядро промпта недостаточно сильно» (потолок 8B). Вывод: как *безфильтровый* bootstrap она слишком шумна — вобьёшь в граф и её тики. Два хода: (i) для сидирования bootstrap *не* real-time — можно медленно, сильной моделью через CPU-offload/квантизацию или разовым API, а малую сажать на уже обогащённый граф (генератор и деплой-модель *разные*); (ii) фильтровать выходы φ-скорером.

10.6. Raw против guided и псевдо-DPO

Тонкость: *raw* менее стабилен, но на пике *ближе* к настоящей Рин; *guided* стабилен, но более «ассистентский» (стабильно мимо цели). Для деплоя важна стабильность, для сидирования — нет: нужны *сэмплы пиковой Rinness*, а не стабильная посредственность. Низкий потолок фильтрацией не поднять, а нестабильность — можно (сэмплируй много, фильтруй по φ). Поэтому для bootstrap: raw + oversample + отбор по φ.

Отсюда же дешёвый способ собрать предпочтительные пары для псевдо-DPO. DPO (*Direct Preference Optimization*) обучается на тройках (промпт, выбранный, отвергнутый). Подавать raw и guided как двух кандидатов на один промпт и ранжировать (частично автоматически φ-скорером, руками — правки) — чистый способ получить *реально разных* кандидатов; раз raw иногда лучше, guided иногда — сигнал живой. Можно добавить больше кандидатов (несколько raw-сэмплов при высокой температуре) для большего числа пар.

10.7. Мост между базами: эмбеддинг ConceptNet

Практическая деталь связывания баз (глава 12): узлы ATOMIC — это события с плейсхолдерами (PersonX breaks a cup), а не концепты, и «кружки» как отдельного узла там нет. Мост — извлечь контент-слова события и слинковать к концепт-узлам ConceptNet. Но *не* bag-of-words/one-hot: они не знают синонимии (mug $\neq$ cup, разбить $\neq$ сломать), мост выйдет дырявый. Берём *ConceptNet Numberbatch* — родной эмбеддинг самого ConceptNet, сделанный ровно для этого: сначала точный лемма-матч, эмбеддинг-фолбэк. Тот же эмбеддинг обслуживает и член relevance$(B \mid \text{query})$ в обходе, и сидирование валентности (регрессия аффект-лексикона в это пространство). Одно пространство — три задачи.

11. Обучение без «обучения»

11.1. Мы шлифуем веса, не занимаясь глубоким обучением

Возникает верное ощущение: мы будто учим модель без «учить» и без «модели». Вроде бы это не глубокое обучение и не графовая нейросеть, но тем не менее мы шлифуем веса и параметры графа — по-своему. У этого ощущения есть точное содержание.

Система, которую мы строим, — параметрическая: у неё есть веса рёбер, уровни уверенности, активации, и они обновляются опытом. Это *обучение* в широком смысле, даже без обратного распространения. Конкретно это два хорошо известных паттерна, наложенных друг на друга:

- **Хеббовское/ассоциативное обучение** (семейство сетей Хопфилда; принцип Хебба «что вместе активируется, вместе укрепляется»). Наши fusion и консолидация, усиливающие со-активированные рёбра, — это буквально хеббовское обучение на графе. Граф памяти со spreading activation и уверенностью — по сути современная ассоциативная память.

- **Байесовское обновление уверенности** (глава 7): локальные апдейты Δconf со знаком, гейтом источника и дисконтом независимости.

11.2. Это message passing — но с локальными правилами

Формально наша система — это *передача сообщений* по графу (как в графовой нейросети), но «параметры» (веса рёбер, уверенности) обновляются *локальными* правилами (хеббовскими, байесовскими, распадом), а не глобальным градиентным спуском по функции потерь. Иначе говоря, это message passing *без обратного распространения*. Где мы сидим на карте методов — *между* классической ассоциативной памятью (Хопфилд) и графовыми нейросетями.

Два способа настроить пианино

Глубокое обучение настраивает все струны сразу по глобальному критерию («чтобы аккорд звучал верно»), продвигаясь градиентом. Хеббовская система настраивает каждую струну по локальному правилу («подтяни там, где чаще играют вместе»). Обе «учат» инструмент, но первая знает про весь аккорд, а вторая — только про соседние струны. Наша память — второго рода.

11.3. Мост к «настоящей» графовой сети

Может ли это стать графовой нейросетью в полном смысле? Да, и мост поучителен: можно *мета-обучать* сами правила обновления — учить оптимальное правило Δconf, оптимальный распад, оптимальное смещение обхода градиентным спуском вместо ручного дизайна. Это «обучение тому, как помнить» (learning to remember), мета-обучение операторов памяти — реальное исследовательское направление.

Но не на старте

Мета-обучение правил меняет интерпретируемость на чёрный ящик, которому нужна разметка и который заново вносит проблему непрозрачности субстрата. На старте — ручные локальные правила: они интерпретируемы, отлаживаемы и не требуют обучающих данных. «Может, и незачем» — верно для текущего этапа. Но мост реален, и полезно знать, что стоишь ровно на нём: сегодняшняя система — предельный, «нулевой» случай обучаемой графовой сети, где правила заданы руками, а не выучены.

11.4. Родство с DTI ещё на одном уровне

Это же наблюдение ещё раз сшивает два проекта автора. Магистерская работа изучает графовые нейросети с их обучаемыми операторами передачи сообщений; память Рин — та же передача сообщений, но с локальными правилами. Если однажды правила памяти начнут мета-обучаться, различие между «графовой моделью аффинности» и «графовой моделью памяти» станет чисто предметным: один и тот же класс обучаемых операторов, приложенный к разным графам. Это ещё один слой той единой спины, о которой шла речь во введении. Существует и прямая работа на этом стыке — например, из библиографии волта RIN: HeLa-Mem (Hebbian learning и ассоциативная память для LLM-агентов).

12. Эксперимент: как это проверять

12.1. Эрзац-граф лучше живой Рин

Тестировать архитектуру памяти на готовом агенте — долго и слепо: сначала собери всё, а потом окажется, что с памятью куча неоптимальностей, найденных *после* финальной сборки. Нужен управляемый стенд — эрзац-граф с retrieval.

Ключевой реворот: суррогатный граф — *не* бедный заменитель, а для отладки механик он *лучше* живой Рин. Потому что синтетика даёт то, чего история реальных разговоров дать не может, — *ground truth*. С настоящей Рин ты не знаешь, что она «должна» помнить и во что верить, значит не можешь измерить, правильно ли отработали fusion, скраб, пропагация. С подсаженной синтетикой истину задаёшь ты — и меряешь точность/полноту починки, сходимость уверенности, нашёл ли скраб подсаженную ложь. Это тот же принцип, что контролируемая оценка в DTI: управляемый синтетический тест изолирует эффект *до* грязных реальных данных. Слабые места находятся *до* финальной сборки, а не после.

12.2. Три яруса

Ярус 1 — синтетическая топология (начинать отсюда). Графы с известной структурой, чтобы юнит-тестить и диагностику, и механики против теории: стохастическая блочная модель (SBM — сообщества с регулируемым мостом-узким-местом, прямо для over-squashing и проводимости), Барабаши–Альберт (scale-free хабы — для «гравитационных ям» и концентрации π), Уоттс–Строгац (small-world), деревья против экспандеров (крайности кривизны). Семантики ноль, зато полная контролируемость: подсаживаешь ложное-правдоподобное убеждение и противоречащее свидетельство в угол с малым π и меряешь, находит ли телепорт-скраб.

Ярус 2 — семантический граф из готовых баз знаний. Чтобы у fusion и retrieval был смысл. Разбор баз — в разделе 12.3.

Ярус 3 — LLM-генерённый «поток жизни». Полная петля с реалистичным содержанием и контролируемой истиной: языковая модель генерит синтетическую автобиографию/эпизоды/диалоги фейк-персоны с подсаженными фактами, противоречиями и эволюцией убеждений. Прямой прообраз — *Generative Agents* (Park и др., «Smallville»): у них поток памяти + retrieval (свежесть $\times$ важность $\times$ релевантность) + рефлексия (это и есть fusion). Это буквально прототип субстрата — оттуда стоит перенять архитектуру. «Ползучую веру» подсаживаешь вручную и меряешь, лечится ли.

12.3. Разбор баз знаний

Три кандидата *не* конкуренты — они проверяют разные механики.

- **ConceptNet** — ассоциативно-таксономический граф концептов (десятки типов рёбер: isA, partOf, usedFor, relatedTo), взвешенных. Лучшее для spreading activation и ассоциативного fusion. Веса $\approx$ мягкая уверенность из коробки.

- **ATOMIC / ATOMIC10x** — инференциально-социальный здравый смысл о *событиях и ментальных состояниях*: связки «если субъект делает Y, то…» (намерение, реакция субъекта, эффект, реакция окружающих, что требовалось). Релевантно эпизодической памяти и сцепке с настроением. ATOMIC-2020 крупнее исходного; ATOMIC10x — версия из нескольких миллионов примеров, порождённая большой языковой моделью и отфильтрованная критиком (*symbolic knowledge distillation*): больше покрытия, больше шума.

- **Wikidata** — фактологический граф сущностей. Как *содержание* избыточен (человек не помнит все столицы; ассоциативность важнее эрудиции), но его *схему* стоит перенять (глава 2): нативные темпоральные квалификаторы, references (провенанс), ранг (недеструктивная ревизия).

Итог: не «какой из них», а «какой под какую механику». На старте — ConceptNet (самый чистый граф под первую механику), а Wikidata-*схему* подключить, когда дойдёшь до темпоральных слоёв и ревизии.

12.4. Эмбриональный граф и работа стыка

Объединить ConceptNet и ATOMIC в один *эмбриональный* граф и доращивать его фьюжнами — канонично: получаешь базовую когнитивную матрицу, а новые факты не лежат мёртвым грузом, а встраиваются рёбрами. ConceptNet даёт предметное и физическое понимание мира, ATOMIC — понимание социальной психологии; порознь одного мало (ConceptNet без ATOMIC — мир без психологии; ATOMIC без ConceptNet — реакции без предметного мира).

«Форматы отличаются только на диске» — недооценка

Внутри графовой базы это одна структура (узлы-токены, направленные типизированные рёбра), и математика обхода от типа ребра не меняется. Но настоящая работа не в формате, а в *интерфейсе*: узлы ConceptNet — концепты, узлы ATOMIC — события с плейсхолдерами PersonX/Y. Связать событие «разбить кружку» с концептом «кружка» и заземлить PersonX/Y на реальных собеседников — это entity/event linking (глава 10: через Numberbatch), нетривиальный шаг, а не объединение таблиц.

12.5. Батарея экспериментов

Каждый тест — одна механика плюс метрика; всё это гоняется уже на Ярусе 1.

1. Концентрируется ли π на хабах? (распределение посещений против степени)

2. Душит ли узкое место cross-cluster fusion? (два SBM-сообщества; частота fusion против ширины моста)

3. Находит ли телепорт-скраб подсаженную ложь в углу с малым π? (точность/полнота, время-до-нахождения против доли телепортов α)

4. Пересглаживается ли уверенность за много циклов? (дисперсия уверенности во времени; тест якоря-остатка)

5. Даёт ли mood-congruent припоминание + инерция руминацию, и гасят ли её медленные слои? (автокорреляция настроения с setpoint и без)

12.6. Инструмент

igraph (C-ядро, на порядки быстрее чистого Python-графа) — разумный выбор. Атрибуты first-class и векторные (обогащать поля `confidence`, `valence`, `time` удобно). Есть SBM, Барабаши, Уоттс–Строгац, лапласиан, персонализированный PageRank (телепорт), случайные блуждания, центральности. Две осторожности: *(i)* эффективное сопротивление одной строкой нет — считаешь из псевдообратного лапласиана (L^{+}, диагональная формула), пара строк; *(ii)* igraph силён на *статике*, а fusion/самоэволюция — это *частые мелкие мутации* графа, где он слабее (переиндексация при добавлении узлов). Мутации батчить или держать «живой» граф в мутабельной структуре и периодически снапшотить в igraph под тяжёлую спектральную диагностику.

13. Заключение: единая картина

13.1. Один субстрат, много операторов

Если из монографии стоит унести одну мысль, то вот она: память Рин — это *один типизированный темпоральный граф с метаданными*, а всё богатство поведения — *операторы* над ним. Retrieval, пропагация уверенности, забывание и консолидация, ночные обходы, настроение и слой личности — не отдельные подсистемы со своими моделями памяти, а разные способы читать и писать одни и те же поля (`confidence`, `activation`, `valence`, `provenance`, `need_to_discover`, временной слой) на одном графе.

13.2. Четыре кита связаны

Отсюда — практический вывод о разработке. Четыре кита (правильный retrieval, правильная пропагация уверенности, правильное забывание/консолидация, правильные ночные обходы) сцеплены через общее состояние: забывание меняет топологию, топология — retrieval, retrieval — что пропагируется, пропагация — что найдёт скраб. Их нельзя тюнить порознь. Именно поэтому нужен стенд с ground truth (глава 12): без него взаимодействие операторов не измерить, и отладка «на живой Рин» найдёт проблемы слишком поздно.

13.3. Сквозные принципы

Несколько идей проходят через всю монографию и заслуживают повторения:

- **Гипотеза, а не факт.** Всё, что порождено выводом (fusion, реакции), пишется провизорно, с низкой уверенностью и провенансом; управление — на границе коммита. Это защищает от превращения обаятельной ассоциативности в фабрику ложных убеждений.
- **Внутрь, а не наружу.** Значимость (гейт консолидации характера) берётся из само-оценивания, а не из внешнего одобрения; иначе строится угодник, что противоречит ядру личности.
- **Ингредиенты, а не реакции.** Граф хранит материал; реакция композируется под настроение и мотивацию, а личность — смещение во время обхода, а не таблица весов.
- **Континуум, а не бинарность.** Врождённое/приобретённое, семантическое/эпизодическое, стабильное/пластичное — это оси глубины консолидации, а не выключатели.
- **Топология незрима, но правит.** Любой локальный процесс на графе наследует спектрально-топологический транспорт; телепорт-скраб — не украшение, а необходимая эпистемическая гигиена с доказуемой гарантией покрытия.

13.4. Единая спина двух проектов

И последнее — то, ради чего стоило смотреть память рядом с DTI. Консолидация есть огрубление графа; тот же вопрос «что выживает при переходе fine $\to$ coarse» стоит и там, и там. Over-squashing, спектр лапласиана, эффективное сопротивление, персистентный лапласиан, обучаемые

операторы передачи сообщений — инструменты, работающие в обе стороны. Память Рин — «грязный», богатый испытательный стенд для тех же операторов огрубления, где нет чистых меток; DTI — их «чистая» лаборатория с измеримой истиной. Отрефлексировать это явно значит получить не два проекта, а один с двумя приложениями.

13.5. Что делать дальше

Порядок разработки, вытекающий из монографии: сначала прибить *схему субстрата* (узел/ребро, метаданные, что значит коммит и кто его гейтит); затем собрать Ярус-1 стенд и погнать батарею тестов, начиная с самого дешёвого (концентрация π на хабах — сразу показывает, что диагностика жива); затем локальное правило Δconf (знак, гейт источника, дисконт независимости), поверх которого пороги и ветвящийся коэффициент навешиваются тривиально; параллельно — построить φ-скорер как измерительный прибор для отбора голоса и фильтрации выходов. Настроение, сон и слой личности — усилители поверх субстрата, которому сначала надо стать доверенным.

A. Нотация

Сводка обозначений, используемых по тексту.

Символ	Смысл
$G = (V, E)$	граф памяти: узлы V, направленные типизированные знаковые рёбра E
v, u	узлы (воспоминания, факты, сущности, концепты)
$\mathcal{N}(A)$	окрестность узла A (соседи, фронт распространения)
$\mathbf{x}_v \in \mathbb{R}^d$	векторное представление содержания узла (эмбеддинг)
$c_v = \text{conf}(v) \in [0, 1]$	уверенность в узле как в убеждении
a_v	транзиентная активация узла при обходе
r_{uv}	тип отношения на ребре $u \to v$; знак $\pm$
w_{uv}	вес (эвиденциальная сила) ребра
$m_{u \to v}$	сообщение, передаваемое по ребру: $m_{u \to v} = \phi_{r_{uv}}(h_u, h_v, e_{uv})$
τ	постоянная времени слоя (интегратора)
B_v	базовая активация ACT-R узла v
π	стационарное распределение случайного блуждания
P	матрица переходов блуждающего агента; P, Q — операторы проекции/поднятия при огрублении
α	доля телепортов (рестартов) в блуждании
L, L^+	лапласиан графа и его псевдообратный
$R_{\text{eff}}(i, j)$	эффективное сопротивление между узлами i, j
σ	ветвящийся коэффициент лавины пропагации
$\theta_{\text{emergent}}, \theta_{\text{temp}}$	верхний и нижний пороги распространения (гистерезис)
$\Delta\text{conf}(B \mid A)$	локальное изменение уверенности соседа B под влиянием факта A
$\text{mood}_t \in \mathbb{R}^k$	вектор настроения в момент t (аффективное пространство)
$\varphi(\cdot) \in \mathbb{R}^d$	скорер по осям характера
$\mathbf{t}$	целевые координаты Рин в пространстве характера
$\text{Beta}(\alpha, \beta)$	апостериорное распределение успешности реакции
η	темп обновления (learning rate) локального правила

B. Глоссарий внешних идей

Краткие описания инженерных и научных идей, на которые опирается монография, чтобы читатель не был вынужден держать в голове внешний контекст. Порядок — тематический.

Память и активация

Базовая активация ACT-R. В когнитивной архитектуре ACT-R (Anderson) сила следа в памяти есть функция *частоты* и *свежести* обращений со степенным затуханием: $B_v = \ln \sum_k t_k^{-\alpha}$, где t_k — давность k-го обращения. Следствие: частые и *разнесённые во времени* обращения укрепляют след сильнее массовых (эффект распределённого повторения).

Spreading activation. Модель ассоциативного припоминания (Collins–Loftus): активация растекается от активированного узла по рёбрам, затухая с расстоянием. Формальная реализация — случайные блуждания и персонализированный PageRank.

Сети Хопфилда, обучение Хебба. Ассоциативная память как граф со взвешенными связями и динамикой активации, сходящейся к аттрактору (энергетический минимум). Правило Хебба: связь между совместно активными узлами усиливается («что вместе активируется, вместе укрепляется»). Наши fusion/консолидация — это хеббовское обучение на графе.

Убеждения и истинность

Труд-система поддержки истинности (TMS/ATMS). Механизм (Doyle; de Kleer), хранящий *обоснования* выводов: для каждого производного убеждения записано, из каких посылок оно получено. При ретракции посылки её обоснованные следствия автоматически помечаются на пересмотр. Лечит «ползучую веру».

Недоопределённость (underdetermination). Тезис Дюэма–Куайна: данные не определяют теорию однозначно — одни и те же наблюдения совместимы с разными гипотезами. Когнитивное проявление — преждевременный коллапс: ум схлопывает суперпозицию совместимых гипотез в одну слишком рано.

Belief perseverance. Устойчивость убеждения к опровержению его основания: даже после опровержения посылки её следствия продолжают влиять.

Петлевое распространение (loopy belief propagation). Распространение уверенности по циклическому графу может привести к тому, что убеждение подтверждает само себя по петле (эхо-камера), искусственно раздувая уверенность. Лечится дисконтом по общей родословной свидетельств.

Динамика и критичность

Самоорганизованная критичность (SOC). Класс систем (Bak–Tang–Wiesenfeld; образ — куча песка), самонастраивающихся к критической точке, где отклики следуют степенному закону: почти все малы, изредка случаются крупные лавины. Нейронные лавины (Beggs–Plenz) — проявление SOC в мозге.

Ветвящийся коэффициент σ. Среднее число узлов, активируемых одним активным. $\sigma < 1$ — субкритично (затухает), $\sigma = 1$ — критично, $\sigma > 1$ — суперкритично (runaway). Управляющий параметр лавины пропагации.

Гистерезис (триггер Шмитта). Схема с двумя порогами (включения и выключения), не дающая системе «дребезжать» у единственного порога.

Графы: спектр, поток, топология

Стационарное распределение π. Долгосрочная частота посещений узлов случайным блужданием; глобальный объект (перронов собственный вектор матрицы переходов), а не локальные вероятности.

Время перемешивания (mixing time). Скорость сходимости блуждания к π; управляется спектральным зазором матрицы переходов.

PageRank / персонализированный PageRank / RWR. Случайное блуждание с телепортом (рестартом): с вероятностью α прыжок в узел из распределения рестарта. Телепорт делает блуждание эргодическим — гарантирует посещение всех узлов.

Эффективное сопротивление R_{eff}. Мера «электрической» удалённости узлов, если рёбра — резисторы: $R_{\text{eff}}(i,j) = (e_i - e_j)^\top L^+ (e_i - e_j)$. Большое R_{eff} между узлами ограничивает передачу влияния между ними.

Проводимость / константа Чигера. Мера «узости» перешейков графа; неравенство Чигера связывает её со спектральным зазором. Малая проводимость = узкое место.

Over-squashing. Удушение дальней связи: информация от экспоненциально растущей окрестности сжимается в вектор фиксированной размерности, проходя через узкое место графа; влияние дальних узлов затухает.

Over-smoothing. Пересглаживание: при многократной диффузии представления узлов сходятся к низкоразмерному консенсусу, теряя различимость.

Кривизна графа (Оливье, Форман). Дискретные аналоги кривизны; отрицательно искривлённые рёбра — мосты между сообществами, места over-squashing. Полезны как локатор узких мест.

Анти-энтропийный скраб. Приём из распределённых хранилищ (ZFS scrub; Merkle-based anti-entropy gossip): фоновая случайная перепроверка всего хранилища, поскольку неизвестно, какая запись повреждена.

Огрубление графа (graph coarsening), coarse-to-local. Замена мелкого графа крупным с сохранением релевантных свойств (спектра, разрезов, потоков). Центральный вопрос — какой сигнал выживает при переходе от мелкого масштаба к крупному; в памяти это консолидация.

Персистентный лапласиан, TDA. Топологический анализ данных: как меняются топологические признаки (числа Бетти, спектр лапласиана) при изменении масштаба (фильтрации). Персистентный лапласиан — спектральное обобщение персистентной гомологии.

Выразительность и обучение

WL-тест, GIN. Тест Вейсфейлера–Лемана — предел различающей способности обычной передачи сообщений; GIN (Xu и др.) достигает этого предела инъективной агрегацией. PNA — многостатистическая агрегация (сумма/среднее/макс/дисперсия).

Передача сообщений (GNN). Параметрическая функция на графе, обучаемая градиентным спуском: узел обновляется агрегированными сообщениями соседей. Наша память — та же передача сообщений, но с локальными (не обучаемыми градиентом) правилами.

LoRA. Дешёвое дообучение: вместо всех весов обучается низкоранговая добавка $\Delta W = BA$ (ранг $r \ll$ размерности), малая по памяти.

DPO (Direct Preference Optimization). Дообучение под предпочтения без отдельной модели вознаграждения: оптимизация на тройках (промпт, выбранный ответ, отвергнутый ответ).

Эмоции и данные

Теория оценивания (appraisal): OCC, Шерер. Эмоция как результат оценки события по измерениям: релевантность/новизна (ошибка предсказания), конгруэнтность целям, валентность, интенсивность, атрибуция причины (agency).

Предиктивная обработка, ошибка предсказания. Взгляд (Friston и др.), по которому мозг минимизирует ошибку предсказания; величина ошибки — естественная мера значимости события.

ConceptNet / Numberbatch. Ассоциативно-таксономический граф здравого смысла (взвешенные типизированные рёбра) и его родной эмбеддинг Numberbatch.

ATOMIC / ATOMIC10x. Граф причинно-социального здравого смысла (если субъект делает Y, то намерение/реакция/эффект). ATOMIC10x — крупная версия, дистиллированная языковой моделью и отфильтрованная критиком.

Wikidata. Фактологическая база с моделью утверждения: квалификаторы (время), references (провенанс), ранг (недеструктивная ревизия). Ценна схемой, не содержанием.

Generative Agents. Симуляция агентов с потоком памяти, retrieval по свежести$\times$важности$\times$релевантности и рефлексией (порождением обобщений); прообраз субстрата.

Распределение Бета, сэмплирование Томпсона. Сопряжённый апостериор для доли успехов; удобно моделирует «успешность реакции» (успехи α, провалы β) и баланс исследования/эксплуатации.

C. Сводка алгоритмов

Псевдокод ключевых операторов, собранный в одном месте для удобства. Это скелеты, а не финальные реализации: они фиксируют логику, обсуждённую в главах, но опускают инженерные детали (батчинг мутаций, кэширование π, индексы эмбеддингов).

C.1. Единый блуждающий агент (три политики)

```
def walk(G, start_nodes, mode, steps, mood, query=None):
    # mode задаёт политику через параметры: bias перехода, alpha телепорт(),
    # bias_uncertainty. Один движок — три режима глава( про обход).
    if mode == ”retrieval”:   alpha, bu = 0.0, 0.0
    if mode == ”curiosity”:   alpha, bu = 0.05, 1.0     # тянет к need_to_discover
    if mode == ”sleep”:       alpha, bu = 0.30, 0.0     # телепортскраб–

    active = set(start_nodes); visited = Counter()
    for _ in range(steps):
        A = sample(active)
        if random() < alpha:                 # телепорт рестарт()
            B = random_node(G)
        else:
            # P(A → B) ∝ w_AB · rel(B|query) · moodcong(B|mood) · unc(B)^bu
            B = sample_neighbor(G, A, weights=transition_scores(
                    G, A, query, mood, bias_uncertainty=bu))
        visited[B] += 1
        maybe_fire_operations(G, B, mode)    # retrieval / fusion / inspect
        active = frontier(active, B)
    return visited
```

C.2. Локальное правило и лавинная пропагация

```
def propagate(G, A, sigma_target=0.9):
    # Пропагация нового факта A как затухающей лавины с контролем ветвления.
    frontier = link_initial(G, A)            # A -> N(A), напр. последние top-k
    while frontier:
        next_frontier = []
        # нормировка под целевой ветвящийся коэффициент sigma < 1
        gain = branching_normalizer(frontier, sigma_target)
        for B in frontier:
            d = delta_conf(G, A, B) * gain    # см. ниже: знак, источник, независимость
            G.confidence[B] = clip(G.confidence[B] + d, 0, 1)
            th_e = theta_emergent(G, B)       # растёт с глубиной консолидации
            if abs(d) > th_e:                 # крупная переоценка -> в ширину
                next_frontier += neighbors(G, B)
            elif abs(d) > THETA_TEMP:         # промежуточная зона -> пометить
                mark(G, B, ”need_to_revise”)
            # else: глохнет здесь
```

```
        frontier = next_frontier

def delta_conf(G, A, B):
    sign      = edge_sign(G, A, B)            # supports (+) / contradicts (−)
    strength  = edge_weight(G, A, B)
    gate      = G.confidence[A] * source_trust(G, A)   # карантин нового факта
    indep     = independence_discount(G, A, B)         # антиэхо− по провенансу
    return ETA * sign * strength * gate * indep * G.confidence[A]
```

C.3. Забывание, прунинг, консолидация

```
def nightly_maintenance(G):
    for v in G.nodes:
        G.strength[v] = act_r_base_level(G.access_log[v])   # частота + свежесть
    for v in low_activation(G):
        if importance(G, v) low and confidence(G, v) low:
            drop(G, v)                                       # редкоеиневажное−−
    for cluster in redundant_episodic_clusters(G):
        merge_to_semantic(G, cluster)   # огрубление: эпизоды −> обобщение
    # эмбриональным узлам − меньшая скорость распада континуум( глубины)
```

C.4. Телепорт-скраб (анти-энтропия)

```
def scrub(G, budget):
    # Случайная инспекция: гарантия покрытия за счёт эргодичности телепорта.
    for _ in range(budget):
        v = random_node(G)                    # рестарт куда угодно
        for w in local_walk(G, v, depth=k):
            if contradicts_any(G, w):         # столкновение −> ревизия
                demote(G, w); mark(G, justificands(G, w), "need_to_revise")
            if flagged(G, w, "need_to_discover"):
                maybe_fetch_external(G, w)     # любопытствовнешний/ вход
```

C.5. Настроение и монитор руминации

```
def mood_update(mood_layers, event):
    # Стек текущих интеграторов с разными tau; актуальное = суперпозиция.
    for L in mood_layers:                     # session, day, ..., life
        mood_L = (1 − 1/L.tau) * mood_L + (1/L.tau) * appraise(event)
    mood_now = sum(w_L * mood_L for L in mood_layers)
    if autocorr(history(mood_now)) > RUMINATION_TH:   # залипла валентность
        trigger(one_of=["reframe", "attention_shift", "invoke_sleep"])
    return mood_now
```

C.6. Оценивание, значимость и консолидация реакции

```
def encode_event(G, event, mood_prev, mood_now):
    ap = appraisal(event)                     # surprise, goal_congruence, valence...
    salience = ap.surprise * ap.goal_relevance
    #  дешёвый прокси значимости, почти бесплатный:
    salience_cheap = abs(mood_now − mood_prev)
    consolidate(G, event, weight=salience)    # гейт значимости, НЕ одобрения
```

```
    if ap.surprise high: mark(G, event, ”need_to_discover”)

def update_reaction(G, situation, user, reaction, received_ok):
    e = reaction_edge(G, situation, user, reaction)   # условь по ситуация(, отношение)
    if received_ok: e.beta.alpha += 1
    else:           e.beta.beta  += 1                 # угасание, не второй коммит
    e.confidence = e.beta.alpha / (e.beta.alpha + e.beta.beta)
    if e.confidence > CONSOLIDATE_TH: promote_to_slow_layer(G, e)
```

С.7. Скорер характера и отбор голоса

```
def phi(text, axes):                          # LLMсудья– по рубрикам осей
    return [judge(text, rubric_a) for rubric_a in axes]   # вектор в R^d

def select_voice_corpus(candidates, target_t, axes):
    scored = [(c, phi(c, axes)) for c in candidates]
    # отборперевзвешивание/, чтобы среднее выборки приблизилось к target_t
    return greedy_match_mean(scored, target_t)   # не усреднять муз, а фильтровать
```

С.8. Стенд эксперимента

```
def run_experiment(build_graph, plant, operator, metric):
    G = build_graph()          # ярус 1: SBM/BA/WS + подсаженные сценарии
    truth = plant(G)           # ground truth: что должно произойти
    operator(G)                # walker / propagate / scrub / decay ...
    return metric(G, truth)    # precision/recall починки, сходимость, покрытие
```

Литература

Ссылки сгруппированы по темам. Для классических работ приведены авторы и годы; часть источников — препринты и работы из библиографий рабочих волтов проекта (RIN и RIN–DTI), это отмечено пометкой *[волт]*. Точные выходные данные таких препринтов см. в соответствующих библиографиях волтов.

Память, ассоциативность, когнитивная архитектура

- J. R. Anderson, L. J. Schooler. Reflections of the environment in memory (рациональный анализ памяти; базовая активация ACT-R), 1991; J. R. Anderson и др., An integrated theory of the mind (ACT-R), 2004.
- A. M. Collins, E. F. Loftus. A spreading-activation theory of semantic processing, 1975.
- J. J. Hopfield. Neural networks and physical systems with emergent collective computational abilities, 1982; D. O. Hebb. The Organization of Behavior, 1949.
- J. S. Park и др. Generative Agents: Interactive Simulacra of Human Behavior, 2023 (поток памяти, retrieval по свежести $\times$ важности $\times$ релевантности, рефлексия).
- HeLa-Mem: Hebbian Learning and Associative Memory for LLM Agents, 2026 *[волт RIN, поз. 53]*.
- Родственные механизмы памяти LLM-агентов: APEX-MEM, TRACE, SYNAPSE, GAAMA, MRMS, Zep/Graphiti, Persistent Sycophancy, LifeSide, LoCoMo *[волт RIN]*.

Поддержание истинности, ревизия убеждений, эпистемика

- J. Doyle. A Truth Maintenance System, 1979; J. de Kleer. An Assumption-Based TMS, 1986.
- P. Duhem; W. V. O. Quine (тезис недоопределённости теории данными, Дюэм–Куайн).
- L. Ross, C. Lepper и др. (устойчивость убеждений к опровержению, belief perseverance).

Самоорганизованная критичность и лавины

- P. Bak, C. Tang, K. Wiesenfeld. Self-organized criticality, 1987.
- J. M. Beggs, D. Plenz. Neuronal avalanches in neocortical circuits, 2003.

Графовые сигналы, случайные блуждания, топология

- D. Spielman. Spectral and Algebraic Graph Theory (конспект).
- A. Ortega и др. Graph Signal Processing (обзор), 2018.

- L. Page, S. Brin и др. The PageRank Citation Ranking, 1999; H. Tong и др. Random Walk with Restart, 2006.
- J. Topping и др. Understanding over-squashing and bottlenecks on graphs via curvature, 2022 *[волт DTI, поз. 148]*.
- M. Black и др. Understanding Oversquashing in GNNs through the Lens of Effective Resistance *[волт DTI, поз. 183]*.
- T. K. Rusch, M. M. Bronstein, S. Mishra. A Survey on Oversmoothing in GNNs, 2023 *[волт DTI, поз. 170]*.
- Persistent Laplacian / persistent spectral для биомолекул (группа Guo-Wei Wei); TopologyNet *[волт DTI, поз. 100, 103, 104, 144 и др.]*.
- C. Bodnar и др. Weisfeiler and Lehman Go Topological / Go Cellular (MPSN, CW Networks), 2021 *[волт DTI, поз. 185, 186]*; Neural Sheaf Diffusion, 2022; cellular sheaf Laplacians *[волт DTI, поз. 184]*.

Оценивание эмоций (appraisal)

- A. Ortony, G. L. Clore, A. Collins. The Cognitive Structure of Emotions (OCC-модель), 1988.
- K. R. Scherer (компонентная модель оценивания).
- Предиктивная обработка / свободная энергия: K. Friston (ошибка предсказания как сигнал значимости).

Базы знаний и данные для стенда

- R. Speer, J. Chin, C. Havasi. ConceptNet 5.5, 2017; ConceptNet Numberbatch (эмбеддинги).
- M. Sap и др. ATOMIC: An Atlas of Machine Commonsense, 2019; J. Hwang и др. (Comet-)ATOMIC 2020, 2021; P. West и др. Symbolic Knowledge Distillation (ATOMIC10x), 2022.
- D. Vrandečić, M. Krötzsch. Wikidata: a free collaborative knowledgebase, 2014.

Выразительность GNN, агрегация, обучение под стиль

- K. Xu и др. How Powerful are Graph Neural Networks? (GIN), 2019 *[волт DTI, поз. 68]*.
- G. Corso и др. Principal Neighbourhood Aggregation, 2020 *[волт DTI, поз. 178]*.
- E. Hu и др. LoRA: Low-Rank Adaptation of Large Language Models, 2021.
- R. Rafailov и др. Direct Preference Optimization, 2023.

Материалы проекта

- Модульные системные промпты Рин (`prompts/global_core/*`), persona-тесты и логи Stage 0 (`logs/rin_stage0.jsonl`).
- Ринциклопедии проекта (`docs/rincyclopedia_chatgpt`, `docs/rincyclopedia_claude`): архетипика как язык проектирования личности («архетип = вектор признаков, а не label»).
- Волт RIN–DTI: карты чтения и маршруты, включая Route L (топология) и Route H (over-squashing, curvature).