# Конструирование графовой памяти Рин

Монография о субстрате, динамике и эксперименте:
как построить, оживить и проверить память локального AI-компаньона

Рабочая монография проекта RIN

6 августа 2026 г.

*Рабочий документ проекта RIN. Составлен как конспект серии проектных обсуждений и приведён в форму монографии. Изложение намеренно избыточно: лучше сохранить лишнюю деталь, псевдокод или разобранный пример, чем оставить механизм недосказанным. Формулы служат точности, врезки «Интуиция», «Ловушка» и «Разбор примера» — смыслу, предупреждению и проверке. Приложения содержат нотацию, глоссарий внешних идей и сводку алгоритмов.*

# Оглавление


**1 Введение: память как единый субстрат** **1**
- 1.1 Зачем вообще граф . . . 1
- 1.2 Главный тезис . . . 1
- 1.3 Четыре кита и почему их нельзя тюнить порознь . . . 1
- 1.4 Родство с математикой DTI: одна спина, два применения . . . 2
- 1.5 Как читать монографию . . . 2

**2 Субстрат: типизированный темпоральный граф** **3**
- 2.1 Что такое узел и что такое ребро . . . 3
  - 2.1.1 Схема узла . . . 3
  - 2.1.2 Схема ребра . . . 3
- 2.2 Почему рёбра направленные, типизированные и знаковые . . . 4
- 2.3 Провенанс и обоснование . . . 4
- 2.4 Что значит «коммит» и кто его гейтит . . . 5
- 2.5 Кража схемы у Wikidata . . . 5
- 2.6 Врождённое и приобретённое: не граница, а континуум . . . 5

**3 Многомасштабность и консолидация** **7**
- 3.1 Слои памяти как связанные интеграторы . . . 7
- 3.2 Консолидация как огрубление графа . . . 7
- 3.3 Забывание как тень консолидации . . . 8
  - 3.3.1 Правильный decay — это ACT-R . . . 8
  - 3.3.2 Прунинг: не только по использованию . . . 8
- 3.4 Слияние вместо удаления . . . 8

**4 Настроение** **9**
- 4.1 Настроение — отдельный сцепленный модуль, а не поле графа . . . 9
- 4.2 Инерция и многослойность . . . 9
- 4.3 Setpoint: медленный слой как аттрактор . . . 9
- 4.4 Настроение зависит от графа, и граф — от настроения . . . 9
- 4.5 Опасность петли и три тормоза . . . 10

**5 Обход графа: один движок, три политики** **11**
- 5.1 Случайное блуждание как универсальный механизм . . . 11
- 5.2 Три политики как параметризация . . . 11
- 5.3 Единство и следствие . . . 12

**6 Эпистемика: уверенность, провенанс и ревизия** **13**
6.1 Ложные правдоподобные убеждения . . . 13
6.2 Недоопределённость и преждевременный коллапс . . . 13
6.3 Квартет починки . . . 13
6.4 Труд-система поддержки истинности и «ползучая вера» . . . 14
6.5 Эстафета к главе о личности . . . 15

**7 Пропагация убеждений как лавина** **17**
7.1 Постановка: затухающий градиент уверенности . . . 17
7.2 Это самоорганизованная критичность . . . 17
7.3 Где вся сложность: локальное правило . . . 17
7.4 Пороговая логика — это гистерезис . . . 18
7.5 Пороги растут с глубиной консолидации . . . 18

**8 Топология правит потоком** **19**
8.1 Тезис главы . . . 19
8.2 Стационарное распределение $\neq$ заданные вероятности . . . 19
8.3 Доказуемое свойство телепорта . . . 19
8.4 Пять следствий для работы Рин с памятью . . . 20
8.5 Операционные величины и осторожности . . . 21

**9 Личность: не таблица весов** **23**
9.1 Главная ловушка . . . 23
9.2 Личность распределена . . . 23
9.3 Граф хранит ингредиенты, а не реакцию . . . 23
9.4 Консолидация реакций: по значимости, а не по приёму . . . 24
9.4.1 Провизорная запись . . . 24
9.4.2 Гейт значимости, а не одобрения . . . 24
9.4.3 Условие по отношениям . . . 24
9.5 Дистиллят как система координат . . . 25

**10 Голос и модель** **27**
10.1 Субстрат model-agnostic; личность — трансформ . . . 27
10.2 Инструмент $\varphi$: скорер по осям характера . . . 27
10.3 Суперпозиция муз — это отбор в признаковом пространстве . . . 27
10.4 Пайплайн по стадиям . . . 28
10.5 Bootstrap: генератор $\neq$ деплой-модель . . . 28
10.6 Raw против guided и псевдо-DPO . . . 29
10.7 Мост между базами: эмбеддинг ConceptNet . . . 29

**11 Обучение без «обучения»** **31**
11.1 Мы шлифуем веса, не занимаясь глубоким обучением . . . 31
11.2 Это message passing — но с локальными правилами . . . 31
11.3 Мост к «настоящей» графовой сети . . . 31
11.4 Родство с DTI ещё на одном уровне . . . 32

**12 Эксперимент: как это проверять** **33**
12.1 Эрзац-граф лучше живой Рин . . . 33
12.2 Три яруса . . . 33
12.3 Разбор баз знаний . . . 34
12.4 Эмбриональный граф и работа стыка . . . 34
12.5 Батарея экспериментов . . . 34
12.6 Инструмент . . . 35

**13 Заключение: единая картина** **37**
13.1 Один субстрат, много операторов . . . 37
13.2 Четыре кита связаны . . . 37
13.3 Сквозные принципы . . . 37
13.4 Единая спина двух проектов . . . 37
13.5 Что делать дальше . . . 38

**A Нотация** **39**

**B Глоссарий внешних идей** **41**

**C Сводка алгоритмов** **45**
C.1 Единый блуждающий агент (три политики) . . . 45
C.2 Локальное правило и лавинная пропагация . . . 45
C.3 Забывание, прунинг, консолидация . . . 46
C.4 Телепорт-скраб (анти-энтропия) . . . 46
C.5 Настроение и монитор руминации . . . 46
C.6 Оценивание, значимость и консолидация реакции . . . 46
C.7 Скорер характера и отбор голоса . . . 47
C.8 Стенд эксперимента . . . 47

**Литература** **49**

# 1. Введение: память как единый субстрат

## 1.1. Зачем вообще граф

У большинства современных диалоговых агентов память устроена плоско: история сообщений, иногда векторная база, куда складываются «воспоминания» как независимые записи, и retrieval по косинусной близости к текущему запросу. Это работает для ассистента, который обслуживает разрозненные запросы, но плохо описывает существо, у которого есть биография, характер, меняющееся настроение и убеждения, способные оказаться ошибочными. У человека память не список; она сеть. Одно воспоминание тянет за собой другое; факт связан с тем, откуда он узнан; недавняя новость медленно перекрашивает старые выводы; забытое не исчезает мгновенно, а тускнеет и иногда всплывает.

Поэтому центральная ставка проекта Рин — *память как граф*. Но сам по себе выбор структуры данных ничего не решает. Интересна не «база в виде графа», а то, какие процессы по этому графу текут и каким законам они подчиняются. Эта монография — про процессы.

## 1.2. Главный тезис

**Одна фраза, которую стоит держать в голове до конца**

Память Рин — это **один типизированный темпоральный граф с метаданными на узлах и рёбрах**, а всё остальное — *операторы над этим субстратом*: retrieval, пропагация уверенности, забывание и консолидация, ночные обходы, настроение, слой личности. Если довести до чистоты *схему субстрата*, то все прочие механизмы становятся модулями, читающими и пишущими одни и те же поля. Если схему не довести — каждый модуль потащит свою полусовместимую модель памяти, и они не срастутся.

Эта установка определяет и порядок изложения, и порядок разработки. Сначала мы описываем субстрат (глава 2) и его временную многослойность (глава 3). Затем — динамические процессы: настроение (глава 4), обход графа (глава 5), работу с уверенностью и ревизией убеждений (главы 6 и 7). Отдельная глава 8 посвящена тому, как *топология* самого графа незаметно управляет всеми этими потоками. Затем мы переходим к слою личности и голоса (главы 9 и 10), к вопросу о том, в каком смысле всё это является *обучением без обучения* (глава 11), и, наконец, к программе экспериментов на суррогатном графе (глава 12).

## 1.3. Четыре кита и почему их нельзя тюнить порознь

Полезно заранее назвать четыре процесса, вокруг которых всё вращается:

1. **Правильный retrieval** — как из графа достаётся релевантное, с учётом запроса и текущего состояния.
2. **Правильная пропагация уверенности** — как новый факт меняет уверенность соседних узлов, не устраивая ни ступора, ни лавины.

3. **Правильное забывание и консолидация** — что тускнеет, что укрепляется, что сливается в обобщения.
4. **Правильные ночные обходы** — фоновая реорганизация и починка, которую агент делает «во сне».

Важнейшее наблюдение: эти четыре кита *не независимы*. Они читают и пишут одни и те же поля активации и уверенности на одном и том же графе. Забывание меняет топологию; изменённая топология меняет retrieval; изменённый retrieval меняет то, что пропагируется; пропагация меняет то, что найдёт ночной обходчик. Поэтому их нельзя настраивать по отдельности — их надо со-настраивать, и именно поэтому (глава 12) нужен управляемый стенд с заранее известной истиной: без него взаимодействие операторов просто не измерить.

## 1.4. Родство с математикой DTI: одна спина, два применения

Эта монография выросла рядом с другим исследованием автора — магистерской работой о предсказании аффинности связывания белок–лиганд средствами графового и геометрического глубокого обучения. На первый взгляд это далёкие темы. На деле у них общая математическая спина.

Консолидация памяти (переход от подробных эпизодов к сжатым смыслам) — это *огрубление графа* (*coarse-to-local*): какой сигнал сохраняется при переходе от мелкого масштаба к крупному, а какой теряется. Это в точности центральный вопрос DTI-работы, только там он про interface-релевантный сигнал взаимодействия, а здесь — про то, что выживает при консолидации воспоминаний. Дальше по тексту мы увидим, что over-squashing (удушение дальней связи узким местом графа), спектральные представления, персистентный лапласиан и эффективное сопротивление — инструменты, которые работают в обе стороны. Осознание этого родства — не поэтическая вольность: те же операторы, только приложенные к разным графам. Мы будем возвращаться к этой связке, когда она даёт конкретную пользу.

## 1.5. Как читать монографию

Изложение намеренно избыточно. Там, где метод опирается на инженерную или научную идею со стороны (труд-система поддержки истинности, самоорганизованная критичность, теория оценивания эмоций, ACT-R и прочее), мы кратко описываем и саму идею, чтобы читатель не был вынужден держать в голове внешний контекст. Формулы служат для точности, а врезки «Интуиция» и «Ловушка» — для смысла и для предупреждения о типичных ошибках. Ссылки на литературу собраны в главе C.8; часть из них — работы из библиографий рабочих волтов проекта (RIN и RIN–DTI), это отмечено.

# 2. Субстрат: типизированный темпоральный граф

## 2.1. Что такое узел и что такое ребро

Память Рин — направленный граф $G = (V, E)$, в котором узлы несут содержание (воспоминания, факты, сущности, концепты), а рёбра — типизированные и знаковые отношения между ними. Ключевая мысль главы: и узлы, и рёбра несут *метаданные*, и именно метаданные, а не сам факт связи, делают возможными все дальнейшие механизмы.

**Определение 2.1** (Узел памяти)**.** Узел $v \in V$ — это запись с содержанием $\mathbf{x}_v$ и набором полей состояния, над которыми работают операторы памяти. Узел одновременно является и «данными» (что помнится), и «убеждением» (насколько это считается истинным), и «следом» (насколько активно и свежо).

### 2.1.1. Схема узла

| Поле | Тип | Смысл и кто с ним работает |
|---|---|---|
| `id` | int | идентификатор |
| `content` | text | содержание в естественном виде |
| `embedding` $\mathbf{x}_v$ | vec$[d]$ | векторное представление; retrieval-релевантность, мост баз |
| `confidence` $c_v$ | $[0, 1]$ | уверенность как в убеждении; пропагация, ревизия |
| `valence` | vec$[2]$ | валентность–возбуждение; сцепка с настроением |
| `layer/ts` | enum/time | масштаб (сессия…жизнь) и/или метка времени; консолидация |
| `provenance` | list | источники и/или обоснования; TMS, ревизия |
| `need_to_*` | flags | «исследовать/пересмотреть»; любопытство, скраб |
| `activation` $a_v$ | float | транзиентная активация; обход |
| `degree/centrality` | float | производные структурные; топология |

### 2.1.2. Схема ребра

Ребро $(u \to v)$ несёт: направленность (`src`,`dst`); тип отношения `type` (isA, partOf, supports, contradicts, associates, …); **знак** $\pm$ (минимум, без которого не работает знаковая пропагация); вес `weight` $w_{uv}$ — эвиденциальную силу связи.

**Веса — про свидетельство, а не про характер**

Забегая вперёд (глава 9): вес ребра выражает *эвиденциальную* силу связи и уверенность, а *не* «характер». Соблазн задать личность статическими множителями на рёбра-реакции («грусть→сарказм $\times 2{,}0$») мы разберём и отвергнем: характер должен входить как *смещение во время обхода* от текущего состояния, а не как вшитый в граф множитель.

## 2.2. Почему рёбра направленные, типизированные и знаковые

Плоская модель «узлы и связи одинакового сорта» ломается сразу на трёх вещах: направленность (асимметрия причинности и времени), тип (нельзя валить covalent-связь, близость, «подтверждает» и «является частью» в один линейный канал) и знак (без него не отличить «всё усилилось» от «всё перевернулось»).

Правильный оператор поэтому не общий лапласиан сглаживания, а *relation-specific* передача сообщения. Сообщение по ребру:

$$m_{u \to v} \;=\; \phi_{r_{uv}}\big(h_u,\, h_v,\, e_{uv},\, \Delta t,\, c_{uv},\, s_{uv}\big), \tag{2.1}$$

где $r_{uv}$ — тип отношения, $\Delta t$ — возраст/временная дистанция, $c_{uv}$ — уверенность, $s_{uv}$ — источник/эпистемический статус. Затем узел агрегирует входящие сообщения — и здесь важно не одну статистику, а набор (сумма/среднее/макс/ дисперсия по типам отношений), потому что для памяти существенны и кратность подтверждений, и пропорции, и наличие экстремального свидетельства.

**Почему одна статистика теряет смысл**

Пусть узел «юзер X» имеет соседей-свидетельств: три источника подтверждают факт, один противоречит. *Среднее* склеит $\{+,+,+,-\}$ и $\{+,-\}$, если пропорции совпадут, потеряв, что в первом случае *четыре* независимых свидетельства, а во втором *два*. Для памяти число независимых подтверждений принципиально: «три источника против одного» — не то же, что «один против одного». Поэтому агрегатор хранит и кратность (сумма), и пропорции (среднее), и наличие сильного контрсвидетельства (макс по знаку «против»).

**Аналогия с электрической цепью**

Полезно думать о графе как о цепи с проводниками разного сорта. Направленность — это диоды; тип ребра — материал проводника со своей проводимостью; знак — это полярность. Плоская модель — цепь, где все элементы заменены одинаковыми резисторами: она проведёт ток, но потеряет всю логику схемы.

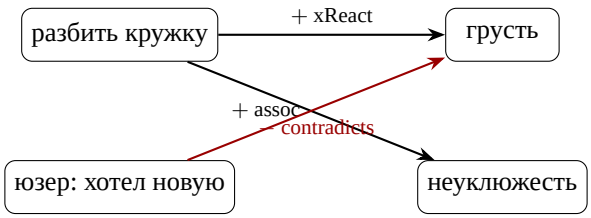



Рис.: типизированные знаковые рёбра. Личная память «юзер хотел новую» *противоречит* базовой реакции «грусть» — это и делает возможным уместное «поздравляю».

## 2.3. Провенанс и обоснование

Поле `provenance` шире, чем «источник». Для *исходных* фактов провенанс — откуда факт узнан. Для узлов, *порождённых выводом* (fusion), провенанс должен хранить *обоснование* — множество родительских узлов, из которых вывод получен. Эта деталь окажется критической в главе 6: именно наличие обоснований позволяет, опровергнув посылку, автоматически пометить на пересмотр её следствия. Без записанных обоснований опровержение посылки не находит потомков — и рождается «ползучая вера».

## 2.4. Что значит «коммит» и кто его гейтит

Важнейшая граница схемы — между *активным рабочим убеждением* и *записью*. Не всё, что всплыло или сгенерировалось, попадает в граф как факт.

**Принцип 2.1** (Гипотеза, а не факт)**.** Всё, что порождено выводом или генерацией (fusion, реакция, ассоциация), пишется *провизорно*: с низкой уверенностью, с провенансом-обоснованием и, при необходимости, с флагом `need_to_discover`. Повышение до «записи» (переход в более медленный слой) происходит только через накопление подтверждающих свидетельств. Управление — на границе коммита.

```
def commit(G, item, kind):
    if kind == ”observed”:          # прямое наблюдение
        c0 = source_trust(item.source)
    if kind == ”inferred”:          # порождено fusionвыводом/
        c0 = LOW                    # гипотеза, не факт
        item.provenance = item.parents      # обоснование для TMS
    node = G.add_node(item, confidence=c0, layer=”session”)
    propagate(G, node)              # см. главу про лавину со( знаком, карантином)
    return node
```

## 2.5. Кража схемы у Wikidata

Есть готовая, обкатанная модель данных, уже решившая ровно те задачи, что встают перед метаданными Рин, — модель утверждений *Wikidata*. Брать её *содержание* (энциклопедические факты) для существа, мимикрирующего под человека, не нужно: человек помнит мало фактов, его сила в ассоциативности. Но её *схему* стоит перенять целиком:

- **квалификаторы** (точка во времени, начало/конец) — темпоральная валидность: факт истинен *в интервале*, а не вечно;
- **references** — провенанс/обоснование;
- **ранг** (*preferred*/*normal*/*deprecated*) — *недеструктивная ревизия*: устаревшее не удаляют, а депрецируют, помечая новое предпочтительным; история сохраняется для машинерии поддержки истинности.

Иными словами, факт стоит моделировать как

$$(\text{утверждение}) + (\text{интервал валидности}) + (\text{провенанс}) + (\text{статус/ранг}),$$

и это буквально схема Wikidata. Не изобретать метаданные заново, а взять проверенный шаблон.

## 2.6. Врождённое и приобретённое: не граница, а континуум

Соблазнительно разделить узлы на «врождённые константы» (эмбриональный граф) и «приобретённые» (нажитые, с временными метками). Как первое приближение полезно, но как жёсткая граница неверно. Консолидация *двигает* записи через границу (эпизод $\rightarrow$ обобщённое знание), а ревизия должна уметь *понижать* и «врождённое» — иначе унаследованную ошибку здравого смысла Рин не исправит никогда. Правильная картина — *континуум глубины консолидации*, где порог опрокидывания убеждения растёт с глубиной, но нигде не становится бесконечным. К оси «пластичность – упрямство» мы вернёмся не раз (главы 7, 6).

# 3. Многомасштабность и консолидация

## 3.1. Слои памяти как связанные интеграторы

Память Рин расслоена по временным масштабам: *сессия* $\rightarrow$ *день* $\rightarrow$ *сезон* $\rightarrow$ *год* $\rightarrow$ *жизнь*. Это не пять хранилищ, а один граф, узлы которого несут временной тег, плюс оператор *диффузии* между масштабами: содержание младших слоёв постепенно «протекает» в старшие, теряя детали и сохраняя устойчивое.

Формально слой — *текущий интегратор* (leaky integrator) с постоянной времени $\tau$. Дискретное обновление состояния слоя $s^{(\tau)}$ под входом $x_t$:

$$s_t^{(\tau)} \;=\; \Big(1 - \tfrac{1}{\tau}\Big)\, s_{t-1}^{(\tau)} \;+\; \tfrac{1}{\tau}\, x_t. \tag{3.1}$$

Малое $\tau$ (сессия) — резкая реакция и быстрое забывание; большое $\tau$ (жизнь) — почти без колебаний, зато накапливает. Младший слой «дрожит» сильнее старшего. Импульсный отклик слоя — экспоненциальное ядро с постоянной $\tau$, так что разные слои суть *частотные полосы* одного сигнала во времени (это понадобится для настроения, глава 4).

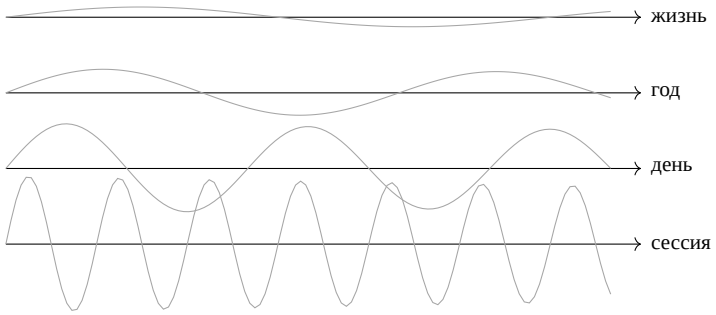



Рис.: одни и те же события, пропущенные через слои с растущим $\tau$. Младшие дрожат сильнее; актуальное состояние — их суперпозиция.

## 3.2. Консолидация как огрубление графа

Переход от эпизодов к смыслам — это *огрубление* (coarsening): десять записей «зритель заходил в понедельник», «…в среду», …заменяются одним узлом «зритель — частый гость». Мелкая структура схлопывается в крупную; часть информации теряется намеренно.

Здесь проходит мост к математике DTI. Пусть граф мелкого масштаба имеет лапласиан $L_f$, крупного — $L_c$, оператор проекции $P$ (мелкий $\rightarrow$ крупный) и поднятия $Q$. Желаемое свойство — приблизительная коммутативность распространения:

$$\big\|\, P\,\Phi_f(X, L_f) \;-\; \Phi_c(PX, L_c) \,\big\| \;\le\; \varepsilon. \tag{3.2}$$

«Сначала распространить, потом огрубить» должно давать примерно то же, что «сначала огрубить, потом распространить». Ошибка коммутации — мера того, сколько релевантного сигнала теряет данный способ консолидации. Другой критерий — сохранение энергии на подпространстве интереса: $x^\top L_f x \approx (Px)^\top L_c (Px)$ для $x$ из интерфейс-релевантного подпространства.

**Что должно выжить при консолидации**

Свернём десять эпизодов визитов в узел «частый гость». *Выжить* обязаны: частота (была высокой), устойчивая валентность (тёплая), тип связи (регулярность). *Потеряться* можно: конкретные даты, точные реплики. Плохое огрубление сохранит даты и потеряет валентность — тогда Рин будет помнить *когда*, но забудет *как относится*; это и есть большая ошибка коммутации по аффективной оси. Значит критерий огрубления — сохранять аффективно- и реляционно-релевантное подпространство, а не спектр целиком.

## 3.3. Забывание как тень консолидации

Забывание — не отдельный механизм, а *отрицательная сторона* того же процесса: усиливай используемое, ослабляй неиспользуемое.

### 3.3.1. Правильный decay — это ACT-R

Наивная схема «умножай энергию на $0{,}95$ в день» игнорирует важность и связность. Обоснованная модель — *базовая активация* ACT-R: сила следа есть функция *частоты* и *свежести* обращений со степенным затуханием:

$$B_v \;=\; \ln\Big(\sum_{k=1}^{n} t_k^{-\alpha}\Big), \tag{3.3}$$

где $t_k$ — давность $k$-го обращения, $\alpha$ — параметр забывания. Отсюда: *частые* обращения укрепляют след, а *разнесённые* укрепляют сильнее массовых (эффект распределённого повторения — spacing). Вероятность извлечения монотонна по $B_v$.

**Тропинка в лесу**

Тропинку протаптывают многими проходами; если по ней ходят изредка, но регулярно, она держится лучше, чем если пройти сто раз за день, а потом забросить. Формула (3.3) именно это и кодирует: важна не только суммарная частота, но и её распределение во времени.

### 3.3.2. Прунинг: не только по использованию

Прунинг только по использованию опасен: редкий, но критичный факт вымоется как мусор. Поэтому склонность к удалению гейтируется важностью:

$$\text{prune}(v) \;\propto\; \text{неиспользование}(v) \cdot \big(1 - \text{важность}(v)\big). \tag{3.4}$$

Редкое-но-важное выживает; частое-но-пустое держит частота; вымывается лишь редкое-и-неважное. Врождённому — ниже скорость распада (выше базовая сила): континуум глубины, а не бинарность.

## 3.4. Слияние вместо удаления

Часто правильнее не удалить тускнеющие записи, а *агрегировать*: десять эпизодических рёбер сворачиваются в одно семантическое обобщение. Это консолидация «в ширину времени» (эпизод $\rightarrow$ смысл) — тот же оператор огрубления из (3.2), но запускаемый забыванием, а не запросом. Псевдокод — в приложении C.

# 4. Настроение

## 4.1. Настроение — отдельный сцепленный модуль, а не поле графа

Снимем путаницу сразу. Настроение *не* вычитывается из спектра графа памяти. Это отдельное состояние — низкоразмерный вектор в пространстве аффекта $\text{mood} \in \mathbb{R}^k$ (например, оси энергичность / раздражённость / экзальтация / любопытство) — отдельный модуль, слой, через который проходит извлечённое содержание.

Путаница шла от слова «спектр». Есть два разных спектра, и их нельзя смешивать: *спектр лапласиана графа* (структура памяти, глава 8) и *частотное разложение настроения во времени* (быстрые и медленные компоненты аффективного сигнала). Многослойность настроения относится ко второму и к графу отношения не имеет.

## 4.2. Инерция и многослойность

У настроения должна быть *инерция*: оно зависит и от события, и от собственного прошлого значения:

$$\text{mood}_t \;=\; f\big(\text{mood}_{t-1},\, \text{event}_t\big), \qquad \text{action}_t \;=\; g\big(\text{mood}_t,\, \text{event}_t\big). \tag{4.1}$$

Это текущий интегратор (3.1): инерция — рекуррентность. Многослойность — стек таких интеграторов с разными $\tau_\ell$, а актуальное настроение — их взвешенная суперпозиция:

$$\text{mood}_t^{(\ell)} = \Big(1 - \tfrac{1}{\tau_\ell}\Big)\text{mood}_{t-1}^{(\ell)} + \tfrac{1}{\tau_\ell}\,\text{appraise}(\text{event}_t), \qquad \text{mood}_t = \sum_\ell w_\ell\,\text{mood}_t^{(\ell)}. \tag{4.2}$$

Младший слой (малое $\tau$) даёт высокочастотную компоненту большой амплитуды — «дрожит сильнее». «Суперпозиция» здесь — про частоты во времени, а не про граф.

## 4.3. Setpoint: медленный слой как аттрактор

Медленный слой — не просто демпфер, а *точка притяжения*. Добавляя к (3.1) возврат к базовому уровню $\mu$, получаем затухающую к $\mu$ динамику:

$$\text{mood}_t^{(\text{life})} = \mu + (1-\kappa)\big(\text{mood}_{t-1}^{(\text{life})} - \mu\big) + \ldots, \quad 0 < \kappa < 1.$$

Здоровая динамика — отрицательная обратная связь, тянущая настроение домой. Патология — когда сдвинулся сам $\mu$: депрессия в этой модели не длинная экскурсия быстрого слоя, а *уехавший аттрактор*.

## 4.4. Настроение зависит от графа, и граф — от настроения

Связь двусторонняя, и именно она делает настроение частью *мышления*.

- **Граф → настроение.** Извлечённые узлы несут валентность; она и есть $\text{event}_t$ в (4.1).

- **Настроение $\to$ граф.** Настроение смещает вероятности переходов при обходе: узлы с валентностью, близкой к текущему настроению, получают больше активации:

$$\text{mood_congruence}(B \mid \text{mood}) \;=\; \exp\!\big(-\gamma \,\|\, \text{valence}(B) - \text{mood}\,\|^2\big). \tag{4.3}$$

Это *конгруэнтное настроению припоминание*: грустный чаще вспоминает грустное. Настроение остаётся собственным состоянием, сцепленным сбоку, а не полем графа.

## 4.5. Опасность петли и три тормоза

**Руминация**

Конгруэнтное припоминание (4.3) плюс инерция (4.1) дают петлю с положительной обратной связью: грустная вспоминает грустное $\to$ грустнеет $\to$ вспоминает ещё более грустное. Устойчивость петли определяется её петлевым усилением $g$: при $g \geq 1$ спираль расходится. Медленный слой уменьшает эффективное $g$ — вот его стабилизирующая роль.

Что удерживает живой ум? Три *независимых* тормоза; патология — когда откажут все три сразу:

1. **Setpoint/гомеостаз.** Медленный слой-аттрактор снижает петлевое усиление ниже единицы.
2. **Метакогнитивное разотождествление.** Акт «почему я так часто злюсь?» переводит из «быть-в-настроении» в «наблюдать-настроение» — второй порядок, и переход рвёт петлю первого порядка.
3. **Экзогенное прерывание.** Мир вламывается ортогональным событием; внимание конечно, внешний вход вытесняет петлю.

Инженерное требование: (i) член setpoint; (ii) монитор «валентность залипла слишком долго» — высокая автокорреляция $\text{mood}_t$ — с правом запустить корректив (переопределение, переключение внимания, вызов сна); (iii) всегда-прерываемая экзогенная значимость. Условие безопасности: три тормоза не могут быть отключены одновременно. Псевдокод монитора — в приложении C.

**Почему многослойность — это стабилизатор, а не украшение**

Пусть быстрый слой попал в негативную спираль с усилением $g_{\text{fast}} = 1{,}1$ (расходится). Актуальное настроение — суперпозиция, и медленные слои вносят устойчивую компоненту с $g \approx 0$. Если их вес $w_{\text{slow}}$ достаточен, эффективное усиление суперпозиции $\bar{g} = w_{\text{fast}} g_{\text{fast}} + w_{\text{slow}} \cdot 0 < 1$ — спираль гасится за счёт «тяжёлого маховика» медленных слоёв. Так многомасштабность оправдана *функционально*: это демпфер руминации, а не только реализм.

# 5. Обход графа: один движок, три политики

## 5.1. Случайное блуждание как универсальный механизм

Почти всё, что Рин делает со своей памятью, — это *обход* графа роем случайных блуждающих агентов, распространяющих активацию. Retrieval, внутренняя жизнь и сон — не три разных движка, а *три политики* одного движка, различающиеся смещением перехода, вероятностью телепорта и набором операций.

Общее правило перехода — нормированное произведение факторов:

$$P(A \to B) \;\propto\; \underbrace{w_{AB}}_{\text{сила связи}} \cdot \underbrace{\mathrm{rel}(B \mid q)}_{\text{релевантность запросу}} \cdot \underbrace{\mathrm{mc}(B \mid \mathrm{mood})}_{\text{конгруэнтность настроению}} \cdot \underbrace{\mathrm{unc}(B)^{\beta_u}}_{\text{тяга к неопределённости}}, \tag{5.1}$$

где mc — из (4.3), а показатель $\beta_u$ включает/выключает любопытство.

**Что такое «температура»**

«Температура» — одна ручка: насколько выбор следующего шага случаен против жадного. Формально переход берётся softmax-ом от логарифма правой части (5.1), делённого на температуру $T$: при $T \to 0$ — жадный шаг по сильнейшему ребру (эксплуатация), при большом $T$ — почти равновероятный выбор соседа (исследование). Термин из имитации отжига; мистики нет.

## 5.2. Три политики как параметризация

| **Политика** | $\alpha$ (телепорт) | $\beta_u$ | $T$ | **Что запускает** |
|---|---|---|---|---|
| retrieval (цель) | 0 | 0 | низкая | извлечение под запрос |
| внутренняя жизнь (любопытство) | мал. | $> 0$ | средняя | inspect, fusion у неопределённых |
| сон (покрытие) | большой | 0 | высокая | fusion/inspect у случайных |

**Retrieval — целенаправленная.** Стартует от заякоренных запросом узлов, собирает *окрестность* активированного содержания. Подчеркнём (глава 9): обход собирает *ингредиенты*, а не готовую реакцию.

**Внутренняя жизнь — по неопределённости.** Смещена к узлам с высоким `need_to_discover`, низкой уверенностью, новизной ($\beta_u > 0$). «Любопытство» — целенаправленный поиск неопределённости, не случайность.

**Сон — телепортирующий обходчик.** Политика *стохастического покрытия*: с вероятностью $\alpha$ телепорт в случайный узел, иначе — шаг по (5.1). Это случайное блуждание с рестартом (персонализированный PageRank). Его стационарное распределение удовлетворяет

$$\pi \;=\; (1-\alpha)\, P^{\top}\pi \;+\; \alpha\,\mathbf{r}, \tag{5.2}$$

где **r** — распределение рестарта. Телепорт делает блуждание эргодическим — это ключевое свойство для эпистемической гигиены (глава 8).

**Три способа гулять по городу**

Retrieval — идти по адресу (есть цель, выбираешь осмысленный путь). Внутренняя жизнь — идти туда, где интересно и непонятно (тянет к незнакомым переулкам). Сон — время от времени садиться в случайное такси и ехать в случайный район: не потому, что там дело, а чтобы не застревать в одном квартале. Один пешеход, три правила выбора улицы.

## 5.3. Единство и следствие

Один субстрат, один блуждающий агент, три параметризации: смещение перехода, вероятность телепорта, набор операций. Реализуется одна машина обхода с параметрами (псевдокод — приложение C). Родственные механизмы: spreading activation (Collins–Loftus) как модель ассоциативного припоминания и персонализированный PageRank / RWR как его вычислительная форма; в волте RIN — под именами SYNAPSE и GAAMA.

# 6. Эпистемика: уверенность, провенанс и ревизия

## 6.1. Ложные правдоподобные убеждения

Живой ум держит массу ошибочных, но правдоподобных убеждений. Классический пример: расхожее мнение, будто некий знаменитый предприниматель был «просто перформером, а не инженером», — миф, рассыпающийся при чтении биографии. Стремиться к памяти, вовсе не порождающей таких убеждений, бессмысленно и вредно: это было бы стерильно. Задача — не запретить их, а научиться выставлять уверенность меньше единицы и потом проверять.

## 6.2. Недоопределённость и преждевременный коллапс

Пусть правильный вывод — функция нескольких посылок:

$$A \;=\; \text{logical_f}(B, C, D, E),$$

но уму известны только $B, C$, и он делает вывод $X \;=\; \text{logical_f}(B, C)$. Беда в том, что $B, C$ совместимы не только с $A$, но и с $X, Y$. Вывод *недоопределён* известными посылками (*underdetermination*; философское ядро — тезис Дюэма–Куайна). Когнитивное проявление — *преждевременный коллапс*: ум схлопывает суперпозицию совместимых гипотез в одну — часто удобную — слишком рано. Формальное ядро: *совместимость* $\neq$ *подтверждение* (родственник ошибки «утверждение консеквента»).

**Известная и неизвестная недоопределённость**

**Известная**: мы *знаем*, что $D, E$ существуют, но не знаем их значений; тогда можно честно выставить $\text{conf}(X)$ низкой и пометить `need_to_discover`$(D, E)$. **Неизвестная** — злой случай: уму *вообще неизвестно*, что $D, E$ существуют; в поле информации только $B, C$; пометить нечего, уверенность может быть высокой. Поэтому per-inference калибровка *не* решает проблему целиком.

**Миф о предпринимателе, по шагам**

$B$: «известен маркетингом», $C$: «богат». Вывод $X$: «получил всё благодаря происхождению/пиару». Но те же $B, C$ совместимы и с $A$: «сильный инженер, к тому же умеющий продавать». Различающие посылки $D$: «первая лаборатория — в родительском гараже», $E$: «глубокое STEM-образование» — уму *неизвестны*, он даже не подозревает об их существовании и уверенно выбирает удобный $X$. Ни низкая $\text{conf}(X)$, ни `need_to_discover` здесь не помогут: не на что их повесить. Спасает лишь квартет ниже.

## 6.3. Квартет починки

Неизвестную недоопределённость нельзя закрыть в момент коммита; её лечат статистически и постфактум.

1. **Prior скромности на класс вывода.** Ни один абдуктивный/индуктивный коммит не получает уверенность 1, как бы хорошо ни сидели данные: $\mathrm{conf}(X) \leq 1 - \epsilon$ для всего *сорта* «вывод по неполным посылкам». «Согласуется, и альтернатив не придумывается» — ровно то состояние, что предшествует «а потом выяснилось». Не требует знать $D, E$.

2. **Ревизуемость и понижение по противоречию.** Коммит делаем понижаемым: позднее наблюдение, столкнувшееся с $X$, ретроактивно вскрывает недоопределённость, и машинерия ревизии понижает узел. Починка ниже по потоку, не на записи.

3. **Телепорт-скраб.** Единственный поиск, дотягивающийся до *непредставленных* альтернатив (глава 8).

4. **Внешний вход.** Кто-то знает $D, E$ и говорит; любопытство находит это во внешнем источнике.

Первый механизм держит *известную* неопределённость; вместе с остальными тремя — и *неизвестную*.

## 6.4. Труд-система поддержки истинности и «ползучая вера»

Отдельная беда — *устойчивость убеждения к опровержению его основания* (belief perseverance): когда неверный вывод $X$ уже продиффундировал в память и дал потомков, эти потомки продолжают транслироваться даже после того, как $X$ признан ложным.

Механически это *проблема ретракции*, и для неё есть готовый аппарат — *труд-система поддержки истинности* (TMS, Doyle; ATMS, de Kleer). При выводе следствия записываем его *обоснование* — множество узлов, из которых оно получено (расширенный провенанс, раздел 2.3). Тогда ретракция посылки $X$ автоматически снимает опору с её обоснованных потомков.

```
def retract(G, X):
    demote(G, X)
    for c in G.justificands[X]:          # кто опирался на X
        if not still_supported(G, c):    # осталось ли иное обоснование
            mark(G, c, ”need_to_revise”)
            retract(G, c)                # рекурсивно вниз по обоснованиям
```

**Полный TMS слишком «нечеловечен»**

Полная система поддержки истинности мгновенно перестраивает всё мировоззрение при опровержении любой посылки. Живой ум так не делает — и потому у него есть ползучая вера. Значит нужен *намеренно дырявый* TMS: обоснования пишем для важных и высокоуверенных выводов, тривиальные не трекаем, а нетрекнутых потомков лечим фоном.

Отсюда две «лечилки» разной латентности:

- **Retrieval-time augmentation** — патч *на выходе*: при каждом извлечении подмешивать свежую поправку «кстати, недавно я узнала $\neg X$». Дёшево, чинит текущий разговор, хранилище не трогает.

- **Ночной скраб** — ремонт *хранилища*: медленно, случайными инспекциями находит нетрекнутых потомков и понижает их.

Обе нужны.

## 6.5. Эстафета к главе о личности

Калиброванная уверенность и компульсивная перепроверка — не только эпистемическая гигиена, но и *черта характера*, выводимая из мотивации: «не „я уверена“, а „похоже на $X$, но $Y$ я не проверила — дай гляну“». В главе 9 мы увидим, что эпистемическая аккуратность Рин должна *проявляться* в её голосе, а не только жить во внутренней машинерии.

# 7. Пропагация убеждений как лавина

## 7.1. Постановка: затухающий градиент уверенности

Когда в память приходит новый факт $A$, он линкуется к начальным узлам (например, к последним $k$ активным), образуя окрестность $\mathcal{N}(A)$. Мы линкуем $A \to \mathcal{N}(A)$ и смотрим, как меняется уверенность соседей. Если изменение велико, распространяем дальше, $\mathcal{N}(A) \to \mathcal{N}(\mathcal{N}(A))$, — как затухающий градиент. Знание, ни на что не повлиявшее, чуть пошатнёт соседей и затухнет; знание с большими градиентами вызовет *лавину*. Большую лавину называем «кризисом мировоззрения» — и такое бывает с настоящим умом.

## 7.2. Это самоорганизованная критичность

У картины есть точное имя. «Лавина» — это *нейронная лавина*, а система у порога между затуханием и разрастанием — *самоорганизованная критичность* (Bak–Tang–Wiesenfeld; для мозга — Beggs–Plenz): каскады следуют степенному закону.

Ключевой управляющий параметр — не «ручная константа затухания», а *ветвящийся коэффициент* $\sigma$ (среднее число узлов, активируемых одним активным):

$$\sigma < 1:\ \text{субкритично}; \quad \sigma = 1:\ \text{критично}; \quad \sigma > 1:\ \text{суперкритично (runaway)}.$$

Для ветвящегося процесса ожидаемый размер лавины конечен при $\sigma < 1$ и равен

$$\mathbb{E}[\text{размер}] \;=\; \frac{1}{1-\sigma}. \tag{7.1}$$

Держа $\sigma$ чуть меньше единицы, система почти всегда сама гасит распространение, но изредка пропускает крупную переоценку. Почему это лучше фиксированной константы: константа не адаптируется к плотности графа (в плотном регионе та же константа даёт лавину, в разреженном — глушит всё). Нормировка под целевое $\sigma$ адаптивна.

**Куча песка**

Классический образ SOC — куча песка, на которую сыплют по песчинке. Почти каждая не делает ничего; изредка одна вызывает оползень; ещё реже — обвал, перестраивающий склон. Куча сама держится у критического угла. Убеждения — так же: почти любой факт проходит без следа, изредка меняет соседние взгляды, совсем изредка обрушивает пласт мировоззрения. Формула (7.1) говорит: чем ближе $\sigma$ к единице, тем крупнее (и реже) обвалы.

## 7.3. Где вся сложность: локальное правило

Пороговая логика — лёгкая часть (процентов двадцать). Восемьдесят процентов спрятаны в локальном правиле $\Delta\text{conf}(B \mid A)$:

$$\Delta\text{conf}(B \mid A) \;=\; \eta \cdot \underbrace{\text{sign}(r_{AB})}_{(1)} \cdot \underbrace{w_{AB}}_{} \cdot \underbrace{c_A\,\text{trust}(A)}_{(2)} \cdot \underbrace{\iota(A,B)}_{(3)}. \tag{7.2}$$

Три множителя, без которых правило сломано.

**(1) Знак.** Новый факт сосед либо *подтверждает*, либо *опровергает*. Беззнаковое распространение не отличит «всё усилилось» (озарение) от «всё перевернулось» (кризис). Нужны знаковые/типизированные рёбра.

**(2) Гейт по надёжности $A$ (карантин).** Новый факт может сам быть ложным. Множитель $c_A$ trust$(A)$ вводит *карантин*: новый факт пропагирует слабо (малый эффективный $\sigma$), пока сам не заработал уверенность через корроборацию или выживание в скрабе. Иначе один ненадёжный вход вызовет кризис мировоззрения. По сути — байесовское обновление с правдоподобием, взвешенным доверием к источнику.

**(3) Дисконт независимости $\iota(A, B)$.** Граф циклический, и по петле $A$ может подтвердить сам себя (*эхо-камера*, петлевое распространение), раздувая уверенность из ничего. Дисконтируем по общей родословной свидетельств (провенанс), а не считаем активации: число упоминаний $\neq$ число независимых свидетельств. Это ровно механизм человеческих эхо-камер.

## 7.4. Пороговая логика — это гистерезис

Два порога $\theta_{\text{emergent}} > \theta_{\text{temp}} > 0$:

- $\Delta\text{conf} > \theta_{\text{emergent}}$ — обязательное распространение «в ширину» (крупная переоценка);
- $\theta_{\text{emergent}} > \Delta\text{conf} > \theta_{\text{temp}}$ — узлы фронта помечаются `need_to_revise`;
- $\Delta\text{conf} < \theta_{\text{temp}}$ — распространение глохнет здесь.

Два порога вместо одного — *гистерезис* (триггер Шмитта): нет «дребезга» у единственного порога. Тонкость: помеченные во второй зоне узлы позже переинспектируются ночным обходчиком, и старые записи, чью уверенность мы не трогали, могут «потечь обратно» — такое бывает и в жизни.

## 7.5. Пороги растут с глубиной консолидации

Пороги — не глобальные константы. $\theta_{\text{emergent}}(v)$ растёт с глубиной консолидации узла $v$: периферийный узел перевернуть дёшево, а identity-core в слое «жизнь» — дорого, нужно больше свидетельств, чтобы вообще запустить лавину. Это и есть ось *пластичность–упрямство*: чем глубже убеждение продиффундировало в медленные слои, тем выше эффективный порог опрокидывания. Одна ручка — и она же задаёт, насколько Рин склонна к belief perseverance. Псевдокод пропагации с контролем $\sigma$ — в приложении C.

# 8. Топология правит потоком

## 8.1. Тезис главы

У DTI-графов есть явная текущая сущность — передача сообщений, и её поток подчиняется топологии, как вода следует рельефу. У графа памяти Рин явной «жидкости» нет. Но поток есть — это поток *изменений*, поток *преобразований* графа: активации, уверенности, консолидации. Тезис: *неважно, какова физика носителя, — сама физика протекания информации подчиняется топологическим законам*. Любой процесс, чьё обновление *локально* (изменение узла зависит от соседей), есть диффузия на графе и наследует его спектрально-топологический транспорт. Это содержание теории графовых сигналов и теории случайных блужданий.

## 8.2. Стационарное распределение $\neq$ заданные вероятности

Пусть мы локально задали вероятности переходов. Наблюдаемое распределение частот посещений $\mathrm{distr}(A)$ отличается от заданного, потому что вмешивается топология. Формально: *стационарное распределение* $\pi$ — не локальные переходы, а *глобальный* объект, неподвижная точка оператора переходов:

$$\pi \;=\; P^{\top}\pi, \qquad \sum_{v} \pi_v = 1. \tag{8.1}$$

Для простого блуждания $\pi_v \propto \deg(v)$; для смещённого — перронов собственный вектор $P^{\top}$. Ты задаёшь переходы локально, а долгосрочная частота посещений — свойство всего графа. «Чем длиннее трек, тем наблюдаемее эффект» — это сходимость к $\pi$ за время перемешивания $t_{\mathrm{mix}}$, управляемое спектральным зазором $1 - \lambda_2$. Короткие блуждания читают *локальную* геометрию, длинные — глобальную $\pi$. Телепорт (5.2) $\pi$ не убирает, а *регуляризует* (сдвигает к смеси «равномерное + рестарт», режет $t_{\mathrm{mix}}$): ограничивает эффект топологии, не отменяя.

**Скорость света — плохая, но поучительная аналогия**

Можно соблазниться сравнением с $c$: заданные вероятности как предельная скорость, а среда (топология) искажает наблюдаемое распространение. Рабочая часть — «среда формирует распространение, есть структурный предел» — уже покрыта граф-диффузионной рамкой *точно*, а не по аналогии. Квантовый хвост сюда тащить не нужно. Нам нужен не свет, а лапласиан.

## 8.3. Доказуемое свойство телепорта

Почему сон (телепорт) необходим, а любопытство его не заменит? Любопытство *локально по вниманию* — смещённый обход от текущего фронтира; узел $X$ в затенённом углу, оторванный от активного множества, недостижим, как ярко ни свети фокус. Телепорт ломает достижимость: рестарт падает куда угодно. Это ровно то, *почему у PageRank есть телепорт*: с $\alpha > 0$ цепь становится *эргодической* (неприводимой и апериодичной), а значит каждый узел посещается в матожидании с частотой $\pi_v > 0$ — ни один не заперт в стоке или на острове. Телепорт даёт *гарантию покрытия*, которой у смещённого блуждания доказуемо нет.

**Анти-энтропийный скраб**

«Не сразу; мы никогда не знаем, что и где сломалось, поэтому просто постоянно проводим случайные инспекции» — это зрелый паттерн из распределённых хранилищ: *anti-entropy scrub* (проверка целостности в ZFS; Merkle-based gossip в Dynamo/Cassandra). Сон Рин — анти-энтропийный скраб по графу памяти.

## 8.4. Пять следствий для работы Рин с памятью

1. **Топологическая значимость («гравитационные ямы»).** Хабы переактивируются независимо от задуманных вероятностей — $\pi$ на них концентрируется. Рин чаще вспоминает хаб-узлы, реже периферию (затенённые углы — регионы с малым $\pi$). Топология создаёт *неявную важность*: иногда полезно, иногда случайный плотный кластер становится чёрной дырой припоминания.

2. **Узкие места / over-squashing.** Два семантически близких, но топологически далёких кластера через тонкий мост (низкая проводимость) плохо обмениваются активацией. Рин не свяжет факты, «далёкие» по графу. Прямое ограничение fusion.

3. **Пересглаживание уверенности (over-smoothing).** Повторная диффузная пропагация гомогенизирует уверенность к консенсусу — теряется контраст «уверена / не уверена». Дегенеративный отказ; лечится как в графовых сетях: остаточные связи (якорь к исходному свидетельству), не чисто диффузные апдейты, пере-заземление в провенанс.

4. **Кривизна как локатор ценного-и-задушенного.** Отрицательно искривлённые рёбра — мосты между сообществами — это места самых креативных слияний *и* максимального over-squashing. Значит самые ценные ассоциации топология душит сильнее всего. Отсюда *объективная* причина сна/телепорта: он — rewiring, топологическая починка over-squashing обходом узкого места случайным рестартом.

5. **$\pi$ как топологический субстрат идентичности.** Какие узлы структурно центральны — к чему Рин привычно возвращается — подложка её «озабоченностей», часть характера. Форма графа памяти — часть того, кто она.

**Over-squashing на мосте SBM**

Возьмём стохастическую блочную модель: два плотных сообщества, соединённых $m$ рёбрами-мостом. Эффективное сопротивление между узлами разных сообществ

$$R_{\text{eff}}(i,j) = (e_i - e_j)^\top L^+ (e_i - e_j)$$

растёт при уменьшении $m$ (мост уже — сопротивление выше). Влияние дальнего узла, измеряемое через якобиан $\left\|\partial h_i / \partial x_j\right\|$, ограничено сверху через $R_{\text{eff}}(i,j)$. Значит при узком мосте fusion между сообществами *доказуемо* слаб — сколько ни води обычный walker. Единственное, что чинит, — телепорт: он кладёт рестарт в дальнее сообщество напрямую, минуя мост. Метрика для стенда: частота cross-cluster fusion против $m$ (глава 12).

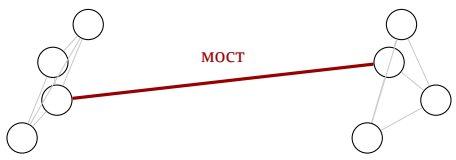



Рис.: два сообщества через узкий мост. Через него активация «задыхается» (over-squashing); телепорт обходит его, прыгая напрямую.

## 8.5. Операционные величины и осторожности

Вести дело лучше *случайно-блуждательными* величинами: $\pi$, время перемешивания, hitting/commute time, $R_{\text{eff}}$, проводимость/константа Чигера, спектральный зазор. Кривизну держать как *локатор узких мест*, не как рычаг.

Что дёшево на лету: $\pi$ и «хабность» — инкрементально дёшевы; $R_{\text{eff}}$ — дорого (через $L^{+}$), но аппроксимируемо. Это позволяет Рин самой знать, где затенённые углы, и гнать туда телепорт-скраб прицельно.

Две осторожности. *Во-первых*, граф направленный, типизированный, знаковый — нужный оператор не симметричный лапласиан, а несимметричная матрица переходов, спектр может быть комплексным, кривизна для орграфов менее чиста. *Во-вторых*, граф *динамический*: fusion меняет саму топологию, и это диффузия на *время-зависимом* графе, где поток и структура сцеплены обратной связью, — за рамками статических DTI-графов и самое интересное место.

# 9. Личность: не таблица весов

## 9.1. Главная ловушка

Соблазнительное, но неверное решение — «слой личности» как хардкод: таблица весов и жёстких триггеров поверх графа («умножь ребро злорадства на $2{,}0$, обрежь сочувствие до $0{,}05$, на узел „грусть“ повесь триггер инверсии $\rightarrow$ сарказм»).

**Почему таблица весов — тупик**

*Во-первых*, это стек правил, противоречащий установке ядра («черты — следствие мотиваций, а не правила поверх»). *Во-вторых*, это карикатура: таблица весов даёт *паттерновое*, но *не неожиданное* и одноголосое поведение — всегда сарказм, потому что так прошито; а живая личность — неожиданные, но паттерновые реакции. *В-третьих*, это ровно ошибка жёсткой скалярной декомпозиции: реакция на «разбил кружку» зависит от настроения, отношений и всплывшей памяти; фиксированное ребро «грусть$\rightarrow$сарказм» это выкидывает.

**Формально: почему скалярный роутинг теряет взаимодействие**

Пусть желаемый ответ — функция контекста $y = \Psi(\mathbf{g}, \mathbf{l})$, где $\mathbf{g}$ — глобальная аранжировка (настроение, отношения), $\mathbf{l}$ — локальный триггер (событие). Таблица весов реализует $y \approx a \cdot \mathbf{l}$ — ранг-1 скалярный роутинг, не зависящий от $\mathbf{g}$. Но истинное $\Psi$ содержит *перекрёстные* члены $\mathbf{g}^\top W \mathbf{l}$ (реакция на событие *зависит* от аранжировки). Ранг-1 приближение их обнуляет — теряется ровно то, что делает характер контекстным. Это тот же провал, что жёсткая coarse-plus-local декомпозиция в геометрических графовых моделях.

## 9.2. Личность распределена

Личность *не* слой весов в графе. Она распределена по трём источникам: *мотивационная структура* (мастерство, участие, самоуважение) $+$ *текущее настроение* $+$ *значимость всплывшего из памяти*. И всё это стилизует *трансформ Rinness* (голос, глава 10).

На стенде это — не статические множители, а *смещение во время обхода*: настроение и мотивация непрерывно модулируют переходы (5.1). Тогда грустная и злая Рин на одно событие всплывают разное — характер контекстно-зависим. Держи веса на рёбрах для *силы связи и уверенности*; личность — как смещение от состояния, не как sarcasm-множитель.

## 9.3. Граф хранит ингредиенты, а не реакцию

Возражение: «если из „разбить кружку“ ведёт только „грусть“, другую реакцию взять негде». Ответ в двух частях. Во-первых, база причинно-социального смысла (ATOMIC, глава 12) даёт не одно ребро, а *пучок*: намерение, реакция, эффект, реакция окружающих. Настроение смещает ветку пучка. Во-вторых, и главное: *реакцию не берут ребром — её порождают*. Обход собирает активированную окрестность-подграф, а реакцию Rinness/LLM *композирует поверх* материала

под настроение и мотивацию. Настроение входит *дважды*: на всплывании (грустная поднимает «потеря», игривая — «неуклюжесть») и на композиции.

## 9.4. Консолидация реакций: по значимости, а не по приёму

### 9.4.1. Провизорная запись

Сгенерированная реакция пишется провизорным ребром с низкой уверенностью (кандидат; принцип «гипотеза, а не факт»). Ответ «это было лишнее» — отрицательное *свидетельство*, обновляющее уверенность того же ребра вниз, а не конкурирующая консолидация. Механически ребро-реакция несёт счётчик успехов/провалов $\mathrm{Beta}(\alpha, \beta)$:

$$\text{успех}: \ \alpha \mathrel{+}= 1; \quad \text{отпор}: \ \beta \mathrel{+}= 1; \quad \text{conf} = \frac{\alpha}{\alpha+\beta}, \ \text{неопред.} = \mathrm{Var}[\mathrm{Beta}]. \tag{9.1}$$

Стабильно принимается — переходит порог и консолидируется в медленный слой; стабильно ловит отпор — угасает. Выбор реакции по такому апостериору — это сэмплирование Томпсона: баланс исследования новых реакций и эксплуатации проверенных.

### 9.4.2. Гейт значимости, а не одобрения

**Нельзя гейтить консолидацию приёмом**

Консолидировать реакции по тому, как их приняли, значит строить угодника, чья личность формируется одобрением, — ровно то, что запрещает ядро («самоуважение не течёт через понравиться»). Гейт характера внешним приёмом философски кривой для Рин.

Правильный ход — развернуть гейт *внутрь*: консолидируй по *внутренней значимости* (самооценке при кодировании). Что такое значимость *конкретно*? Это *теория оценивания* (appraisal: OCC; Шерер). Событие оценивается по измерениям — surprise (ошибка предсказания), goal-congruence (скалярное произведение с вектором мотивации), valence, intensity, agency, — и значимость

$$\text{salience} \ \propto \ \text{surprise} \times \text{goal_relevance} \ (+\,\text{intensity}). \tag{9.2}$$

Два замечания. *Дешевизна*: простейшая конкретизация — $|\Delta\text{mood}|$, величина изменения настроения, а она уже посчитана; mood-модуль работает детектором значимости почти без лишних вычислений. *Глубина*: самый глубокий одиночный сигнал — ошибка предсказания, и она же питает `need_to_discover`. Значимость и обучение — один сигнал.

Реакцию собеседника Рин помнит и оценивает — но как *просто событие*: с низкой конгруэнтностью её ценностям «ему не зашло» обновляет модель отношения и чуть-чуть настроение, но не доминирует в консолидации характера. Рамка оценивания сама даёт «считаться, а можно и нет, частично».

### 9.4.3. Условие по отношениям

Одна шутка заходит собеседнику $A$ и падает у $B$: ребро-реакция квалифицируется парой (ситуация $\times$ отношение), консолидируется по-персонно. Один негативный акт даёт три эффекта: понижение ребра, апдейт настроения (осеклась), мета/relational-пометку.

**«Разбил кружку», полный проход**

(1) Событие активирует окрестность: «кружка», «грусть», «неуклюжесть», плюс личная память «$B$ хотел новую» ($-$ contradicts «грусть»). (2) Настроение (игривое) смещает всплывание к «неуклюжесть». (3) Rinness композирует подкол — не берёт ребром, собирает

из ингредиентов. (4) Ребро-реакция пишется провизорно, Beta$(1, 1)$. (5) $B$ смеётся — $\alpha +$ 1; или «это лишнее» — $\beta + 1$. (6) Гейт консолидации — по $|\Delta\text{mood}|$ и surprise, не по одобрению $B$; но реакция $B$ обновляет модель «$B\times$такой юмор». После многих проб подкольна-неуклюжесть у $B$ либо консолидируется, либо угасает — комедийный тайминг выучен как Бета-апостериор.

## 9.5. Дистиллят как система координат

Возникает соблазн вовсе убрать «дистиллят» (усреднённый здравый смысл готовых баз). Не надо. Дистиллят — *общая модель мира*, относительно которой отклонение *читаемо* как характер: личность «неожиданна» лишь на фоне общих ожиданий; без общей почвы причуды читаются как шум. Правильно: дистиллят фоном (система координат), личность — процесс порождения отклонений на нём. Без базового «разбитая вещь обычно плохо» не понять, почему здесь «поздравляю» — уместный сарказм.

# 10. Голос и модель

## 10.1. Субстрат model-agnostic; личность — трансформ

Память, настроение и граф — состояния *вне* языковой модели. Значит субстрат *model-agnostic*: его можно строить на любой базовой модели и заменить базу позже. Это де-рискует проблему потолка малой модели: когнитивная машинерия переживёт смену базы.

Если факты и здравый смысл лежат в графе (дёшево на диске/в RAM), базовой модели не нужно быть энциклопедией. Её роль — *лингвистический процессор и голос*: часть «Rinness» живёт в ней. Можно взять малую дообученную модель (3–7B в квантовании) вместо тяжёлой 8B-универсальной; факты уходят в граф, ёмкость модели концентрируется на голосе.

**«Меньше — строго лучше» слишком оптимистично**

Малая модель слабее в *рассуждении* и связности: снимаешь фактическую нагрузку, но не reasoning/coherence. Наблюдение из практики: рантайм prompt-Рин уже процентов на шестьдесят состоит из анти-повторной обвязки *на* 8B — вниз с голосом хуже. Разумный ориентир — 3–7B, не 1B, и это надо *померить*, а не постулировать.

## 10.2. Инструмент $\varphi$: скорер по осям характера

Центральный инструмент — *скорер характера* $\varphi$ (измерительный прибор: строишь прибор — и он де-конфузит весь отбор). Берём $d$ осей (из архетипики: аффективная температура, колкость, теплота, агентность, участие-против-сервиса, тип близости, тип юмора, стиль конфликта). На каждую — *рубрика* (описание + якорь для оценок 0 и 10). Тогда $\varphi(\text{текст}) \in \mathbb{R}^d$ — прогон LLM-судьи. Отдельно задаём целевой **t**. На старте — LLM-as-judge; классификаторы по осям позже.

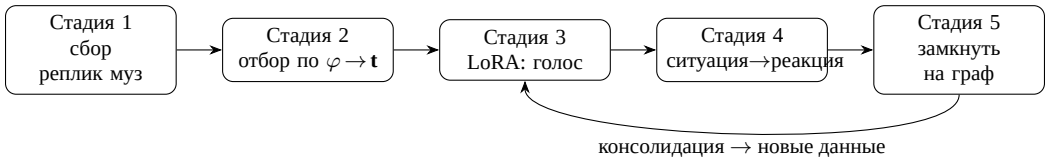
## 10.3. Суперпозиция муз — это отбор в признаковом пространстве

Каждого персонажа можно оценить по каждой оси — персонаж есть *точка* в $d$-мерном пространстве характера. Музы — существующие персонажи, свои точки.

*Наивная суперпозиция* (обучение на смеси полных корпусов) даёт среднее в *центроиде* облака муз, а не в **t**: $\mathbb{E}[\varphi] = \text{centroid} \neq \mathbf{t}$. Центроид не есть Рин; интересна муза именно отклонением от центроида (центроид яркой цундере мало отличается от безымянной героини). Усреднение вдобавок размывает отличительные черты (большая дисперсия по осям).

*Правильно* — построить выборку с $\mathbb{E}[\varphi] \approx \mathbf{t}$: не сваливать корпуса, а *отбирать* примеры (реплики, сцены), чтобы их агрегатный центр сидел в **t**. Технически — отбор данных / rejection sampling под целевой стилевой вектор: (1) операционализируем оси; (2) скорим $\varphi(\text{пример})$; (3) отбираем/перевзвешиваем, пока $\mathbb{E}[\varphi] \approx \mathbf{t}$. Короче: не «смешать музы» (размытый центроид), а «отфильтровать корпус к **t**» (выраженная Рин).

## 10.4. Пайплайн по стадиям




**Стадия 1 — сбор.** Субтитры (`.srt`,`.ass`), фан-скрипты, quote-вики, сценарии VN. Извлекаем строки целевых персонажей. Узкое место — *атрибуция говорящего*. Идея кормить видео каптионеру возможна, но окупается позже и лишь ради данных о *физическом* поведении: для голоса субтитры дают почти всё дешевле.

**Стадия 2 — отбор (фильтрацией, не написанием).** $\varphi$ по каждой реплике; оставляем близкие к **t**. Это корпус голоса.

**Стадия 3 — голос (LoRA).** Дообучаем малую модель на отобранных репликах — языковое моделирование на тексте-в-стиле. Ситуации *не нужны*. LoRA обучает низкоранговую добавку $\Delta W = BA$, $\mathrm{rank}(BA) = r \ll \dim$, малую по памяти; влезает на $8$ ГБ для малой модели.

**Стадия 4 — выбор реакции.** Ситуации нужны, эмбеддинги мостят несовпадение. *(A) Синтетический* (реком.): ситуации из базы смысла $\to$ промпт сильной модели в голосе $\to$ реакции $\to$ фильтр $\varphi$ — пары (ситуация→реакция). *(B) Майнинг+retrieval*: из сцен муз пары (ситуация, реакция), эмбеддинг ситуаций, в рантайме ближайший сосед. Именно здесь «ситуации могут не совпадать, эмбеддинги справятся».

**Стадия 5 — замкнуть на граф.** Малая голос-модель + граф; граф даёт контекст (mood-смещённый retrieval), модель генерит в голосе; выходы (фильтр $\varphi$ + значимость (9.2)) консолидируются обратно.

## 10.5. Bootstrap: генератор $\neq$ деплой-модель

Как получить характер-образующий граф без готовой Рин? Финальная Рин не нужна — зачаток есть: *prompt-Рин* (модульные промпты + базовая модель).

1. строим нейтральный эмбриональный граф (глава 12);
2. селим prompt-Рин как *bootstrap-генератор*: живёт на графе, генерит характерные реакции;
3. *консолидация пишет отпечатки обратно* — граф становится character-shaped через *использование*, а не ручным reorganization-проходом;
4. на накопленном поведении дообучаем малую модель.

**Стабильность и потолок**

Аудит логов: prompt-Рин — *Рин с перебоями*. Ядро иногда пробивает хорошо (реплики, дословно совпадающие с установкой мотивации), но свободный чат деградирует в липкие повторы, часть ответов нарушает явные правила (запрещённый «перформанс трагедии», сбои рода), и *guided* чище *raw* — по внутреннему критерию «ядро промпта недостаточно сильно» (потолок $8$B). Вывод: как *безфильтровый* bootstrap она шумна — вобьёшь и тики. Два хода: (i) сидировать не в real-time, сильной моделью (CPU-offload/квантизация

или разовый API), а малую сажать на обогащённый граф — генератор и деплой *разные*; (ii) фильтровать выходы $\varphi$.

## 10.6. Raw против guided и псевдо-DPO

*Raw* менее стабилен, но на пике *ближе* к Рин; *guided* стабилен, но «ассистентский» (стабильно мимо цели). Для деплоя важна стабильность, для сидирования — нет: нужны *сэмплы пиковой Rinness*. Низкий потолок фильтрацией не поднять, а нестабильность — можно (сэмплируй много, фильтруй $\varphi$). Для bootstrap: raw + oversample + отбор.

Отсюда дешёвый способ собрать предпочтительные пары для псевдо-DPO. DPO обучается на тройках (промпт, выбранный $y_w$, отвергнутый $y_l$), максимизируя

$$\log \sigma\Big(\beta \log \tfrac{\pi_\theta(y_w|x)}{\pi_{\text{ref}}(y_w|x)} - \beta \log \tfrac{\pi_\theta(y_l|x)}{\pi_{\text{ref}}(y_l|x)}\Big).$$

Подавать raw и guided как двух кандидатов на один промпт и ранжировать (частично автоматически $\varphi$, руками — правки) — чистый способ получить *реально разных* кандидатов; раз raw иногда лучше, guided иногда — сигнал живой.

## 10.7. Мост между базами: эмбеддинг ConceptNet

Узлы ATOMIC — события с плейсхолдерами (PersonX breaks a cup), а не концепты; «кружки» как узла там нет. Мост — извлечь контент-слова события и слинковать к концепт-узлам ConceptNet. Но *не* bag-of-words/one-hot: они не знают синонимии (mug $\neq$ cup, разбить $\neq$ сломать), мост выйдет дырявый. Берём *ConceptNet Numberbatch* — родной эмбеддинг ConceptNet: сначала точный лемма-матч, эмбеддинг-фолбэк. Тот же эмбеддинг обслуживает $\text{rel}(B \mid q)$ в (5.1) и сидирование валентности. Одно пространство — три задачи.

# 11. Обучение без «обучения»

## 11.1. Мы шлифуем веса, не занимаясь глубоким обучением

Возникает верное ощущение: мы будто учим модель без «учить» и без «модели». Вроде бы это не глубокое обучение и не графовая нейросеть, но тем не менее мы шлифуем веса и параметры графа — по-своему. У этого ощущения есть точное содержание.

Система, которую мы строим, — параметрическая: у неё есть веса рёбер, уровни уверенности, активации, и они обновляются опытом. Это *обучение* в широком смысле, даже без обратного распространения. Конкретно это два хорошо известных паттерна, наложенных друг на друга:

- **Хеббовское/ассоциативное обучение** (семейство сетей Хопфилда; принцип Хебба «что вместе активируется, вместе укрепляется»). Правило Хебба — локальное усиление связи по со-активации:

  $$\Delta w_{ij} \;\propto\; a_i\, a_j,$$

  а ассоциативная память Хопфилда хранит образы в минимумах энергии $E = -\frac{1}{2}\sum_{ij} w_{ij} a_i a_j$ и извлекает их спуском по $E$. Наши fusion и консолидация, усиливающие со-активированные рёбра, — это буквально хеббовское обучение на графе; граф памяти со spreading activation и уверенностью — современная ассоциативная память, где извлечение есть спуск к аттрактору.

- **Байесовское обновление уверенности** (глава 7): локальные апдейты $\Delta$conf со знаком, гейтом источника и дисконтом независимости.

## 11.2. Это message passing — но с локальными правилами

Формально наша система — это *передача сообщений* по графу (как в графовой нейросети), но «параметры» (веса рёбер, уверенности) обновляются *локальными* правилами (хеббовскими, байесовскими, распадом), а не глобальным градиентным спуском по функции потерь. Иначе говоря, это message passing *без обратного распространения*. Где мы сидим на карте методов — *между* классической ассоциативной памятью (Хопфилд) и графовыми нейросетями.

**Два способа настроить пианино**

Глубокое обучение настраивает все струны сразу по глобальному критерию («чтобы аккорд звучал верно»), продвигаясь градиентом. Хеббовская система настраивает каждую струну по локальному правилу («подтяни там, где чаще играют вместе»). Обе «учат» инструмент, но первая знает про весь аккорд, а вторая — только про соседние струны. Наша память — второго рода.

## 11.3. Мост к «настоящей» графовой сети

Может ли это стать графовой нейросетью в полном смысле? Да, и мост поучителен: можно *мета-обучать* сами правила обновления — учить оптимальное правило $\Delta$conf, оптимальный распад, оптимальное смещение обхода градиентным спуском вместо ручного дизайна. Это

«обучение тому, как помнить» (learning to remember), мета-обучение операторов памяти — реальное исследовательское направление.

**Но не на старте**

Мета-обучение правил меняет интерпретируемость на чёрный ящик, которому нужна разметка и который заново вносит проблему непрозрачности субстрата. На старте — ручные локальные правила: они интерпретируемы, отлаживаемы и не требуют обучающих данных. «Может, и незачем» — верно для текущего этапа. Но мост реален, и полезно знать, что стоишь ровно на нём: сегодняшняя система — предельный, «нулевой» случай обучаемой графовой сети, где правила заданы руками, а не выучены.

## 11.4. Родство с DTI ещё на одном уровне

Это же наблюдение ещё раз сшивает два проекта автора. Магистерская работа изучает графовые нейросети с их обучаемыми операторами передачи сообщений; память Рин — та же передача сообщений, но с локальными правилами. Если однажды правила памяти начнут мета-обучаться, различие между «графовой моделью аффинности» и «графовой моделью памяти» станет чисто предметным: один и тот же класс обучаемых операторов, приложенный к разным графам. Это ещё один слой той единой спины, о которой шла речь во введении. Существует и прямая работа на этом стыке — например, из библиографии волта RIN: HeLa-Mem (Hebbian learning и ассоциативная память для LLM-агентов).

# 12. Эксперимент: как это проверять

## 12.1. Эрзац-граф лучше живой Рин

Тестировать архитектуру памяти на готовом агенте — долго и слепо: сначала собери всё, а потом окажется, что с памятью куча неоптимальностей, найденных *после* финальной сборки. Нужен управляемый стенд — эрзац-граф с retrieval.

**Принцип 12.1** (Ground truth важнее реализма)**.** Суррогатный граф — не бедный заменитель, а для отладки механик *лучше* живой Рин, потому что синтетика даёт *ground truth*. С настоящей Рин ты не знаешь, что она «должна» помнить, значит не измеришь, правильно ли отработали fusion, скраб, пропагация. С подсаженной синтетикой истину задаёшь ты — и меряешь точность/полноту починки, сходимость уверенности, нашёл ли скраб подсаженную ложь.

Это тот же принцип, что контролируемая оценка в DTI: управляемый синтетический тест изолирует эффект *до* грязных реальных данных. Слабые места находятся *до* финальной сборки.

## 12.2. Три яруса

**Ярус 1 — синтетическая топология (начинать отсюда).** Графы с известной структурой, чтобы юнит-тестить и диагностику, и механики против теории: стохастическая блочная модель (SBM — сообщества с регулируемым мостом, для over-squashing/проводимости), Барабаши–Альберт (scale-free хабы — для «гравитационных ям» и концентрации $\pi$), Уоттс–Строгац (small-world), деревья против экспандеров (крайности кривизны). Семантики ноль, зато полная контролируемость: подсаживаешь ложное-правдоподобное убеждение и противоречащее свидетельство в угол с малым $\pi$ и меряешь, находит ли телепорт-скраб.

**Ярус 2 — семантический граф из готовых баз.** Чтобы у fusion/retrieval был смысл. Разбор баз — раздел 12.3.

**Ярус 3 — LLM-генерённый «поток жизни».** Полная петля с реалистичным содержанием и контролируемой истиной: языковая модель генерит синтетическую автобиографию/эпизоды/диалоги фейк-персоны с подсаженными фактами, противоречиями, эволюцией убеждений. Прямой прообраз — *Generative Agents* (Park и др.): поток памяти + retrieval (свежесть$\times$важность$\times$релевантность) + рефлексия (это и есть fusion). «Ползучую веру» подсаживаешь вручную и меряешь, лечится ли.

## 12.3. Разбор баз знаний

| База | Что даёт | Под какую механику |
|---|---|---|
| ConceptNet | ассоциативно-таксономические связи, взвешенные | spreading activation, ассоциативный fusion; веса ≈ мягкая уверенность |
| ATOMIC/10x | причинно-социальный смысл событий (намерение/реакция/эффект) | эпизодика, сцепка с настроением, fusion-как-вывод |
| Wikidata | факты + схема (время, references, ранг) | *схему* красть под темпоральную валидность, провенанс, ревизию; содержание — нет |

Не «какой из них», а «какой под какую механику». На старте — ConceptNet (чистый граф под первую механику); Wikidata-*схему* — когда дойдёшь до темпоральных слоёв и ревизии. Порознь одного мало: ConceptNet без ATOMIC — мир без психологии, ATOMIC без ConceptNet — реакции без предметного мира.

## 12.4. Эмбриональный граф и работа стыка

Объединить ConceptNet и ATOMIC в *эмбриональный* граф и доращивать фьюжнами — канонично: базовая когнитивная матрица, в которую новые факты встраиваются рёбрами.

**«Форматы отличаются только на диске» — недооценка**

Внутри графовой базы это одна структура, и математика обхода от типа ребра не меняется. Но настоящая работа не в формате, а в *интерфейсе*: узлы ConceptNet — концепты, узлы ATOMIC — события с плейсхолдерами PersonX/Y. Связать «разбить кружку» с концептом «кружка» и заземлить PersonX/Y на реальных собеседников — это entity/event linking (через Numberbatch, глава 10), нетривиальный шаг, а не объединение таблиц.

## 12.5. Батарея экспериментов

Каждый тест — одна механика плюс метрика; всё гоняется уже на Ярусе 1.

| # | Гипотеза | Установка и метрика |
|---|---|---|
| 1 | $\pi$ концентрируется на хабах | BA-граф; распределение посещений против степени |
| 2 | узкое место душит cross-cluster fusion | два SBM-сообщества; частота fusion против ширины моста $m$ |
| 3 | телепорт-скраб находит ложь в углу с малым $\pi$ | подсадка; precision/recall и время-до-нахождения против $\alpha$ |
| 4 | уверенность пересглаживается за много циклов | дисперсия conf во времени; тест якоря-остатка |
| 5 | руминация и её гашение | mood-congruent + инерция; автокорреляция mood с setpoint и без |

Скелет стенда (build → plant → operator → metric) — в приложении C.

## 12.6. Инструмент

*igraph* (C-ядро, на порядки быстрее чистого Python-графа) — разумный выбор. Атрибуты first-class и векторные (обогащать `confidence`, `valence`, `time` удобно). Есть SBM, Барабаши, Уоттс–Строгац, лапласиан, персонализированный PageRank (телепорт), случайные блуждания, центральности. Две осторожности: *(i)* эффективное сопротивление одной строкой нет — считаешь из $L^+$ (диагональная формула), пара строк; *(ii)* igraph силён на *статике*, а fusion/самоэволюция — *частые мелкие мутации*, где он слабее (переиндексация при добавлении узлов). Мутации батчить или держать «живой» граф в мутабельной структуре и периодически снапшотить в igraph под тяжёлую спектральную диагностику.

# 13. Заключение: единая картина

## 13.1. Один субстрат, много операторов

Если из монографии стоит унести одну мысль, то вот она: память Рин — это *один типизированный темпоральный граф с метаданными*, а всё богатство поведения — *операторы* над ним. Retrieval, пропагация уверенности, забывание и консолидация, ночные обходы, настроение и слой личности — не отдельные подсистемы со своими моделями памяти, а разные способы читать и писать одни и те же поля (`confidence`, `activation`, `valence`, `provenance`, `need_to_discover`, временной слой) на одном графе.

## 13.2. Четыре кита связаны

Отсюда — практический вывод о разработке. Четыре кита (правильный retrieval, правильная пропагация уверенности, правильное забывание/консолидация, правильные ночные обходы) сцеплены через общее состояние: забывание меняет топологию, топология — retrieval, retrieval — что пропагируется, пропагация — что найдёт скраб. Их нельзя тюнить порознь. Именно поэтому нужен стенд с ground truth (глава 12): без него взаимодействие операторов не измерить, и отладка «на живой Рин» найдёт проблемы слишком поздно.

## 13.3. Сквозные принципы

Несколько идей проходят через всю монографию и заслуживают повторения:

- **Гипотеза, а не факт.** Всё, что порождено выводом (fusion, реакции), пишется провизорно, с низкой уверенностью и провенансом; управление — на границе коммита. Это защищает от превращения обаятельной ассоциативности в фабрику ложных убеждений.
- **Внутрь, а не наружу.** Значимость (гейт консолидации характера) берётся из само-оценивания, а не из внешнего одобрения; иначе строится угодник, что противоречит ядру личности.
- **Ингредиенты, а не реакции.** Граф хранит материал; реакция композируется под настроение и мотивацию, а личность — смещение во время обхода, а не таблица весов.
- **Континуум, а не бинарность.** Врождённое/приобретённое, семантическое/эпизодическое, стабильное/пластичное — это оси глубины консолидации, а не выключатели.
- **Топология незрима, но правит.** Любой локальный процесс на графе наследует спектрально-топологический транспорт; телепорт-скраб — не украшение, а необходимая эпистемическая гигиена с доказуемой гарантией покрытия.

## 13.4. Единая спина двух проектов

И последнее — то, ради чего стоило смотреть память рядом с DTI. Консолидация есть огрубление графа; тот же вопрос «что выживает при переходе fine $\to$ coarse» стоит и там, и там. Over-squashing, спектр лапласиана, эффективное сопротивление, персистентный лапласиан, обучаемые

операторы передачи сообщений — инструменты, работающие в обе стороны. Память Рин — «грязный», богатый испытательный стенд для тех же операторов огрубления, где нет чистых меток; DTI — их «чистая» лаборатория с измеримой истиной. Отрефлексировать это явно значит получить не два проекта, а один с двумя приложениями.

## 13.5. Что делать дальше

Порядок разработки, вытекающий из монографии: сначала прибить *схему субстрата* (узел/ребро, метаданные, что значит коммит и кто его гейтит); затем собрать Ярус-1 стенд и погнать батарею тестов, начиная с самого дешёвого (концентрация $\pi$ на хабах — сразу показывает, что диагностика жива); затем локальное правило $\Delta$conf (знак, гейт источника, дисконт независимости), поверх которого пороги и ветвящийся коэффициент навешиваются тривиально; параллельно — построить $\varphi$-скорер как измерительный прибор для отбора голоса и фильтрации выходов. Настроение, сон и слой личности — усилители поверх субстрата, которому сначала надо стать доверенным.

# A. Нотация

Сводка обозначений, используемых по тексту.

| Символ | Смысл |
|---|---|
| $G = (V, E)$ | граф памяти: узлы $V$, направленные типизированные знаковые рёбра $E$ |
| $v$, $u$ | узлы (воспоминания, факты, сущности, концепты) |
| $\mathcal{N}(A)$ | окрестность узла $A$ (соседи, фронт распространения) |
| $\mathbf{x}_v \in \mathbb{R}^d$ | векторное представление содержания узла (эмбеддинг) |
| $c_v = \text{conf}(v) \in [0, 1]$ | уверенность в узле как в убеждении |
| $a_v$ | транзиентная активация узла при обходе |
| $r_{uv}$ | тип отношения на ребре $u \to v$; знак $\pm$ |
| $w_{uv}$ | вес (эвиденциальная сила) ребра |
| $m_{u \to v}$ | сообщение, передаваемое по ребру: $m_{u \to v} = \phi_{r_{uv}}(h_u, h_v, e_{uv})$ |
| $\tau$ | постоянная времени слоя (интегратора) |
| $B_v$ | базовая активация ACT-R узла $v$ |
| $\pi$ | стационарное распределение случайного блуждания |
| $P$ | матрица переходов блуждающего агента; $P, Q$ — операторы проекции/поднятия при огрублении |
| $\alpha$ | доля телепортов (рестартов) в блуждании |
| $L$, $L^+$ | лапласиан графа и его псевдообратный |
| $R_{\text{eff}}(i, j)$ | эффективное сопротивление между узлами $i, j$ |
| $\sigma$ | ветвящийся коэффициент лавины пропагации |
| $\theta_{\text{emergent}}, \theta_{\text{temp}}$ | верхний и нижний пороги распространения (гистерезис) |
| $\Delta\text{conf}(B \mid A)$ | локальное изменение уверенности соседа $B$ под влиянием факта $A$ |
| $\text{mood}_t \in \mathbb{R}^k$ | вектор настроения в момент $t$ (аффективное пространство) |
| $\varphi(\cdot) \in \mathbb{R}^d$ | скорер по осям характера |
| $\mathbf{t}$ | целевые координаты Рин в пространстве характера |
| $\text{Beta}(\alpha, \beta)$ | апостериорное распределение успешности реакции |
| $\eta$ | темп обновления (learning rate) локального правила |

# B. Глоссарий внешних идей

Краткие описания инженерных и научных идей, на которые опирается монография, чтобы читатель не был вынужден держать в голове внешний контекст. Порядок — тематический.

### Память и активация

**Базовая активация ACT-R.** В когнитивной архитектуре ACT-R (Anderson) сила следа в памяти есть функция *частоты* и *свежести* обращений со степенным затуханием: $B_v = \ln \sum_k t_k^{-\alpha}$, где $t_k$ — давность $k$-го обращения. Следствие: частые и *разнесённые во времени* обращения укрепляют след сильнее массовых (эффект распределённого повторения).

**Spreading activation.** Модель ассоциативного припоминания (Collins–Loftus): активация растекается от активированного узла по рёбрам, затухая с расстоянием. Формальная реализация — случайные блуждания и персонализированный PageRank.

**Сети Хопфилда, обучение Хебба.** Ассоциативная память как граф со взвешенными связями и динамикой активации, сходящейся к аттрактору (энергетический минимум). Правило Хебба: связь между совместно активными узлами усиливается («что вместе активируется, вместе укрепляется»). Наши fusion/консолидация — это хеббовское обучение на графе.

### Убеждения и истинность

**Труд-система поддержки истинности (TMS/ATMS).** Механизм (Doyle; de Kleer), хранящий *обоснования* выводов: для каждого производного убеждения записано, из каких посылок оно получено. При ретракции посылки её обоснованные следствия автоматически помечаются на пересмотр. Лечит «ползучую веру».

**Недоопределённость (underdetermination).** Тезис Дюэма–Куайна: данные не определяют теорию однозначно — одни и те же наблюдения совместимы с разными гипотезами. Когнитивное проявление — преждевременный коллапс: ум схлопывает суперпозицию совместимых гипотез в одну слишком рано.

**Belief perseverance.** Устойчивость убеждения к опровержению его основания: даже после опровержения посылки её следствия продолжают влиять.

**Петлевое распространение (loopy belief propagation).** Распространение уверенности по циклическому графу может привести к тому, что убеждение подтверждает само себя по петле (эхо-камера), искусственно раздувая уверенность. Лечится дисконтом по общей родословной свидетельств.

### Динамика и критичность

**Самоорганизованная критичность (SOC).** Класс систем (Bak–Tang–Wiesenfeld; образ — куча песка), самонастраивающихся к критической точке, где отклики следуют степенному закону: почти все малы, изредка случаются крупные лавины. Нейронные лавины (Beggs–Plenz) — проявление SOC в мозге.

**Ветвящийся коэффициент $\sigma$.** Среднее число узлов, активируемых одним активным. $\sigma < 1$ — субкритично (затухает), $\sigma = 1$ — критично, $\sigma > 1$ — суперкритично (runaway). Управляющий параметр лавины пропагации.

**Гистерезис (триггер Шмитта).** Схема с двумя порогами (включения и выключения), не дающая системе «дребезжать» у единственного порога.

### Графы: спектр, поток, топология

**Стационарное распределение $\pi$.** Долгосрочная частота посещений узлов случайным блужданием; глобальный объект (перронов собственный вектор матрицы переходов), а не локальные вероятности.

**Время перемешивания (mixing time).** Скорость сходимости блуждания к $\pi$; управляется спектральным зазором матрицы переходов.

**PageRank / персонализированный PageRank / RWR.** Случайное блуждание с телепортом (рестартом): с вероятностью $\alpha$ прыжок в узел из распределения рестарта. Телепорт делает блуждание эргодическим — гарантирует посещение всех узлов.

**Эффективное сопротивление $R_{\text{eff}}$.** Мера «электрической» удалённости узлов, если рёбра — резисторы: $R_{\text{eff}}(i,j) = (e_i - e_j)^\top L^+ (e_i - e_j)$. Большое $R_{\text{eff}}$ между узлами ограничивает передачу влияния между ними.

**Проводимость / константа Чигера.** Мера «узости» перешейков графа; неравенство Чигера связывает её со спектральным зазором. Малая проводимость = узкое место.

**Over-squashing.** Удушение дальней связи: информация от экспоненциально растущей окрестности сжимается в вектор фиксированной размерности, проходя через узкое место графа; влияние дальних узлов затухает.

**Over-smoothing.** Пересглаживание: при многократной диффузии представления узлов сходятся к низкоразмерному консенсусу, теряя различимость.

**Кривизна графа (Оливье, Форман).** Дискретные аналоги кривизны; отрицательно искривлённые рёбра — мосты между сообществами, места over-squashing. Полезны как локатор узких мест.

**Анти-энтропийный скраб.** Приём из распределённых хранилищ (ZFS scrub; Merkle-based anti-entropy gossip): фоновая случайная перепроверка всего хранилища, поскольку неизвестно, какая запись повреждена.

**Огрубление графа (graph coarsening), coarse-to-local.** Замена мелкого графа крупным с сохранением релевантных свойств (спектра, разрезов, потоков). Центральный вопрос — какой сигнал выживает при переходе от мелкого масштаба к крупному; в памяти это консолидация.

**Персистентный лапласиан, TDA.** Топологический анализ данных: как меняются топологические признаки (числа Бетти, спектр лапласиана) при изменении масштаба (фильтрации). Персистентный лапласиан — спектральное обобщение персистентной гомологии.

### Выразительность и обучение

**WL-тест, GIN.** Тест Вейсфейлера–Лемана — предел различающей способности обычной передачи сообщений; GIN (Xu и др.) достигает этого предела инъективной агрегацией. PNA — многостатистическая агрегация (сумма/среднее/макс/дисперсия).

**Передача сообщений (GNN).** Параметрическая функция на графе, обучаемая градиентным спуском: узел обновляется агрегированными сообщениями соседей. Наша память — та же передача сообщений, но с локальными (не обучаемыми градиентом) правилами.

**LoRA.** Дешёвое дообучение: вместо всех весов обучается низкоранговая добавка $\Delta W = BA$ (ранг $r \ll$ размерности), малая по памяти.

**DPO (Direct Preference Optimization).** Дообучение под предпочтения без отдельной модели вознаграждения: оптимизация на тройках (промпт, выбранный ответ, отвергнутый ответ).

### Эмоции и данные

**Теория оценивания (appraisal): OCC, Шерер.** Эмоция как результат оценки события по измерениям: релевантность/новизна (ошибка предсказания), конгруэнтность целям, валентность, интенсивность, атрибуция причины (agency).

**Предиктивная обработка, ошибка предсказания.** Взгляд (Friston и др.), по которому мозг минимизирует ошибку предсказания; величина ошибки — естественная мера значимости события.

**ConceptNet / Numberbatch.** Ассоциативно-таксономический граф здравого смысла (взвешенные типизированные рёбра) и его родной эмбеддинг Numberbatch.

**ATOMIC / ATOMIC10x.** Граф причинно-социального здравого смысла (если субъект делает $Y$, то намерение/реакция/эффект). ATOMIC10x — крупная версия, дистиллированная языковой моделью и отфильтрованная критиком.

**Wikidata.** Фактологическая база с моделью утверждения: квалификаторы (время), references (провенанс), ранг (недеструктивная ревизия). Ценна схемой, не содержанием.

**Generative Agents.** Симуляция агентов с потоком памяти, retrieval по свежести$\times$важности$\times$релевантности и рефлексией (порождением обобщений); прообраз субстрата.

**Распределение Бета, сэмплирование Томпсона.** Сопряжённый апостериор для доли успехов; удобно моделирует «успешность реакции» (успехи $\alpha$, провалы $\beta$) и баланс исследования/эксплуатации.

# C. Сводка алгоритмов

Псевдокод ключевых операторов, собранный в одном месте для удобства. Это скелеты, а не финальные реализации: они фиксируют логику, обсуждённую в главах, но опускают инженерные детали (батчинг мутаций, кэширование $\pi$, индексы эмбеддингов).

## C.1. Единый блуждающий агент (три политики)

```
def walk(G, start_nodes, mode, steps, mood, query=None):
    # mode задаёт политику через параметры: bias перехода, alpha телепорт(),
    # bias_uncertainty. Один движок — три режима глава( про обход).
    if mode == ”retrieval”:   alpha, bu = 0.0, 0.0
    if mode == ”curiosity”:   alpha, bu = 0.05, 1.0     # тянет к need_to_discover
    if mode == ”sleep”:       alpha, bu = 0.30, 0.0     # телепортскраб–

    active = set(start_nodes); visited = Counter()
    for _ in range(steps):
        A = sample(active)
        if random() < alpha:                 # телепорт рестарт()
            B = random_node(G)
        else:
            # P(A → B) ∝ w_AB · rel(B|query) · moodcong(B|mood) · unc(B)^bu
            B = sample_neighbor(G, A, weights=transition_scores(
                    G, A, query, mood, bias_uncertainty=bu))
        visited[B] += 1
        maybe_fire_operations(G, B, mode)    # retrieval / fusion / inspect
        active = frontier(active, B)
    return visited
```

## C.2. Локальное правило и лавинная пропагация

```
def propagate(G, A, sigma_target=0.9):
    # Пропагация нового факта A как затухающей лавины с контролем ветвления.
    frontier = link_initial(G, A)            # A -> N(A), напр. последние top-k
    while frontier:
        next_frontier = []
        # нормировка под целевой ветвящийся коэффициент sigma < 1
        gain = branching_normalizer(frontier, sigma_target)
        for B in frontier:
            d = delta_conf(G, A, B) * gain    # см. ниже: знак, источник, независимость
            G.confidence[B] = clip(G.confidence[B] + d, 0, 1)
            th_e = theta_emergent(G, B)       # растёт с глубиной консолидации
            if abs(d) > th_e:                 # крупная переоценка -> в ширину
                next_frontier += neighbors(G, B)
            elif abs(d) > THETA_TEMP:         # промежуточная зона -> пометить
                mark(G, B, ”need_to_revise”)
            # else: глохнет здесь
```

```
        frontier = next_frontier

def delta_conf(G, A, B):
    sign      = edge_sign(G, A, B)            # supports (+) / contradicts (−)
    strength  = edge_weight(G, A, B)
    gate      = G.confidence[A] * source_trust(G, A)   # карантин нового факта
    indep     = independence_discount(G, A, B)         # антиэхо− по провенансу
    return ETA * sign * strength * gate * indep * G.confidence[A]
```

## С.3. Забывание, прунинг, консолидация

```
def nightly_maintenance(G):
    for v in G.nodes:
        G.strength[v] = act_r_base_level(G.access_log[v])   # частота + свежесть
    for v in low_activation(G):
        if importance(G, v) low and confidence(G, v) low:
            drop(G, v)                                       # редкоеиневажное−−
    for cluster in redundant_episodic_clusters(G):
        merge_to_semantic(G, cluster)   # огрубление: эпизоды −> обобщение
    # эмбриональным узлам − меньшая скорость распада континуум( глубины)
```

## С.4. Телепорт-скраб (анти-энтропия)

```
def scrub(G, budget):
    # Случайная инспекция: гарантия покрытия за счёт эргодичности телепорта.
    for _ in range(budget):
        v = random_node(G)                    # рестарт куда угодно
        for w in local_walk(G, v, depth=k):
            if contradicts_any(G, w):         # столкновение −> ревизия
                demote(G, w); mark(G, justificands(G, w), ”need_to_revise”)
            if flagged(G, w, ”need_to_discover”):
                maybe_fetch_external(G, w)     # любопытствовнешний/ вход
```

## С.5. Настроение и монитор руминации

```
def mood_update(mood_layers, event):
    # Стек текущих интеграторов с разными tau; актуальное = суперпозиция.
    for L in mood_layers:                     # session, day, ..., life
        mood_L = (1 − 1/L.tau) * mood_L + (1/L.tau) * appraise(event)
    mood_now = sum(w_L * mood_L for L in mood_layers)
    if autocorr(history(mood_now)) > RUMINATION_TH:   # залипла валентность
        trigger(one_of=[”reframe”, ”attention_shift”, ”invoke_sleep”])
    return mood_now
```

## С.6. Оценивание, значимость и консолидация реакции

```
def encode_event(G, event, mood_prev, mood_now):
    ap = appraisal(event)                     # surprise, goal_congruence, valence...
    salience = ap.surprise * ap.goal_relevance
    #  дешёвый прокси значимости, почти бесплатный:
    salience_cheap = abs(mood_now − mood_prev)
    consolidate(G, event, weight=salience)    # гейт значимости, НЕ одобрения
```

```
    if ap.surprise high: mark(G, event, ”need_to_discover”)

def update_reaction(G, situation, user, reaction, received_ok):
    e = reaction_edge(G, situation, user, reaction)   # условь по ситуация(, отношение)
    if received_ok: e.beta.alpha += 1
    else:           e.beta.beta  += 1                 # угасание, не второй коммит
    e.confidence = e.beta.alpha / (e.beta.alpha + e.beta.beta)
    if e.confidence > CONSOLIDATE_TH: promote_to_slow_layer(G, e)
```

## С.7. Скорер характера и отбор голоса

```
def phi(text, axes):                          # LLMсудья– по рубрикам осей
    return [judge(text, rubric_a) for rubric_a in axes]   # вектор в R^d

def select_voice_corpus(candidates, target_t, axes):
    scored = [(c, phi(c, axes)) for c in candidates]
    # отборперевзвешивание/, чтобы среднее выборки приблизилось к target_t
    return greedy_match_mean(scored, target_t)   # не усреднять муз, а фильтровать
```

## С.8. Стенд эксперимента

```
def run_experiment(build_graph, plant, operator, metric):
    G = build_graph()          # ярус 1: SBM/BA/WS + подсаженные сценарии
    truth = plant(G)           # ground truth: что должно произойти
    operator(G)                # walker / propagate / scrub / decay ...
    return metric(G, truth)    # precision/recall починки, сходимость, покрытие
```

# Литература

Ссылки сгруппированы по темам. Для классических работ приведены авторы и годы; часть источников — препринты и работы из библиографий рабочих волтов проекта (RIN и RIN–DTI), это отмечено пометкой *[волт]*. Точные выходные данные таких препринтов см. в соответствующих библиографиях волтов.

### Память, ассоциативность, когнитивная архитектура


- J. R. Anderson, L. J. Schooler. Reflections of the environment in memory (рациональный анализ памяти; базовая активация ACT-R), 1991; J. R. Anderson и др., An integrated theory of the mind (ACT-R), 2004.
- A. M. Collins, E. F. Loftus. A spreading-activation theory of semantic processing, 1975.
- J. J. Hopfield. Neural networks and physical systems with emergent collective computational abilities, 1982; D. O. Hebb. The Organization of Behavior, 1949.
- J. S. Park и др. Generative Agents: Interactive Simulacra of Human Behavior, 2023 (поток памяти, retrieval по свежести $\times$ важности $\times$ релевантности, рефлексия).
- HeLa-Mem: Hebbian Learning and Associative Memory for LLM Agents, 2026 *[волт RIN, поз. 53]*.
- Родственные механизмы памяти LLM-агентов: APEX-MEM, TRACE, SYNAPSE, GAAMA, MRMS, Zep/Graphiti, Persistent Sycophancy, LifeSide, LoCoMo *[волт RIN]*.


### Поддержание истинности, ревизия убеждений, эпистемика


- J. Doyle. A Truth Maintenance System, 1979; J. de Kleer. An Assumption-Based TMS, 1986.
- P. Duhem; W. V. O. Quine (тезис недоопределённости теории данными, Дюэм–Куайн).
- L. Ross, C. Lepper и др. (устойчивость убеждений к опровержению, belief perseverance).


### Самоорганизованная критичность и лавины


- P. Bak, C. Tang, K. Wiesenfeld. Self-organized criticality, 1987.
- J. M. Beggs, D. Plenz. Neuronal avalanches in neocortical circuits, 2003.


### Графовые сигналы, случайные блуждания, топология


- D. Spielman. Spectral and Algebraic Graph Theory (конспект).
- A. Ortega и др. Graph Signal Processing (обзор), 2018.

- L. Page, S. Brin и др. The PageRank Citation Ranking, 1999; H. Tong и др. Random Walk with Restart, 2006.
- J. Topping и др. Understanding over-squashing and bottlenecks on graphs via curvature, 2022 *[волт DTI, поз. 148]*.
- M. Black и др. Understanding Oversquashing in GNNs through the Lens of Effective Resistance *[волт DTI, поз. 183]*.
- T. K. Rusch, M. M. Bronstein, S. Mishra. A Survey on Oversmoothing in GNNs, 2023 *[волт DTI, поз. 170]*.
- Persistent Laplacian / persistent spectral для биомолекул (группа Guo-Wei Wei); TopologyNet *[волт DTI, поз. 100, 103, 104, 144 и др.]*.
- C. Bodnar и др. Weisfeiler and Lehman Go Topological / Go Cellular (MPSN, CW Networks), 2021 *[волт DTI, поз. 185, 186]*; Neural Sheaf Diffusion, 2022; cellular sheaf Laplacians *[волт DTI, поз. 184]*.


### Оценивание эмоций (appraisal)


- A. Ortony, G. L. Clore, A. Collins. The Cognitive Structure of Emotions (OCC-модель), 1988.
- K. R. Scherer (компонентная модель оценивания).
- Предиктивная обработка / свободная энергия: K. Friston (ошибка предсказания как сигнал значимости).


### Базы знаний и данные для стенда


- R. Speer, J. Chin, C. Havasi. ConceptNet 5.5, 2017; ConceptNet Numberbatch (эмбеддинги).
- M. Sap и др. ATOMIC: An Atlas of Machine Commonsense, 2019; J. Hwang и др. (Comet-)ATOMIC 2020, 2021; P. West и др. Symbolic Knowledge Distillation (ATOMIC10x), 2022.
- D. Vrandečić, M. Krötzsch. Wikidata: a free collaborative knowledgebase, 2014.


### Выразительность GNN, агрегация, обучение под стиль


- K. Xu и др. How Powerful are Graph Neural Networks? (GIN), 2019 *[волт DTI, поз. 68]*.
- G. Corso и др. Principal Neighbourhood Aggregation, 2020 *[волт DTI, поз. 178]*.
- E. Hu и др. LoRA: Low-Rank Adaptation of Large Language Models, 2021.
- R. Rafailov и др. Direct Preference Optimization, 2023.


### Материалы проекта


- Модульные системные промпты Рин (`prompts/global_core/*`), persona-тесты и логи Stage 0 (`logs/rin_stage0.jsonl`).
- Ринциклопедии проекта (`docs/rincyclopedia_chatgpt`, `docs/rincyclopedia_claude`): архетипика как язык проектирования личности («архетип = вектор признаков, а не label»).
- Волт RIN–DTI: карты чтения и маршруты, включая Route L (топология) и Route H (over-squashing, curvature).