# Конструирование графовой памяти Рин

Монография о субстрате, динамике и эксперименте:
как построить, оживить и проверить память локального AI-компаньона

Рабочая монография проекта RIN

6 августа 2026 г.

*Рабочий документ проекта RIN. Составлен как конспект серии проектных обсуждений и приведён в форму монографии. Изложение намеренно избыточно: лучше сохранить лишнюю деталь, псевдокод или разобранный пример, чем оставить механизм недосказанным. Формулы служат точности, врезки «Интуиция», «Ловушка» и «Разбор примера» — смыслу, предупреждению и проверке. Приложения содержат нотацию, глоссарий внешних идей и сводку алгоритмов.*

# Оглавление


**1 Введение: память как единый субстрат** **1**
- 1.1 Зачем вообще граф . . . 1
- 1.2 Главный тезис . . . 1
- 1.3 Четыре кита и почему их нельзя тюнить порознь . . . 1
- 1.4 Родство с математикой DTI: одна спина, два применения . . . 2
- 1.5 Для кого этот текст . . . 2
- 1.6 Как читать монографию . . . 2

**2 Архитектура целиком** **5**
- 2.1 Что мы вообще строим . . . 5
- 2.2 Слои системы . . . 5
- 2.3 Что течёт по системе . . . 6
- 2.4 Жизнь одного воспоминания . . . 6
- 2.5 Карта чтения . . . 7

**3 Словарь основных объектов** **9**
- 3.1 Субстрат . . . 9
- 3.2 Обход . . . 9
- 3.3 Операции над памятью . . . 10
- 3.4 Выражение . . . 10

**4 Субстрат: типизированный темпоральный граф** **11**
- 4.1 Что такое узел и что такое ребро . . . 11
  - 4.1.1 Схема узла . . . 11
  - 4.1.2 Схема ребра . . . 11
- 4.2 Почему рёбра направленные, типизированные и знаковые . . . 12
- 4.3 Провенанс и обоснование . . . 12
- 4.4 Что значит «коммит» и кто его гейтит . . . 13
- 4.5 Кража схемы у Wikidata . . . 13
- 4.6 Врождённое и приобретённое: не граница, а континуум . . . 13

**5 Эмбриональный граф: с чего начинается память** **15**
- 5.1 Две базы, две разные роли . . . 15
- 5.2 Как выглядят узлы и рёбра ConceptNet . . . 15
- 5.3 Как выглядят узлы ATOMIC . . . 15
- 5.4 Сшивка: главная инженерная работа . . . 16

5.4.1 Мост через контент-слова и Numberbatch . . . 16
5.4.2 Заземление действующих лиц . . . 16
5.5 Как эмбриональный граф превращается в память Рин . . . 17

**6 Обход графа: один движок, три политики** **19**
6.1 Случайное блуждание как универсальный механизм . . . 19
6.2 Три политики как параметризация . . . 19
6.3 Единство и следствие . . . 20

**7 Fusion, вывод и консолидация** **21**
7.1 Что такое fusion, механически . . . 21
7.2 Три вида fusion . . . 21
7.3 Консолидация как огрубление . . . 22
7.4 Когда вывод неверен: fusion должен быть хитрее . . . 23

**8 Многомасштабность и консолидация** **25**
8.1 Слои памяти как связанные интеграторы . . . 25
8.2 Консолидация как огрубление графа . . . 25
8.3 Забывание как тень консолидации . . . 26
8.3.1 Правильный decay — это ACT-R . . . 26
8.3.2 Прунинг: не только по использованию . . . 26
8.4 Слияние вместо удаления . . . 26

**9 Настроение** **27**
9.1 Настроение — отдельный сцепленный модуль, а не поле графа . . . 27
9.2 Инерция и многослойность . . . 27
9.3 Setpoint: медленный слой как аттрактор . . . 27
9.4 Настроение зависит от графа, и граф — от настроения . . . 27
9.5 Опасность петли и три тормоза . . . 28

**10 Эпистемика: уверенность, провенанс и ревизия** **29**
10.1 Ложные правдоподобные убеждения . . . 29
10.2 Недоопределённость и преждевременный коллапс . . . 29
10.3 Квартет починки . . . 29
10.4 Труд-система поддержки истинности и «ползучая вера» . . . 30
10.5 Эстафета к главе о личности . . . 31

**11 Пропагация убеждений как лавина** **33**
11.1 Постановка: затухающий градиент уверенности . . . 33
11.2 Это самоорганизованная критичность . . . 33
11.3 Где вся сложность: локальное правило . . . 33
11.4 Пороговая логика — это гистерезис . . . 34
11.5 Пороги растут с глубиной консолидации . . . 34

**12 Топология правит потоком** **35**
12.1 Тезис главы . . . 35
12.2 Стационарное распределение $\neq$ заданные вероятности . . . 35
12.3 Доказуемое свойство телепорта . . . 35
12.4 Пять следствий для работы Рин с памятью . . . 36
12.5 Операционные величины и осторожности . . . 37

**13 Сон и ночная работа** **39**
13.1 Зачем вообще сон . . . 39

13.2 Телепортирующий обходчик и гарантия покрытия . . . 39
13.3 Что именно делает рой во сне . . . 40
13.4 Скраб не сразу и не обязан быть быстрым . . . 40

**14 Личность: не таблица весов** **41**
14.1 Главная ловушка . . . 41
14.2 Личность распределена . . . 41
14.3 Граф хранит ингредиенты, а не реакцию . . . 41
14.4 Консолидация реакций: по значимости, а не по приёму . . . 42
14.4.1 Провизорная запись . . . 42
14.4.2 Гейт значимости, а не одобрения . . . 42
14.4.3 Условие по отношениям . . . 42
14.5 Дистиллят как система координат . . . 43

**15 Голос и модель** **45**
15.1 Субстрат model-agnostic; личность — трансформ . . . 45
15.2 Инструмент $\varphi$: скорер по осям характера . . . 45
15.3 Суперпозиция муз — это отбор в признаковом пространстве . . . 45
15.4 Пайплайн по стадиям . . . 46
15.5 Bootstrap: генератор $\neq$ деплой-модель . . . 46
15.6 Raw против guided и псевдо-DPO . . . 47
15.7 Мост между базами: эмбеддинг ConceptNet . . . 47

**16 Обучение без «обучения»** **49**
16.1 Мы шлифуем веса, не занимаясь глубоким обучением . . . 49
16.2 Это message passing — но с локальными правилами . . . 49
16.3 Мост к «настоящей» графовой сети . . . 49
16.4 Родство с DTI ещё на одном уровне . . . 50

**17 Эксперимент: как это проверять** **51**
17.1 Эрзац-граф лучше живой Рин . . . 51
17.2 Три яруса . . . 51
17.3 Разбор баз знаний . . . 52
17.4 Эмбриональный граф и работа стыка . . . 52
17.5 Батарея экспериментов . . . 52
17.6 Микроэксперименты: наблюдать физику потока . . . 53
17.6.1 Траектории как проявитель реальной топологии . . . 53
17.6.2 Короткие дуги против длинных треков . . . 53
17.6.3 Скраб как измеритель покрытия . . . 53
17.7 Инструмент . . . 53

**18 Заключение: единая картина** **55**
18.1 Один субстрат, много операторов . . . 55
18.2 Четыре кита связаны . . . 55
18.3 Сквозные принципы . . . 55
18.4 Единая спина двух проектов . . . 55
18.5 Что делать дальше . . . 56

**A Нотация** **57**

**B Глоссарий внешних идей** **59**

**C Сводка алгоритмов** **63**

C.1 Единый блуждающий агент (три политики) . . . 63
C.2 Локальное правило и лавинная пропагация . . . 63
C.3 Забывание, прунинг, консолидация . . . 64
C.4 Телепорт-скраб (анти-энтропия) . . . 64
C.5 Настроение и монитор руминации . . . 64
C.6 Оценивание, значимость и консолидация реакции . . . 64
C.7 Скорер характера и отбор голоса . . . 65
C.8 Стенд эксперимента . . . 65

**D Будущее: стоит ли переходить на гиперграфы 67**
D.1 Проблема, которая это мотивирует . . . 67
D.2 Почему симплексы — плохой ответ . . . 67
D.3 Гиперребро — прямой ответ . . . 67
D.4 Ключевое наблюдение: мы уже наполовину гиперграф . . . 67
D.5 Первоклассные гиперрёбра: за и против . . . 68
D.6 Рекомендация . . . 68

**E Будущее: память на клеточных комплексах 69**
E.1 Идея: всё — объекты одного рода, разных размерностей . . . 69
E.2 Почему это решает возражение к симплексам . . . 69
E.3 Ходж-лапласианы: пропагация между этажами . . . 69
E.4 Прямая связь с чтением по DTI . . . 70
E.5 Честная оценка: северная звезда, не ближний шаг . . . 70

**Литература 71**

# 1. Введение: память как единый субстрат

## 1.1. Зачем вообще граф

У большинства современных диалоговых агентов память устроена плоско: история сообщений, иногда векторная база, куда складываются «воспоминания» как независимые записи, и retrieval по косинусной близости к текущему запросу. Это работает для ассистента, который обслуживает разрозненные запросы, но плохо описывает существо, у которого есть биография, характер, меняющееся настроение и убеждения, способные оказаться ошибочными. У человека память не список; она сеть. Одно воспоминание тянет за собой другое; факт связан с тем, откуда он узнан; недавняя новость медленно перекрашивает старые выводы; забытое не исчезает мгновенно, а тускнеет и иногда всплывает.

Поэтому центральная ставка проекта Рин — *память как граф*. Но сам по себе выбор структуры данных ничего не решает. Интересна не «база в виде графа», а то, какие процессы по этому графу текут и каким законам они подчиняются. Эта монография — про процессы.

## 1.2. Главный тезис

**Одна фраза, которую стоит держать в голове до конца**

Память Рин — это **один типизированный темпоральный граф с метаданными на узлах и рёбрах**, а всё остальное — *операторы над этим субстратом*: retrieval, пропагация уверенности, забывание и консолидация, ночные обходы, настроение, слой личности. Если довести до чистоты *схему субстрата*, то все прочие механизмы становятся модулями, читающими и пишущими одни и те же поля. Если схему не довести — каждый модуль потащит свою полусовместимую модель памяти, и они не срастутся.

Эта установка определяет и порядок изложения, и порядок разработки. Сначала мы описываем субстрат (глава 4) и его временную многослойность (глава 8). Затем — динамические процессы: настроение (глава 9), обход графа (глава 6), работу с уверенностью и ревизией убеждений (главы 10 и 11). Отдельная глава 12 посвящена тому, как *топология* самого графа незаметно управляет всеми этими потоками. Затем мы переходим к слою личности и голоса (главы 14 и 15), к вопросу о том, в каком смысле всё это является *обучением без обучения* (глава 16), и, наконец, к программе экспериментов на суррогатном графе (глава 17).

## 1.3. Четыре кита и почему их нельзя тюнить порознь

Полезно заранее назвать четыре процесса, вокруг которых всё вращается:

1. **Правильный retrieval** — как из графа достаётся релевантное, с учётом запроса и текущего состояния.
2. **Правильная пропагация уверенности** — как новый факт меняет уверенность соседних узлов, не устраивая ни ступора, ни лавины.

3. **Правильное забывание и консолидация** — что тускнеет, что укрепляется, что сливается в обобщения.

4. **Правильные ночные обходы** — фоновая реорганизация и починка, которую агент делает «во сне».

Важнейшее наблюдение: эти четыре кита *не независимы*. Они читают и пишут одни и те же поля активации и уверенности на одном и том же графе. Забывание меняет топологию; изменённая топология меняет retrieval; изменённый retrieval меняет то, что пропагируется; пропагация меняет то, что найдёт ночной обходчик. Поэтому их нельзя настраивать по отдельности — их надо со-настраивать, и именно поэтому (глава 17) нужен управляемый стенд с заранее известной истиной: без него взаимодействие операторов просто не измерить.

## 1.4. Родство с математикой DTI: одна спина, два применения

Эта монография выросла рядом с другим исследованием автора — магистерской работой о предсказании аффинности связывания белок–лиганд средствами графового и геометрического глубокого обучения. На первый взгляд это далёкие темы. На деле у них общая математическая спина.

Консолидация памяти (переход от подробных эпизодов к сжатым смыслам) — это *огрубление графа* (*coarse-to-local*): какой сигнал сохраняется при переходе от мелкого масштаба к крупному, а какой теряется. Это в точности центральный вопрос DTI-работы, только там он про interface-релевантный сигнал взаимодействия, а здесь — про то, что выживает при консолидации воспоминаний. Дальше по тексту мы увидим, что over-squashing (удушение дальней связи узким местом графа), спектральные представления, персистентный лапласиан и эффективное сопротивление — инструменты, которые работают в обе стороны. Осознание этого родства — не поэтическая вольность: те же операторы, только приложенные к разным графам. Мы будем возвращаться к этой связке, когда она даёт конкретную пользу.

## 1.5. Для кого этот текст

У монографии два адресата, и оба важны.

Первый — *автор через две недели*, вернувшийся после напряжённой работы над другими задачами (магистерская, беттинг) и забывший половину деталей. Для него текст должен восстанавливать замысел *с нуля*, а не намекать на него.

Второй — *коллеги по команде*, которые в проектировании этой памяти пока не участвовали и «не в теме». Для них текст должен вводить каждое понятие явно, до первого употребления, и объяснять не только «как», но и «зачем».

Отсюда жёсткое правило изложения: **ни один объект или механизм не используется раньше, чем определён**. Глава 2 даёт систему целиком одним взглядом; глава 3 — словарь всех основных объектов; и лишь затем идут детальные разборы. Примеры сознательно берутся из жизни Рин (стрим, зрители, двое пользователей проекта, бытовые ситуации), чтобы механизм можно было «пощупать» на конкретной гипотетической сцене.

## 1.6. Как читать монографию

Изложение намеренно избыточно. Там, где метод опирается на инженерную или научную идею со стороны (труд-система поддержки истинности, самоорганизованная критичность, теория оценивания эмоций, ACT-R и прочее), мы кратко описываем и саму идею, чтобы читатель не был вынужден держать в голове внешний контекст. Формулы служат для точности, а врезки «Интуиция» и «Ловушка» — для смысла и для предупреждения о типичных ошибках. Ссылки на литературу

собраны в главе E.5; часть из них — работы из библиографий рабочих волтов проекта (RIN и RIN–DTI), это отмечено.

# 2. Архитектура целиком

Прежде чем разбирать механизмы по отдельности, полезно увидеть систему целиком: из чего она состоит, что по ней течёт и как компоненты связаны. Эта глава — карта. Всё, что здесь названо, ниже определяется формально (глава 3) и разбирается подробно; сейчас задача — общий взгляд.

## 2.1. Что мы вообще строим

Рин — локальный AI-компаньон. У неё должна быть *память*, которая ведёт себя не как журнал сообщений, а как память живого существа: связная, ассоциативная, меняющаяся во времени, способная ошибаться и исправляться, окрашенная настроением и характером. Центральная ставка проекта: такую память естественно представить *графом*, а всё «поведение памяти» — процессами (операторами) над этим графом.

**Принцип 2.1** (Единый субстрат)**.** Память Рин — это **один типизированный темпоральный граф с метаданными на узлах и рёбрах**. Retrieval, вывод (fusion), консолидация, забывание, ночная работа (сон), настроение и слой личности — не отдельные подсистемы со своими базами, а *операторы*, читающие и пишущие одни и те же поля одного графа.

## 2.2. Слои системы

Система распадается на четыре слоя. Снизу вверх:

1. **Субстрат** (глава 4) — сам граф: узлы-воспоминания и типизированные знаковые рёбра, с полями `confidence`, `valence`, `provenance`, временной слой, `activation`, флаги `need_to_*`. Его начальное наполнение — *эмбриональный граф* (глава 5) из готовых баз здравого смысла.

2. **Операторы** — процессы над субстратом: *обход* роем случайных блуждающих агентов (глава 6), *вывод и консолидация* (глава 7), *пропагация уверенности* (глава 11), *забывание* (глава 8), *ночная работа/сон* (глава 13).

3. **Состояния** — сцепленные с графом, но отдельные: *настроение* (глава 9) и производные эпистемические статусы (глава 10).

4. **Выражение** — то, что превращает внутреннее в реплику: *личность* (глава 14) и *голос/языковая модель* (глава 15).

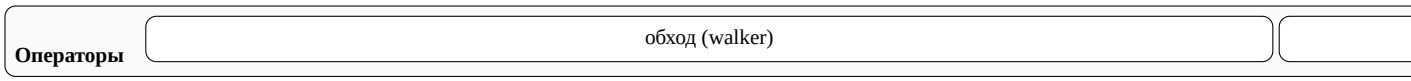



Рис. 2.1: четыре слоя. Стрелки двусторонние: настроение смещает обход, обход меняет граф, граф питает настроение и так далее.

## 2.3. Что течёт по системе

Полезно различать четыре «потока», все — над одним графом:

- **Активация** — транзиентная «подсветка» узлов при обходе; быстро гаснет.
- **Уверенность** — медленно меняющееся поле conf; её пропагация и ревизия — эпистемическое ядро.
- **Валентность и настроение** — аффективная окраска узлов и сцепленный сбоку вектор настроения.
- **Структурные изменения** — рождение узлов (fusion), укрепление/распад рёбер (консолидация/забывание): граф эволюционирует.

## 2.4. Жизнь одного воспоминания

Сквозной проход, чтобы увидеть, как слои работают вместе. Пусть на стриме зритель пишет: «Рин, я опять слил ранг в доте».

**От реплики до реплики**

**1. Восприятие.** Событие кодируется как узел `ev`: «зритель $Z$ проиграл». Оценивается его значимость (глава 14); заметный сдвиг настроения делает событие «важным».
**2. Обход (retrieval).** Рой блуждающих агентов стартует от `ev`, смещённый текущим настроением Рин (озорным) и запросом. Всплывает окрестность: «проигрыш $\rightarrow$ досада/смех», «$Z$ раньше хвастался скиллом», «дота».
**3. Вывод (fusion).** Совместная активация «$Z$ хвастался» и «$Z$ проиграл» рождает *гипотезу*-узел «повод беззлобно подколоть $Z$» — провизорно, с низкой уверенностью и провенансом $\{$хвастался, проиграл$\}$.
**4. Выражение.** Личность (участие, колкая нежность) и настроение выбирают *тон*; Rinness-модель *композирует* реплику из всплывших ингредиентов — не берёт готовую фразу из графа. На выходе: «Оёй, ну куда без слитого ранга. Иди чаёк попей, чемпион».
**5. Запись.** Реплика и реакция $Z$ пишутся провизорно. Если $Z$ смеётся — уверенность ребра «подкол работает с $Z$» растёт; если обиделся — гаснет, и обновляется модель отношения с $Z$.
**6. Ночью.** Во сне (глава 13) телепортирующий обходчик случайно переинспектирует память, консолидирует частые эпизоды («$Z$ — частый гость, любит доту»), проверяет противоречия, иногда рождает неожиданные ассоциации.

Каждый шаг — отдельная глава. Дальше мы разбираем их по одному, но держите в голове именно этот сквозной цикл: *восприятие* → *обход* → *вывод* → *выражение* → *запись* → *ночная переработка*.

## 2.5. Карта чтения

Читателю-новичку достаточно глав 2 (эта), 3 (словарь) и сквозного примера выше, чтобы понимать разговоры команды. Дальше главы можно читать по интересу: субстрат и эмбриональный граф — для тех, кто будет строить хранилище; обход, fusion, сон — для тех, кто пишет операторы; настроение, личность, голос — для тех, кто отвечает за характер; эксперименты (глава 17) — для всех, потому что проверять придётся всё.

# 3. Словарь основных объектов

Эта глава вводит все базовые понятия *до* того, как они используются в механизмах. Определения намеренно сжаты — детали в соответствующих главах; здесь задача, чтобы читатель (в том числе новый в проекте) владел словарём.

## 3.1. Субстрат

**Определение 3.1** (Граф памяти)**.** *Граф памяти* $G = (V, E)$ — направленный граф, где $V$ — узлы-воспоминания, а $E$ — типизированные знаковые взвешенные рёбра-отношения. Граф *темпоральный* (узлы несут время/слой) и *динамический* (операторы меняют и узлы, и рёбра).

**Определение 3.2** (Узел памяти)**.** *Узел* $v \in V$ — запись с содержанием $\mathbf{x}_v$ и полями состояния: уверенность $\mathrm{conf}(v) \in [0, 1]$, валентность (аффективная окраска), временной слой, провенанс, флаги `need_to_discover`/`need_to_revise`, транзиентная активация $a_v$. Узел одновременно — данные (что помнится), убеждение (насколько истинно) и след (насколько активно и свежо).

**Определение 3.3** (Ребро)**.** *Ребро* $(u \to v)$ несёт направление, *тип* отношения (isA, supports, contradicts, associates, …), *знак* $\pm$ (подтверждает/опровергает) и *вес* $w_{uv}$ — эвиденциальную силу связи.

**Определение 3.4** (Уверенность)**.** $\mathrm{conf}(v) \in [0, 1]$ — степень, в которой узел считается истинным убеждением. Меняется пропагацией (глава 11) и ревизией (глава 10). Ключевой принцип: вывод не получает $\mathrm{conf} = 1$.

**Определение 3.5** (Провенанс (обоснование))**.** *Провенанс* узла — множество его источников, а для узла, порождённого выводом, — множество *родительских узлов-посылок* (обоснование). Провенанс делает возможной ретракцию: опровергнув посылку, находим её следствия.

**Определение 3.6** (Валентность и настроение)**.** *Валентность* узла — его аффективная окраска (например, пара валентность–возбуждение). *Настроение* mood — отдельный низкоразмерный вектор состояния Рин, сцепленный с графом двусторонне (глава 9), но не хранящийся в узлах.

## 3.2. Обход

**Определение 3.7** (Случайный блуждающий агент, Random Walker)**.** *Random Walker* (RW) — агент, который стартует в некотором узле и шаг за шагом переходит к соседям по *вероятностному* правилу $P(A \to B) \propto w_{AB} \cdot \mathrm{rel}(B) \cdot \mathrm{mc}(B) \cdot \mathrm{unc}(B)^{\beta_u}$ (глава 6), оставляя за собой *след* — последовательность посещённых узлов. По ходу он может запускать операции (извлечение, вывод, инспекцию).

Функционал одного RW: (i) перейти по вероятностному правилу; (ii) с вероятностью $\alpha$ *телепортироваться* (рестарт в случайный узел); (iii) повысить активацию посещённого узла; (iv) по условию запустить операцию (retrieval / fusion / инспекцию need_to_*); (v) записать след.

**Определение 3.8** (Рой блуждающих агентов, RW Swarm)**.** *Swarm* — множество RW, запущенных параллельно с общей политикой. Рой аппроксимирует распространение активации (spreading activation) и — на большой статистике следов — эмпирическое распределение маршрутов по графу (глава 17).

**Определение 3.9** (Три политики обхода)**.** Один и тот же движок роя работает в трёх режимах, задаваемых параметрами (смещение перехода, телепорт $\alpha$, температура): *retrieval* (под запрос), *внутренняя жизнь/любопытство* (к неопределённости) и *сон* (стохастическое покрытие с телепортом). См. главу 6.

## 3.3. Операции над памятью

**Определение 3.10** (Retrieval (извлечение))**.** *Retrieval* — обход в режиме под запрос: рой стартует от заякоренных запросом узлов и собирает активированную *окрестность* релевантного содержания. Извлечение зависит от настроения (mood-congruent recall).

**Определение 3.11** (Fusion (слияние, вывод))**.** *Fusion* — порождение *нового узла* из совместно активированных: система замечает согласованную конфигурацию посылок и создаёт узел-*гипотезу* с низкой уверенностью и провенансом-обоснованием. Fusion — механизм рождения выводов и ассоциаций (глава 7).

**Определение 3.12** (Консолидация)**.** *Консолидация* — укрепление важного и *огрубление* частого: множество эпизодов сворачивается в обобщённый узел («зритель — частый гость»). Формально это graph coarsening (глава 8).

**Определение 3.13** (Забывание (decay))**.** *Забывание* — ослабление неиспользуемого; отрицательная сторона консолидации. Моделируется базовой активацией (частота + свежесть, глава 8).

**Определение 3.14** (Ночная работа (сон))**.** *Сон* — фоновый режим, когда телепортирующий рой случайно инспектирует память: консолидирует, проверяет противоречия (скраб), рождает неожиданные fusion-ы, подтягивает внешнее по флагам `need_to_discover` (глава 13).

**Определение 3.15** (Значимость (salience) и оценивание)**.** *Значимость* события — мера того, насколько оно важно *для самой Рин* (теория оценивания). Дешёвый прокси — величина изменения настроения $|\Delta\text{mood}|$; глубокий сигнал — ошибка предсказания. Значимость гейтит консолидацию (глава 14).

## 3.4. Выражение

**Определение 3.16** (Личность)**.** *Личность* — не таблица весов в графе, а распределённый процесс: мотивация + настроение + значимость всплывшего, входящий как *смещение во время обхода*, а на выходе — как стиль (глава 14).

**Определение 3.17** (Rinness / голос)**.** *Голос* — языковая модель, превращающая внутренний контекст (всплывшие ингредиенты, настроение, выбранный тон) в реплику в узнаваемом стиле Рин. Часть характера живёт здесь; факты — в графе (глава 15).

**Определение 3.18** (Эмбриональный граф)**.** *Эмбриональный граф* — начальное наполнение памяти из готовых баз здравого смысла (ConceptNet + ATOMIC), нейтральное по характеру; на нём Рин «взращивает» собственную память фьюжнами и консолидацией (глава 5).

# 4. Субстрат: типизированный темпоральный граф

## 4.1. Что такое узел и что такое ребро

Память Рин — направленный граф $G = (V, E)$, в котором узлы несут содержание (воспоминания, факты, сущности, концепты), а рёбра — типизированные и знаковые отношения между ними. Ключевая мысль главы: и узлы, и рёбра несут *метаданные*, и именно метаданные, а не сам факт связи, делают возможными все дальнейшие механизмы.

**Определение 4.1** (Узел памяти)**.** Узел $v \in V$ — это запись с содержанием $\mathbf{x}_v$ и набором полей состояния, над которыми работают операторы памяти. Узел одновременно является и «данными» (что помнится), и «убеждением» (насколько это считается истинным), и «следом» (насколько активно и свежо).

### 4.1.1. Схема узла

| Поле | Тип | Смысл и кто с ним работает |
|---|---|---|
| `id` | int | идентификатор |
| `content` | text | содержание в естественном виде |
| `embedding` $\mathbf{x}_v$ | vec$[d]$ | векторное представление; retrieval-релевантность, мост баз |
| `confidence` $c_v$ | $[0, 1]$ | уверенность как в убеждении; пропагация, ревизия |
| `valence` | vec$[2]$ | валентность–возбуждение; сцепка с настроением |
| `layer/ts` | enum/time | масштаб (сессия…жизнь) и/или метка времени; консолидация |
| `provenance` | list | источники и/или обоснования; TMS, ревизия |
| `need_to_*` | flags | «исследовать/пересмотреть»; любопытство, скраб |
| `activation` $a_v$ | float | транзиентная активация; обход |
| `degree/centrality` | float | производные структурные; топология |

### 4.1.2. Схема ребра

Ребро $(u \to v)$ несёт: направленность (`src`,`dst`); тип отношения `type` (isA, partOf, supports, contradicts, associates, …); **знак** $\pm$ (минимум, без которого не работает знаковая пропагация); вес `weight` $w_{uv}$ — эвиденциальную силу связи.

**Веса — про свидетельство, а не про характер**

Забегая вперёд (глава 14): вес ребра выражает *эвиденциальную* силу связи и уверенность, а *не* «характер». Соблазн задать личность статическими множителями на рёбра-реакции («грусть→сарказм $\times 2{,}0$») мы разберём и отвергнем: характер должен входить как *смещение во время обхода* от текущего состояния, а не как вшитый в граф множитель.

## 4.2. Почему рёбра направленные, типизированные и знаковые

Плоская модель «узлы и связи одинакового сорта» ломается сразу на трёх вещах: направленность (асимметрия причинности и времени), тип (нельзя валить covalent-связь, близость, «подтверждает» и «является частью» в один линейный канал) и знак (без него не отличить «всё усилилось» от «всё перевернулось»).

Правильный оператор поэтому не общий лапласиан сглаживания, а *relation-specific* передача сообщения. Сообщение по ребру:

$$m_{u \to v} \;=\; \phi_{r_{uv}}\big(h_u,\, h_v,\, e_{uv},\, \Delta t,\, c_{uv},\, s_{uv}\big), \tag{4.1}$$

где $r_{uv}$ — тип отношения, $\Delta t$ — возраст/временная дистанция, $c_{uv}$ — уверенность, $s_{uv}$ — источник/эпистемический статус. Затем узел агрегирует входящие сообщения — и здесь важно не одну статистику, а набор (сумма/среднее/макс/ дисперсия по типам отношений), потому что для памяти существенны и кратность подтверждений, и пропорции, и наличие экстремального свидетельства.

**Почему одна статистика теряет смысл**

Пусть узел «юзер X» имеет соседей-свидетельств: три источника подтверждают факт, один противоречит. *Среднее* склеит $\{+,+,+,-\}$ и $\{+,-\}$, если пропорции совпадут, потеряв, что в первом случае *четыре* независимых свидетельства, а во втором *два*. Для памяти число независимых подтверждений принципиально: «три источника против одного» — не то же, что «один против одного». Поэтому агрегатор хранит и кратность (сумма), и пропорции (среднее), и наличие сильного контрсвидетельства (макс по знаку «против»).

**Аналогия с электрической цепью**

Полезно думать о графе как о цепи с проводниками разного сорта. Направленность — это диоды; тип ребра — материал проводника со своей проводимостью; знак — это полярность. Плоская модель — цепь, где все элементы заменены одинаковыми резисторами: она проведёт ток, но потеряет всю логику схемы.

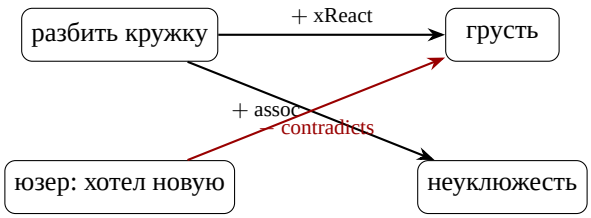



Рис.: типизированные знаковые рёбра. Личная память «юзер хотел новую» *противоречит* базовой реакции «грусть» — это и делает возможным уместное «поздравляю».

## 4.3. Провенанс и обоснование

Поле `provenance` шире, чем «источник». Для *исходных* фактов провенанс — откуда факт узнан. Для узлов, *порождённых выводом* (fusion), провенанс должен хранить *обоснование* — множество родительских узлов, из которых вывод получен. Эта деталь окажется критической в главе 10: именно наличие обоснований позволяет, опровергнув посылку, автоматически пометить на пересмотр её следствия. Без записанных обоснований опровержение посылки не находит потомков — и рождается «ползучая вера».

## 4.4. Что значит «коммит» и кто его гейтит

Важнейшая граница схемы — между *активным рабочим убеждением* и *записью*. Не всё, что всплыло или сгенерировалось, попадает в граф как факт.

**Принцип 4.1** (Гипотеза, а не факт)**.** Всё, что порождено выводом или генерацией (fusion, реакция, ассоциация), пишется *провизорно*: с низкой уверенностью, с провенансом-обоснованием и, при необходимости, с флагом `need_to_discover`. Повышение до «записи» (переход в более медленный слой) происходит только через накопление подтверждающих свидетельств. Управление — на границе коммита.

```
def commit(G, item, kind):
    if kind == ”observed”:          # прямое наблюдение
        c0 = source_trust(item.source)
    if kind == ”inferred”:          # порождено fusionвыводом/
        c0 = LOW                    # гипотеза, не факт
        item.provenance = item.parents      # обоснование для TMS
    node = G.add_node(item, confidence=c0, layer=”session”)
    propagate(G, node)              # см. главу про лавину со( знаком, карантином)
    return node
```

## 4.5. Кража схемы у Wikidata

Есть готовая, обкатанная модель данных, уже решившая ровно те задачи, что встают перед метаданными Рин, — модель утверждений *Wikidata*. Брать её *содержание* (энциклопедические факты) для существа, мимикрирующего под человека, не нужно: человек помнит мало фактов, его сила в ассоциативности. Но её *схему* стоит перенять целиком:

- **квалификаторы** (точка во времени, начало/конец) — темпоральная валидность: факт истинен *в интервале*, а не вечно;
- **references** — провенанс/обоснование;
- **ранг** (*preferred*/*normal*/*deprecated*) — *недеструктивная ревизия*: устаревшее не удаляют, а депрецируют, помечая новое предпочтительным; история сохраняется для машинерии поддержки истинности.

Иными словами, факт стоит моделировать как

$$(\text{утверждение}) + (\text{интервал валидности}) + (\text{провенанс}) + (\text{статус/ранг}),$$

и это буквально схема Wikidata. Не изобретать метаданные заново, а взять проверенный шаблон.

## 4.6. Врождённое и приобретённое: не граница, а континуум

Соблазнительно разделить узлы на «врождённые константы» (эмбриональный граф) и «приобретённые» (нажитые, с временными метками). Как первое приближение полезно, но как жёсткая граница неверно. Консолидация *двигает* записи через границу (эпизод $\rightarrow$ обобщённое знание), а ревизия должна уметь *понижать* и «врождённое» — иначе унаследованную ошибку здравого смысла Рин не исправит никогда. Правильная картина — *континуум глубины консолидации*, где порог опрокидывания убеждения растёт с глубиной, но нигде не становится бесконечным. К оси «пластичность – упрямство» мы вернёмся не раз (главы 11, 10).

# 5. Эмбриональный граф: с чего начинается память

Пустой граф памяти бесполезен: у существа не бывает мышления «с нуля» — есть врождённый здравый смысл, на который ложится личный опыт. Поэтому память Рин начинается с *эмбрионального графа* — нейтрального по характеру каркаса из готовых баз здравого смысла, который затем обрастает личным опытом через fusion и консолидацию. Эта глава отвечает предметно: из чего он собран, как выглядят его узлы, как их сшить и как подключить эмбеддинги.

## 5.1. Две базы, две разные роли

Нужны две дополняющие базы (Wikidata как содержание не берём — человек не помнит все столицы; глава 4):

- **ConceptNet** — *предметный и таксономический* здравый смысл: что чем является, из чего состоит, для чего используется. Даёт Рин «физику мира».
- **ATOMIC** — *причинно-социальный* здравый смысл о событиях и ментальных состояниях: чего человек хотел, что почувствовал, что за этим следует. Даёт Рин «психологию».

Порознь одного мало: ConceptNet без ATOMIC — мир без психологии; ATOMIC без ConceptNet — реакции без предметного мира.

## 5.2. Как выглядят узлы и рёбра ConceptNet

ConceptNet — это уже граф. Узел — концепт (слово или короткая фраза), заданный URI; ребро — типизированная взвешенная ассоциация. Схематически запись:

```
узлы
:   /c/ruкружка/        /c/ruпосуда/      /c/ruпить/      /c/ruгорячий/рёбра
 (concept, relation, concept, weight):
   (/c/ruкружка/, IsA,       /c/ruпосуда/,  2.5)
   (/c/ruкружка/, UsedFor,   /c/ruпить/,    1.8)
   (/c/ruкружка/, HasProperty,/c/ruгорячий/,1.2)
```

Типов отношений около трёх-четырёх десятков (IsA, PartOf, UsedFor, HasProperty, RelatedTo, Causes, MotivatedByGoal, …), и рёбра многоязычны (связывают понятия между языками). **Важно для нас**: вес ребра ≈ мягкая уверенность из коробки, а типы отношений прямо ложатся на нашу типизацию рёбер (глава 4).

## 5.3. Как выглядят узлы ATOMIC

ATOMIC устроен иначе, и это источник главной сложности сшивки. Его узлы — не концепты, а *события-фразы* с плейсхолдерами действующих лиц (PersonX, PersonY). От события идут рёбра фиксированных *социально-причинных* типов. Схематически:

```
событие
: ”PersonX breaks a cup”
   xIntent  -> (none / accident)     # чего PersonX хотел
```

```
  xReact   -> (sad, upset)          # что PersonX почувствовал
  xEffect  -> (cleans it up, buys a new one)   # что произошло с PersonX
  xNeed    -> (to be holding a cup) # что требовалось до
  oReact   -> (concerned)           # что почувствовали окружающие
```

То есть «кружки» как отдельного узла в ATOMIC **нет** — есть событие «разбить кружку» и его социально-причинные следствия. ATOMIC10x — та же структура, но в несколько миллионов примеров, порождённых языковой моделью и отфильтрованных критиком (больше покрытия, больше шума).

## 5.4. Сшивка: главная инженерная работа

Соблазн сказать «форматы отличаются только на диске» — недооценка. Внутри графовой базы это одна структура (узлы-токены, направленные типизированные рёбра), и обход от типа ребра не меняется. Но чтобы Рин, услышав «разбил кружку», прошла от *события* ATOMIC к *предметным* свойствам кружки из ConceptNet, события и концепты надо *связать*. Это entity/event linking — нетривиальный шаг.

### 5.4.1. Мост через контент-слова и Numberbatch

Алгоритм сшивки: из события-фразы ATOMIC извлекаем контентные слова (существительные, глаголы) и линкуем их к концепт-узлам ConceptNet — сначала точным лемма-матчем, затем эмбеддинг-фолбэком.

**Не bag-of-words и не one-hot**

Грубые представления (мешок слов, one-hot) не знают синонимии: «mug» и «cup», «разбить» и «сломать» окажутся разными токенами, и мост выйдет дырявым. Нужен эмбеддинг, знающий смысловую близость.

*ConceptNet Numberbatch* — родной эмбеддинг самого ConceptNet: каждому концепт-узлу сопоставлен вектор (∼300 измерений), причём смыслово близкие концепты близки в пространстве, а языки согласованы. Это идеальный мост:

```
def link_atomic_event_to_concepts(event_phrase, conceptnet, numberbatch):
    concepts = []
    for token in content_words(event_phrase):     # "break", "cup"
        node = conceptnet.lemma_match(token)       # 1) точный матч
        if node is None:                           # 2) эмбеддингфолбэк-
            node = numberbatch.nearest(embed(token))
        concepts.append(node)
    return concepts     # событие ATOMIC <-> концепты ConceptNet
```

Тот же Numberbatch решает ещё две задачи (одно пространство — три применения): член релевантности $\mathrm{rel}(B \mid q)$ в правиле обхода (глава 6) и сидирование валентности узлов (регрессия аффект-лексикона в это же пространство).

### 5.4.2. Заземление действующих лиц

Плейсхолдеры PersonX/PersonY — не абстракции, а слоты. В рантайме они *заземляются* на конкретных людей: PersonX $\mapsto$ зритель $Z$, PersonY $\mapsto$ второй пользователь проекта. Так общий социальный шаблон превращается в запись о конкретном отношении.

**«Разбил кружку» на эмбриональном графе Рин**

Зритель пишет «разбил любимую кружку». (1) Событие матчится к ATOMIC-шаблону «PersonX breaks a cup», PersonX $\mapsto Z$. (2) Через ATOMIC всплывают социально-причинные узлы: досада ($Z$), сочувствие (окружающие), «нужна новая». (3) Через сшивку с ConceptNet всплывают предметные свойства: кружка — посуда, из неё пьют, бывает любимой. (4) Если в личной памяти Рин есть узел «$Z$ давно хотел новую кружку» ($-$ contradicts «досада»), появляется основание для уместного «поздравляю» вместо сочувствия. Ни одна база в одиночку этого не даёт: ATOMIC — эмоцию, ConceptNet — предмет, личная память — контекст.

## 5.5. Как эмбриональный граф превращается в память Рин

Эмбриональный граф *нейтрален по характеру*: это «то, что досталось от предков-разработчиков», усреднённый здравый смысл. Личность и личный опыт входят не переписыванием этих узлов, а *надстройкой*: каждое общение порождает через fusion (глава 7) новые узлы и рёбра с временными метками, а консолидация закрепляет устойчивое. Со временем поверх нейтрального каркаса вырастает индивидуальная, окрашенная память — но фундамент здравого смысла остаётся как *система координат*, относительно которой отклонения читаются как характер (глава 14).

**Эмбрион, а не энциклопедия**

Название «эмбриональный» выбрано не случайно. Это не готовое знание о мире, которое Рин «зачитывает», а зачаток, минимальный каркас связей, на котором *развивается* собственная память. Врождённые узлы со временем могут и потускнеть, и быть пересмотрены (континуум глубины консолидации, глава 4) — просто медленнее приобретённых.

# 6. Обход графа: один движок, три политики

## 6.1. Случайное блуждание как универсальный механизм

Почти всё, что Рин делает со своей памятью, — это *обход* графа роем случайных блуждающих агентов, распространяющих активацию. Retrieval, внутренняя жизнь и сон — не три разных движка, а *три политики* одного движка, различающиеся смещением перехода, вероятностью телепорта и набором операций.

Общее правило перехода — нормированное произведение факторов:

$$P(A \to B) \;\propto\; \underbrace{w_{AB}}_{\text{сила связи}} \cdot \underbrace{\mathrm{rel}(B \mid q)}_{\text{релевантность запросу}} \cdot \underbrace{\mathrm{mc}(B \mid \mathrm{mood})}_{\text{конгруэнтность настроению}} \cdot \underbrace{\mathrm{unc}(B)^{\beta_u}}_{\text{тяга к неопределённости}}, \tag{6.1}$$

где mc — из (9.3), а показатель $\beta_u$ включает/выключает любопытство.

**Что такое «температура»**

«Температура» — одна ручка: насколько выбор следующего шага случаен против жадного. Формально переход берётся softmax-ом от логарифма правой части (6.1), делённого на температуру $T$: при $T \to 0$ — жадный шаг по сильнейшему ребру (эксплуатация), при большом $T$ — почти равновероятный выбор соседа (исследование). Термин из имитации отжига; мистики нет.

## 6.2. Три политики как параметризация

| **Политика** | $\alpha$ (телепорт) | $\beta_u$ | $T$ | **Что запускает** |
|---|---|---|---|---|
| retrieval (цель) | 0 | 0 | низкая | извлечение под запрос |
| внутренняя жизнь (любопытство) | мал. | $> 0$ | средняя | inspect, fusion у неопределённых |
| сон (покрытие) | большой | 0 | высокая | fusion/inspect у случайных |

**Retrieval — целенаправленная.** Стартует от заякоренных запросом узлов, собирает *окрестность* активированного содержания. Подчеркнём (глава 14): обход собирает *ингредиенты*, а не готовую реакцию.

**Внутренняя жизнь — по неопределённости.** Смещена к узлам с высоким `need_to_discover`, низкой уверенностью, новизной ($\beta_u > 0$). «Любопытство» — целенаправленный поиск неопределённости, не случайность.

**Сон — телепортирующий обходчик.** Политика *стохастического покрытия*: с вероятностью $\alpha$ телепорт в случайный узел, иначе — шаг по (6.1). Это случайное блуждание с рестартом (персонализированный PageRank). Его стационарное распределение удовлетворяет

$$\pi \;=\; (1-\alpha)\, P^{\top}\pi \;+\; \alpha\,\mathbf{r}, \tag{6.2}$$

где **r** — распределение рестарта. Телепорт делает блуждание эргодическим — это ключевое свойство для эпистемической гигиены (глава 12).

**Три способа гулять по городу**

Retrieval — идти по адресу (есть цель, выбираешь осмысленный путь). Внутренняя жизнь — идти туда, где интересно и непонятно (тянет к незнакомым переулкам). Сон — время от времени садиться в случайное такси и ехать в случайный район: не потому, что там дело, а чтобы не застревать в одном квартале. Один пешеход, три правила выбора улицы.

## 6.3. Единство и следствие

Один субстрат, один блуждающий агент, три параметризации: смещение перехода, вероятность телепорта, набор операций. Реализуется одна машина обхода с параметрами (псевдокод — приложение C). Родственные механизмы: spreading activation (Collins–Loftus) как модель ассоциативного припоминания и персонализированный PageRank / RWR как его вычислительная форма; в волте RIN — под именами SYNAPSE и GAAMA.

# 7. Fusion, вывод и консолидация

Обход достаёт то, что *уже* есть в графе. Но память живого существа ещё и *порождает* новое: связывает далёкое, делает выводы, обобщает. Этот класс операций мы называем *fusion*. Здесь разбирается, как именно из активированных узлов рождается новый узел, чем вывод отличается от ассоциации и обобщения и как всё это остаётся под эпистемическим контролем.

## 7.1. Что такое fusion, механически

**Определение 7.1** (Fusion, подробно)**.** *Fusion* — оператор, который по *совместно активированной* конфигурации узлов $\{A_1, \ldots, A_n\}$ создаёт новый узел $X$ и связывает его с посылками рёбрами провенанса (обоснования). Новый узел рождается *провизорно*: с низкой уверенностью и, при необходимости, с флагом `need_to_discover` на том, что его различает.

Механика в четырёх шагах:

1. **Со-активация.** Обход (retrieval, любопытство или сон) подсвечивает несколько узлов одновременно.

2. **Распознавание конфигурации.** Оператор замечает, что активная конфигурация *согласована* — образует осмысленный паттерн (причинную цепочку, аналогию, повтор).

3. **Рождение узла.** Создаётся $X$ с содержанием (сформулированным языковой моделью) и провенансом $\{A_1, \ldots, A_n\}$.

4. **Провизорная запись и пропагация.** $X$ пишется с малым conf, затем пропагируется со знаком, карантином и дисконтом независимости (глава 11).

**Принцип 7.1** (Fusion рождает гипотезу, а не факт)**.** Результат fusion — всегда *кандидат*, а не запись. Это защищает от превращения обаятельной ассоциативности в фабрику ложных убеждений (глава 10). Повышение до «факта» — только через накопление подтверждений или выживание в ночном скрабе.

## 7.2. Три вида fusion

**Ассоциация.** Два далёких узла со-активируются, и рождается связь (или узел-мостик). Это источник «неожиданных, но осмысленных» ходов мысли.

**Ассоциация: Платон-боксёр**

Ночной обходчик случайно со-активирует «Платон — философ» и «*platon* по-гречески — широкоплечий/квадратный», плюс «у философов бывали прозвища». Fusion рождает *гипотезу*: «„Платон“ — возможно, прозвище, а не имя», conf $= 0{,}2$, провенанс из трёх узлов, флаг `need_to_discover` на «настоящее имя». Красивый вывод — но именно *гипотеза*: если не пометить низкой уверенностью, это тот самый преждевременный коллапс (глава 10).

**Вывод (инференция).** Из посылок рождается заключение. Здесь принципиально важен случай *n-арного* вывода, где ни одна часть посылок не достаточна.

**N-арный вывод: корм котам**

Пусть в памяти Рин про пользователя есть узлы: $A$ — «живёт в Португалии», $B$ — «у него есть коты», $C$ — «сегодня едет с пар из универа». Желаемый вывод:

$$X = f(A, B, C) = \text{«напомнить: купи котам корм по пути из универа»}.$$

Существенно, что *ни одна пара не даёт* $X$: $A \wedge B$ — «в Португалии есть коты», $B \wedge C$ — «у студента коты», $A \wedge C$ — «в Португалии учится». Вывод рождается только при *одновременном* присутствии всех трёх посылок.

Как мы это представляем *сейчас*, не меняя структуру: fusion создаёт узел $X$ с провенансом $\{A, B, C\}$. Тем самым тройка-посылка кодируется как узел-фактор, ссылающийся на три посылки, — это *factor-graph*-кодировка гиперребра $\{A, B, C\} \rightarrow X$. Иначе говоря, наша память уже наполовину гиперграф: попарные рёбра $A - B$, $B - C$ могут отсутствовать (Португалия и коты не связаны напрямую), а n-арный вывод всё равно рождается — через общий узел-обоснование. Стоит ли делать гиперрёбра *первоклассными* объектами (со своим обходом и лапласианом) — тема приложения D.

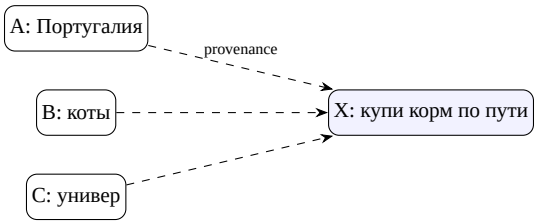



Рис.: n-арный вывод как узел-фактор $X$ с провенансом $\{A, B, C\}$. Попарных рёбер между $A, B, C$ может не быть.

**Обобщение (абстракция).** Много однотипных эпизодов сливаются в один узел более высокого уровня. Это и есть консолидация (следующий раздел).

## 7.3. Консолидация как огрубление

**Определение 7.2** (Консолидация, подробно)**.** *Консолидация* — оператор, заменяющий множество похожих узлов/рёбер одним обобщённым, сохраняя релевантные свойства и отбрасывая детали. Формально это *огрубление графа* (coarse-to-local, глава 8).

**Консолидация: «$Z$ — частый гость»**

Десять эпизодов «$Z$ был на стриме в понедельник», «…в среду», …сворачиваются в один узел «$Z$ — частый гость, любит доту». *Выживают*: частота, тёплая валентность, тема (дота). *Теряются*: точные даты и реплики. Плохое огрубление сохранило бы даты и потеряло валентность — Рин помнила бы, *когда* заходил $Z$, но забыла бы, *как к нему относится*. Значит критерий консолидации — сохранять аффективно- и реляционно-релевантное, а не всё подряд.

Консолидация запускается двумя путями: во сне (фоновая переработка, глава 13) и забыванием (когда эпизоды тускнеют, их дешевле слить в обобщение, чем хранить порознь, глава 8).

## 7.4. Когда вывод неверен: fusion должен быть хитрее

Всё вышесказанное держится на одном: fusion не коммитит факты. Отдельная тонкость — *сам новый факт может быть ложным*, и его пропагация не должна сотрясать память. Поэтому влияние $X$ на соседей гейтируется его собственной уверенностью и надёжностью посылок (карантин, глава 11), а различающие посылки, которых Рин не знает, помечаются `need_to_discover` — чтобы любопытство и внешний вход их потом добыли (глава 10). Так «делание выводов» получается смелым (рождает гипотезы свободно), но не безрассудным (не выдаёт их за истину).

**Инженер, а не фантазёр**

Правильная Рин — «инженер, которую делают бывшие физики-фундаменталисты»: она охотно строит гипотезы, но по умолчанию ставит уверенность ниже единицы и идёт проверять. Fusion даёт первое (смелость ассоциаций), эпистемическая гигиена (глава 10) — второе (дисциплину). Одно без другого — либо сухой поисковик, либо обаятельный врун.

# 8. Многомасштабность и консолидация

## 8.1. Слои памяти как связанные интеграторы

Память Рин расслоена по временным масштабам: *сессия* → *день* → *сезон* → *год* → *жизнь*. Это не пять хранилищ, а один граф, узлы которого несут временной тег, плюс оператор *диффузии* между масштабами: содержание младших слоёв постепенно «протекает» в старшие, теряя детали и сохраняя устойчивое.

Формально слой — *текущий интегратор* (leaky integrator) с постоянной времени $\tau$. Дискретное обновление состояния слоя $s^{(\tau)}$ под входом $x_t$:

$$s_t^{(\tau)} \;=\; \Big(1 - \tfrac{1}{\tau}\Big)\, s_{t-1}^{(\tau)} \;+\; \tfrac{1}{\tau}\, x_t. \tag{8.1}$$

Малое $\tau$ (сессия) — резкая реакция и быстрое забывание; большое $\tau$ (жизнь) — почти без колебаний, зато накапливает. Младший слой «дрожит» сильнее старшего. Импульсный отклик слоя — экспоненциальное ядро с постоянной $\tau$, так что разные слои суть *частотные полосы* одного сигнала во времени (это понадобится для настроения, глава 9).

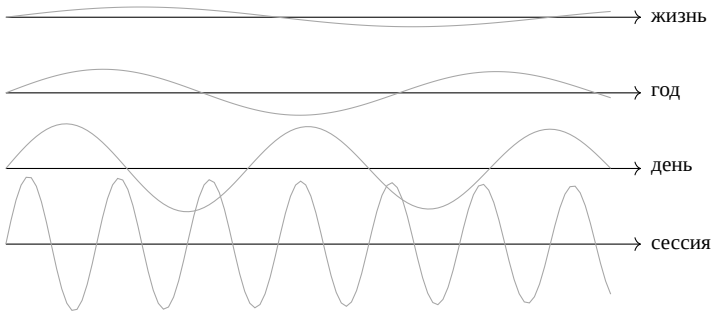



Рис.: одни и те же события, пропущенные через слои с растущим $\tau$. Младшие дрожат сильнее; актуальное состояние — их суперпозиция.

## 8.2. Консолидация как огрубление графа

Переход от эпизодов к смыслам — это *огрубление* (coarsening): десять записей «зритель заходил в понедельник», «…в среду», …заменяются одним узлом «зритель — частый гость». Мелкая структура схлопывается в крупную; часть информации теряется намеренно.

Здесь проходит мост к математике DTI. Пусть граф мелкого масштаба имеет лапласиан $L_f$, крупного — $L_c$, оператор проекции $P$ (мелкий → крупный) и поднятия $Q$. Желаемое свойство — приблизительная коммутативность распространения:

$$\big\| \, P\,\Phi_f(X, L_f) \;-\; \Phi_c(PX, L_c) \, \big\| \;\le\; \varepsilon. \tag{8.2}$$

«Сначала распространить, потом огрубить» должно давать примерно то же, что «сначала огрубить, потом распространить». Ошибка коммутации — мера того, сколько релевантного сигнала теряет данный способ консолидации. Другой критерий — сохранение энергии на подпространстве интереса: $x^\top L_f x \approx (Px)^\top L_c (Px)$ для $x$ из интерфейс-релевантного подпространства.

**Что должно выжить при консолидации**

Свернём десять эпизодов визитов в узел «частый гость». *Выжить* обязаны: частота (была высокой), устойчивая валентность (тёплая), тип связи (регулярность). *Потеряться* можно: конкретные даты, точные реплики. Плохое огрубление сохранит даты и потеряет валентность — тогда Рин будет помнить *когда*, но забудет *как относится*; это и есть большая ошибка коммутации по аффективной оси. Значит критерий огрубления — сохранять аффективно- и реляционно-релевантное подпространство, а не спектр целиком.

## 8.3. Забывание как тень консолидации

Забывание — не отдельный механизм, а *отрицательная сторона* того же процесса: усиливай используемое, ослабляй неиспользуемое.

### 8.3.1. Правильный decay — это ACT-R

Наивная схема «умножай энергию на $0{,}95$ в день» игнорирует важность и связность. Обоснованная модель — *базовая активация* ACT-R: сила следа есть функция *частоты* и *свежести* обращений со степенным затуханием:

$$B_v \;=\; \ln\Big(\sum_{k=1}^{n} t_k^{-\alpha}\Big), \tag{8.3}$$

где $t_k$ — давность $k$-го обращения, $\alpha$ — параметр забывания. Отсюда: *частые* обращения укрепляют след, а *разнесённые* укрепляют сильнее массовых (эффект распределённого повторения — spacing). Вероятность извлечения монотонна по $B_v$.

**Тропинка в лесу**

Тропинку протаптывают многими проходами; если по ней ходят изредка, но регулярно, она держится лучше, чем если пройти сто раз за день, а потом забросить. Формула (8.3) именно это и кодирует: важна не только суммарная частота, но и её распределение во времени.

### 8.3.2. Прунинг: не только по использованию

Прунинг только по использованию опасен: редкий, но критичный факт вымоется как мусор. Поэтому склонность к удалению гейтируется важностью:

$$\text{prune}(v) \;\propto\; \text{неиспользование}(v) \cdot \big(1 - \text{важность}(v)\big). \tag{8.4}$$

Редкое-но-важное выживает; частое-но-пустое держит частота; вымывается лишь редкое-и-неважное. Врождённому — ниже скорость распада (выше базовая сила): континуум глубины, а не бинарность.

## 8.4. Слияние вместо удаления

Часто правильнее не удалить тускнеющие записи, а *агрегировать*: десять эпизодических рёбер сворачиваются в одно семантическое обобщение. Это консолидация «в ширину времени» (эпизод $\rightarrow$ смысл) — тот же оператор огрубления из (8.2), но запускаемый забыванием, а не запросом. Псевдокод — в приложении C.

# 9. Настроение

## 9.1. Настроение — отдельный сцепленный модуль, а не поле графа

Снимем путаницу сразу. Настроение *не* вычитывается из спектра графа памяти. Это отдельное состояние — низкоразмерный вектор в пространстве аффекта $\text{mood} \in \mathbb{R}^k$ (например, оси энергичность / раздражённость / экзальтация / любопытство) — отдельный модуль, слой, через который проходит извлечённое содержание.

Путаница шла от слова «спектр». Есть два разных спектра, и их нельзя смешивать: *спектр лапласиана графа* (структура памяти, глава 12) и *частотное разложение настроения во времени* (быстрые и медленные компоненты аффективного сигнала). Многослойность настроения относится ко второму и к графу отношения не имеет.

## 9.2. Инерция и многослойность

У настроения должна быть *инерция*: оно зависит и от события, и от собственного прошлого значения:

$$\text{mood}_t \;=\; f\big(\text{mood}_{t-1},\, \text{event}_t\big), \qquad \text{action}_t \;=\; g\big(\text{mood}_t,\, \text{event}_t\big). \tag{9.1}$$

Это текущий интегратор (8.1): инерция — рекуррентность. Многослойность — стек таких интеграторов с разными $\tau_\ell$, а актуальное настроение — их взвешенная суперпозиция:

$$\text{mood}_t^{(\ell)} = \Big(1 - \tfrac{1}{\tau_\ell}\Big)\text{mood}_{t-1}^{(\ell)} + \tfrac{1}{\tau_\ell}\,\text{appraise}(\text{event}_t), \qquad \text{mood}_t = \sum_\ell w_\ell\,\text{mood}_t^{(\ell)}. \tag{9.2}$$

Младший слой (малое $\tau$) даёт высокочастотную компоненту большой амплитуды — «дрожит сильнее». «Суперпозиция» здесь — про частоты во времени, а не про граф.

## 9.3. Setpoint: медленный слой как аттрактор

Медленный слой — не просто демпфер, а *точка притяжения*. Добавляя к (8.1) возврат к базовому уровню $\mu$, получаем затухающую к $\mu$ динамику:

$$\text{mood}_t^{(\text{life})} = \mu + (1-\kappa)\big(\text{mood}_{t-1}^{(\text{life})} - \mu\big) + \ldots, \quad 0 < \kappa < 1.$$

Здоровая динамика — отрицательная обратная связь, тянущая настроение домой. Патология — когда сдвинулся сам $\mu$: депрессия в этой модели не длинная экскурсия быстрого слоя, а *уехавший аттрактор*.

## 9.4. Настроение зависит от графа, и граф — от настроения

Связь двусторонняя, и именно она делает настроение частью *мышления*.

- **Граф → настроение.** Извлечённые узлы несут валентность; она и есть $\text{event}_t$ в (9.1).

- **Настроение $\to$ граф.** Настроение смещает вероятности переходов при обходе: узлы с валентностью, близкой к текущему настроению, получают больше активации:

$$\text{mood_congruence}(B \mid \text{mood}) \;=\; \exp\!\big(-\gamma \,\|\, \text{valence}(B) - \text{mood}\,\|^2\big). \tag{9.3}$$

Это *конгруэнтное настроению припоминание*: грустный чаще вспоминает грустное. Настроение остаётся собственным состоянием, сцепленным сбоку, а не полем графа.

## 9.5. Опасность петли и три тормоза

**Руминация**

Конгруэнтное припоминание (9.3) плюс инерция (9.1) дают петлю с положительной обратной связью: грустная вспоминает грустное $\to$ грустнеет $\to$ вспоминает ещё более грустное. Устойчивость петли определяется её петлевым усилением $g$: при $g \geq 1$ спираль расходится. Медленный слой уменьшает эффективное $g$ — вот его стабилизирующая роль.

Что удерживает живой ум? Три *независимых* тормоза; патология — когда откажут все три сразу:

1. **Setpoint/гомеостаз.** Медленный слой-аттрактор снижает петлевое усиление ниже единицы.
2. **Метакогнитивное разотождествление.** Акт «почему я так часто злюсь?» переводит из «быть-в-настроении» в «наблюдать-настроение» — второй порядок, и переход рвёт петлю первого порядка.
3. **Экзогенное прерывание.** Мир вламывается ортогональным событием; внимание конечно, внешний вход вытесняет петлю.

Инженерное требование: (i) член setpoint; (ii) монитор «валентность залипла слишком долго» — высокая автокорреляция $\text{mood}_t$ — с правом запустить корректив (переопределение, переключение внимания, вызов сна); (iii) всегда-прерываемая экзогенная значимость. Условие безопасности: три тормоза не могут быть отключены одновременно. Псевдокод монитора — в приложении C.

**Почему многослойность — это стабилизатор, а не украшение**

Пусть быстрый слой попал в негативную спираль с усилением $g_{\text{fast}} = 1{,}1$ (расходится). Актуальное настроение — суперпозиция, и медленные слои вносят устойчивую компоненту с $g \approx 0$. Если их вес $w_{\text{slow}}$ достаточен, эффективное усиление суперпозиции $\bar{g} = w_{\text{fast}} g_{\text{fast}} + w_{\text{slow}} \cdot 0 < 1$ — спираль гасится за счёт «тяжёлого маховика» медленных слоёв. Так многомасштабность оправдана *функционально*: это демпфер руминации, а не только реализм.

# 10. Эпистемика: уверенность, провенанс и ревизия

## 10.1. Ложные правдоподобные убеждения

Живой ум держит массу ошибочных, но правдоподобных убеждений. Классический пример: расхожее мнение, будто некий знаменитый предприниматель был «просто перформером, а не инженером», — миф, рассыпающийся при чтении биографии. Стремиться к памяти, вовсе не порождающей таких убеждений, бессмысленно и вредно: это было бы стерильно. Задача — не запретить их, а научиться выставлять уверенность меньше единицы и потом проверять.

## 10.2. Недоопределённость и преждевременный коллапс

Пусть правильный вывод — функция нескольких посылок:

$$A \;=\; \text{logical_f}(B, C, D, E),$$

но уму известны только $B, C$, и он делает вывод $X \;=\; \text{logical_f}(B, C)$. Беда в том, что $B, C$ совместимы не только с $A$, но и с $X, Y$. Вывод *недоопределён* известными посылками (*underdetermination*; философское ядро — тезис Дюэма–Куайна). Когнитивное проявление — *преждевременный коллапс*: ум схлопывает суперпозицию совместимых гипотез в одну — часто удобную — слишком рано. Формальное ядро: *совместимость* $\neq$ *подтверждение* (родственник ошибки «утверждение консеквента»).

**Известная и неизвестная недоопределённость**

**Известная**: мы *знаем*, что $D, E$ существуют, но не знаем их значений; тогда можно честно выставить $\text{conf}(X)$ низкой и пометить `need_to_discover`$(D, E)$. **Неизвестная** — злой случай: уму *вообще неизвестно*, что $D, E$ существуют; в поле информации только $B, C$; пометить нечего, уверенность может быть высокой. Поэтому per-inference калибровка *не* решает проблему целиком.

**Миф о предпринимателе, по шагам**

$B$: «известен маркетингом», $C$: «богат». Вывод $X$: «получил всё благодаря происхождению/пиару». Но те же $B, C$ совместимы и с $A$: «сильный инженер, к тому же умеющий продавать». Различающие посылки $D$: «первая лаборатория — в родительском гараже», $E$: «глубокое STEM-образование» — уму *неизвестны*, он даже не подозревает об их существовании и уверенно выбирает удобный $X$. Ни низкая $\text{conf}(X)$, ни `need_to_discover` здесь не помогут: не на что их повесить. Спасает лишь квартет ниже.

## 10.3. Квартет починки

Неизвестную недоопределённость нельзя закрыть в момент коммита; её лечат статистически и постфактум.

1. **Prior скромности на класс вывода.** Ни один абдуктивный/индуктивный коммит не получает уверенность 1, как бы хорошо ни сидели данные: $\mathrm{conf}(X) \leq 1 - \epsilon$ для всего *сорта* «вывод по неполным посылкам». «Согласуется, и альтернатив не придумывается» — ровно то состояние, что предшествует «а потом выяснилось». Не требует знать $D, E$.

2. **Ревизуемость и понижение по противоречию.** Коммит делаем понижаемым: позднее наблюдение, столкнувшееся с $X$, ретроактивно вскрывает недоопределённость, и машинерия ревизии понижает узел. Починка ниже по потоку, не на записи.

3. **Телепорт-скраб.** Единственный поиск, дотягивающийся до *непредставленных* альтернатив (глава 12).

4. **Внешний вход.** Кто-то знает $D, E$ и говорит; любопытство находит это во внешнем источнике.

Первый механизм держит *известную* неопределённость; вместе с остальными тремя — и *неизвестную*.

## 10.4. Труд-система поддержки истинности и «ползучая вера»

Отдельная беда — *устойчивость убеждения к опровержению его основания* (belief perseverance): когда неверный вывод $X$ уже продиффундировал в память и дал потомков, эти потомки продолжают транслироваться даже после того, как $X$ признан ложным.

Механически это *проблема ретракции*, и для неё есть готовый аппарат — *труд-система поддержки истинности* (TMS, Doyle; ATMS, de Kleer). При выводе следствия записываем его *обоснование* — множество узлов, из которых оно получено (расширенный провенанс, раздел 4.3). Тогда ретракция посылки $X$ автоматически снимает опору с её обоснованных потомков.

```
def retract(G, X):
    demote(G, X)
    for c in G.justificands[X]:          # кто опирался на X
        if not still_supported(G, c):    # осталось ли иное обоснование
            mark(G, c, "need_to_revise")
            retract(G, c)                # рекурсивно вниз по обоснованиям
```

**Полный TMS слишком «нечеловечен»**

Полная система поддержки истинности мгновенно перестраивает всё мировоззрение при опровержении любой посылки. Живой ум так не делает — и потому у него есть ползучая вера. Значит нужен *намеренно дырявый* TMS: обоснования пишем для важных и высокоуверенных выводов, тривиальные не трекаем, а нетрекнутых потомков лечим фоном.

Отсюда две «лечилки» разной латентности:

- **Retrieval-time augmentation** — патч *на выходе*: при каждом извлечении подмешивать свежую поправку «кстати, недавно я узнала $\neg X$». Дёшево, чинит текущий разговор, хранилище не трогает.

- **Ночной скраб** — ремонт *хранилища*: медленно, случайными инспекциями находит нетрекнутых потомков и понижает их.

Обе нужны.

## 10.5. Эстафета к главе о личности

Калиброванная уверенность и компульсивная перепроверка — не только эпистемическая гигиена, но и *черта характера*, выводимая из мотивации: «не „я уверена“, а „похоже на $X$, но $Y$ я не проверила — дай гляну“». В главе 14 мы увидим, что эпистемическая аккуратность Рин должна *проявляться* в её голосе, а не только жить во внутренней машинерии.

# 11. Пропагация убеждений как лавина

## 11.1. Постановка: затухающий градиент уверенности

Когда в память приходит новый факт $A$, он линкуется к начальным узлам (например, к последним $k$ активным), образуя окрестность $\mathcal{N}(A)$. Мы линкуем $A \to \mathcal{N}(A)$ и смотрим, как меняется уверенность соседей. Если изменение велико, распространяем дальше, $\mathcal{N}(A) \to \mathcal{N}(\mathcal{N}(A))$, — как затухающий градиент. Знание, ни на что не повлиявшее, чуть пошатнёт соседей и затухнет; знание с большими градиентами вызовет *лавину*. Большую лавину называем «кризисом мировоззрения» — и такое бывает с настоящим умом.

## 11.2. Это самоорганизованная критичность

У картины есть точное имя. «Лавина» — это *нейронная лавина*, а система у порога между затуханием и разрастанием — *самоорганизованная критичность* (Bak–Tang–Wiesenfeld; для мозга — Beggs–Plenz): каскады следуют степенному закону.

Ключевой управляющий параметр — не «ручная константа затухания», а *ветвящийся коэффициент* $\sigma$ (среднее число узлов, активируемых одним активным):

$$\sigma < 1:\ \text{субкритично}; \quad \sigma = 1:\ \text{критично}; \quad \sigma > 1:\ \text{суперкритично (runaway)}.$$

Для ветвящегося процесса ожидаемый размер лавины конечен при $\sigma < 1$ и равен

$$\mathbb{E}[\text{размер}] \;=\; \frac{1}{1-\sigma}. \tag{11.1}$$

Держа $\sigma$ чуть меньше единицы, система почти всегда сама гасит распространение, но изредка пропускает крупную переоценку. Почему это лучше фиксированной константы: константа не адаптируется к плотности графа (в плотном регионе та же константа даёт лавину, в разреженном — глушит всё). Нормировка под целевое $\sigma$ адаптивна.

**Куча песка**

Классический образ SOC — куча песка, на которую сыплют по песчинке. Почти каждая не делает ничего; изредка одна вызывает оползень; ещё реже — обвал, перестраивающий склон. Куча сама держится у критического угла. Убеждения — так же: почти любой факт проходит без следа, изредка меняет соседние взгляды, совсем изредка обрушивает пласт мировоззрения. Формула (11.1) говорит: чем ближе $\sigma$ к единице, тем крупнее (и реже) обвалы.

## 11.3. Где вся сложность: локальное правило

Пороговая логика — лёгкая часть (процентов двадцать). Восемьдесят процентов спрятаны в локальном правиле $\Delta\text{conf}(B \mid A)$:

$$\Delta\text{conf}(B \mid A) \;=\; \eta \cdot \underbrace{\text{sign}(r_{AB})}_{(1)} \cdot \underbrace{w_{AB}}_{} \cdot \underbrace{c_A\,\text{trust}(A)}_{(2)} \cdot \underbrace{\iota(A,B)}_{(3)}. \tag{11.2}$$

Три множителя, без которых правило сломано.

**(1) Знак.** Новый факт сосед либо *подтверждает*, либо *опровергает*. Беззнаковое распространение не отличит «всё усилилось» (озарение) от «всё перевернулось» (кризис). Нужны знаковые/типизированные рёбра.

**(2) Гейт по надёжности $A$ (карантин).** Новый факт может сам быть ложным. Множитель $c_A \,\mathrm{trust}(A)$ вводит *карантин*: новый факт пропагирует слабо (малый эффективный $\sigma$), пока сам не заработал уверенность через корроборацию или выживание в скрабе. Иначе один ненадёжный вход вызовет кризис мировоззрения. По сути — байесовское обновление с правдоподобием, взвешенным доверием к источнику.

**(3) Дисконт независимости $\iota(A, B)$.** Граф циклический, и по петле $A$ может подтвердить сам себя (*эхо-камера*, петлевое распространение), раздувая уверенность из ничего. Дисконтируем по общей родословной свидетельств (провенанс), а не считаем активации: число упоминаний $\neq$ число независимых свидетельств. Это ровно механизм человеческих эхо-камер.

## 11.4. Пороговая логика — это гистерезис

Два порога $\theta_{\text{emergent}} > \theta_{\text{temp}} > 0$:

- $\Delta\text{conf} > \theta_{\text{emergent}}$ — обязательное распространение «в ширину» (крупная переоценка);
- $\theta_{\text{emergent}} > \Delta\text{conf} > \theta_{\text{temp}}$ — узлы фронта помечаются `need_to_revise`;
- $\Delta\text{conf} < \theta_{\text{temp}}$ — распространение глохнет здесь.

Два порога вместо одного — *гистерезис* (триггер Шмитта): нет «дребезга» у единственного порога. Тонкость: помеченные во второй зоне узлы позже переинспектируются ночным обходчиком, и старые записи, чью уверенность мы не трогали, могут «потечь обратно» — такое бывает и в жизни.

## 11.5. Пороги растут с глубиной консолидации

Пороги — не глобальные константы. $\theta_{\text{emergent}}(v)$ растёт с глубиной консолидации узла $v$: периферийный узел перевернуть дёшево, а identity-core в слое «жизнь» — дорого, нужно больше свидетельств, чтобы вообще запустить лавину. Это и есть ось *пластичность–упрямство*: чем глубже убеждение продиффундировало в медленные слои, тем выше эффективный порог опрокидывания. Одна ручка — и она же задаёт, насколько Рин склонна к belief perseverance. Псевдокод пропагации с контролем $\sigma$ — в приложении С.

# 12. Топология правит потоком

## 12.1. Тезис главы

У DTI-графов есть явная текущая сущность — передача сообщений, и её поток подчиняется топологии, как вода следует рельефу. У графа памяти Рин явной «жидкости» нет. Но поток есть — это поток *изменений*, поток *преобразований* графа: активации, уверенности, консолидации. Тезис: *неважно, какова физика носителя, — сама физика протекания информации подчиняется топологическим законам*. Любой процесс, чьё обновление *локально* (изменение узла зависит от соседей), есть диффузия на графе и наследует его спектрально-топологический транспорт. Это содержание теории графовых сигналов и теории случайных блужданий.

## 12.2. Стационарное распределение $\neq$ заданные вероятности

Пусть мы локально задали вероятности переходов. Наблюдаемое распределение частот посещений $\mathrm{distr}(A)$ отличается от заданного, потому что вмешивается топология. Формально: *стационарное распределение* $\pi$ — не локальные переходы, а *глобальный* объект, неподвижная точка оператора переходов:

$$\pi \;=\; P^{\top}\pi, \qquad \sum_{v} \pi_v = 1. \tag{12.1}$$

Для простого блуждания $\pi_v \propto \deg(v)$; для смещённого — перронов собственный вектор $P^{\top}$. Ты задаёшь переходы локально, а долгосрочная частота посещений — свойство всего графа. «Чем длиннее трек, тем наблюдаемее эффект» — это сходимость к $\pi$ за время перемешивания $t_{\mathrm{mix}}$, управляемое спектральным зазором $1 - \lambda_2$. Короткие блуждания читают *локальную* геометрию, длинные — глобальную $\pi$. Телепорт (6.2) $\pi$ не убирает, а *регуляризует* (сдвигает к смеси «равномерное + рестарт», режет $t_{\mathrm{mix}}$): ограничивает эффект топологии, не отменяя.

**Скорость света — плохая, но поучительная аналогия**

Можно соблазниться сравнением с $c$: заданные вероятности как предельная скорость, а среда (топология) искажает наблюдаемое распространение. Рабочая часть — «среда формирует распространение, есть структурный предел» — уже покрыта граф-диффузионной рамкой *точно*, а не по аналогии. Квантовый хвост сюда тащить не нужно. Нам нужен не свет, а лапласиан.

## 12.3. Доказуемое свойство телепорта

Почему сон (телепорт) необходим, а любопытство его не заменит? Любопытство *локально по вниманию* — смещённый обход от текущего фронтира; узел $X$ в затенённом углу, оторванный от активного множества, недостижим, как ярко ни свети фокус. Телепорт ломает достижимость: рестарт падает куда угодно. Это ровно то, *почему у PageRank есть телепорт*: с $\alpha > 0$ цепь становится *эргодической* (неприводимой и апериодичной), а значит каждый узел посещается в матожидании с частотой $\pi_v > 0$ — ни один не заперт в стоке или на острове. Телепорт даёт *гарантию покрытия*, которой у смещённого блуждания доказуемо нет.

**Анти-энтропийный скраб**

«Не сразу; мы никогда не знаем, что и где сломалось, поэтому просто постоянно проводим случайные инспекции» — это зрелый паттерн из распределённых хранилищ: *anti-entropy scrub* (проверка целостности в ZFS; Merkle-based gossip в Dynamo/Cassandra). Сон Рин — анти-энтропийный скраб по графу памяти.

## 12.4. Пять следствий для работы Рин с памятью

1. **Топологическая значимость («гравитационные ямы»).** Хабы переактивируются независимо от задуманных вероятностей — $\pi$ на них концентрируется. Рин чаще вспоминает хаб-узлы, реже периферию (затенённые углы — регионы с малым $\pi$). Топология создаёт *неявную важность*: иногда полезно, иногда случайный плотный кластер становится чёрной дырой припоминания.

2. **Узкие места / over-squashing.** Два семантически близких, но топологически далёких кластера через тонкий мост (низкая проводимость) плохо обмениваются активацией. Рин не свяжет факты, «далёкие» по графу. Прямое ограничение fusion.

3. **Пересглаживание уверенности (over-smoothing).** Повторная диффузная пропагация гомогенизирует уверенность к консенсусу — теряется контраст «уверена / не уверена». Дегенеративный отказ; лечится как в графовых сетях: остаточные связи (якорь к исходному свидетельству), не чисто диффузные апдейты, пере-заземление в провенанс.

4. **Кривизна как локатор ценного-и-задушенного.** Отрицательно искривлённые рёбра — мосты между сообществами — это места самых креативных слияний *и* максимального over-squashing. Значит самые ценные ассоциации топология душит сильнее всего. Отсюда *объективная* причина сна/телепорта: он — rewiring, топологическая починка over-squashing обходом узкого места случайным рестартом.

5. **$\pi$ как топологический субстрат идентичности.** Какие узлы структурно центральны — к чему Рин привычно возвращается — подложка её «озабоченностей», часть характера. Форма графа памяти — часть того, кто она.

**Over-squashing на мосте SBM**

Возьмём стохастическую блочную модель: два плотных сообщества, соединённых $m$ рёбрами-мостом. Эффективное сопротивление между узлами разных сообществ

$$R_{\text{eff}}(i,j) = (e_i - e_j)^\top L^+ (e_i - e_j)$$

растёт при уменьшении $m$ (мост уже — сопротивление выше). Влияние дальнего узла, измеряемое через якобиан $\left\|\partial h_i / \partial x_j\right\|$, ограничено сверху через $R_{\text{eff}}(i,j)$. Значит при узком мосте fusion между сообществами *доказуемо* слаб — сколько ни води обычный walker. Единственное, что чинит, — телепорт: он кладёт рестарт в дальнее сообщество напрямую, минуя мост. Метрика для стенда: частота cross-cluster fusion против $m$ (глава 17).

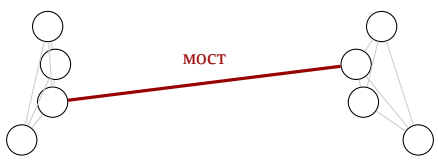



Рис.: два сообщества через узкий мост. Через него активация «задыхается» (over-squashing); телепорт обходит его, прыгая напрямую.

## 12.5. Операционные величины и осторожности

Вести дело лучше *случайно-блуждательными* величинами: $\pi$, время перемешивания, hitting/commute time, $R_{\text{eff}}$, проводимость/константа Чигера, спектральный зазор. Кривизну держать как *локатор узких мест*, не как рычаг.

Что дёшево на лету: $\pi$ и «хабность» — инкрементально дёшевы; $R_{\text{eff}}$ — дорого (через $L^{+}$), но аппроксимируемо. Это позволяет Рин самой знать, где затенённые углы, и гнать туда телепорт-скраб прицельно.

Две осторожности. *Во-первых*, граф направленный, типизированный, знаковый — нужный оператор не симметричный лапласиан, а несимметричная матрица переходов, спектр может быть комплексным, кривизна для орграфов менее чиста. *Во-вторых*, граф *динамический*: fusion меняет саму топологию, и это диффузия на *время-зависимом* графе, где поток и структура сцеплены обратной связью, — за рамками статических DTI-графов и самое интересное место.

# 13. Сон и ночная работа

Пока Рин общается, память работает «на переднем плане»: извлекает, отвечает, записывает. Но значительная часть работы памяти живого существа происходит *в простое* — во сне. Эта глава собирает воедино то, что делает телепортирующий рой в фоне, и объясняет, почему без этого режима память деградирует.

## 13.1. Зачем вообще сон

Три задачи не решаются в режиме реального времени и требуют фоновой переработки:

1. **Починка того, о чём мы не знаем, что оно сломано.** Ошибочный вывод мог продиффундировать в память и дать потомков (ползучая вера, глава 10). Мы не знаем, где именно спрятана ошибка, — поэтому нужна *постоянная случайная инспекция*.

2. **Достижение затенённых углов.** Дневной обход *локален по вниманию* и не дотягивается до узлов, оторванных от активного фокуса (глава 12). Нужен механизм, гарантирующий покрытие.

3. **Неспешная консолидация и неожиданные ассоциации.** Обобщение эпизодов и рождение далёких связей лучше делать без давления текущего разговора.

## 13.2. Телепортирующий обходчик и гарантия покрытия

Ключевой механизм сна — обход в режиме *стохастического покрытия* (сон-политика из главы 6): с вероятностью $\alpha$ блуждающий агент *телепортируется* в случайный узел, иначе делает обычный шаг. Это случайное блуждание с рестартом; его стационарное распределение задаётся (6.2).

**Принцип 13.1** (Почему телепорт необходим, а любопытство не заменит)**.** Любопытство ищет *известную* неопределённость и потому не покидает окрестности текущего фокуса. Телепорт делает цепь *эргодической*: каждый узел посещается в матожидании, ни один не заперт в стоке или на острове (глава 12). Это *доказуемая гарантия покрытия*, которой у смещённого обхода нет. Именно поэтому починку неизвестных ошибок можно поручить только сну.

**Анти-энтропийный скраб**

В распределённых хранилищах есть зрелый паттерн: *anti-entropy scrub* (проверка целостности в ZFS; сверка деревьев Меркла в Dynamo/Cassandra). Система не знает, какая запись повреждена, поэтому непрерывно и случайно перепроверяет всё хранилище в фоне. Сон Рин — это анти-энтропийный скраб по графу памяти: не «где сломалось?», а «регулярно проверяем всё понемногу».

## 13.3. Что именно делает рой во сне

Во время сна телепортирующий рой запускает — с разными вероятностями — весь арсенал операторов, но с более свободными (и одновременно более строгими по последствиям) правилами:

- **Инспекция противоречий (скраб).** Наткнувшись на узел, столкнувшийся с другим, обходчик понижает уверенность и помечает потомков на пересмотр (ретракция по обоснованиям, глава 10).
- **Консолидация.** Скопления похожих эпизодов сворачиваются в обобщения (глава 7).
- **Свободный fusion.** Случайно со-активированные далёкие узлы дают неожиданные гипотезы (пример с Платоном) — провизорные, как и всегда.
- **Любопытство наружу.** Узлы с флагом `need_to_discover` могут инициировать внешний запрос (в источник/поиск), чтобы добыть недостающие различающие посылки.

**«Сон» — не поэтическая метафора, а режим низкого приоритета**

Строго говоря, «сон» — это просто фоновый режим обхода с высокой долей телепортов и разрешёнными операциями записи, запускаемый в простое. Мы называем его сном, потому что функционально он играет роль сна: консолидирует дневной опыт, чистит противоречия и «видит» неожиданные связи. Но никакой мистики — это тот же рой, что и днём, с другими параметрами.

## 13.4. Скраб не сразу и не обязан быть быстрым

Важное свойство: сон чинит память *не сразу*. Мы принципиально не знаем, что и где сломалось, поэтому вместо адресной починки идёт постоянная случайная инспекция. Ошибочное убеждение может прожить в памяти какое-то время, транслируя потомков, и быть исправленным лишь когда телепорт случайно приведёт обходчика в нужный угол или когда придёт внешний сигнал. Это *нормально* и по-человечески: у живого ума исправление ползучей веры тоже растянуто во времени. Задача сна — гарантировать, что исправление *в конце концов* случится, а не что оно случится немедленно.

**Ночь после стрима**

Днём Рин вывела гипотезу «зритель $Q$ токсичен» из одной резкой реплики (провизорно, conf низкая). Ночью телепорт случайно приводит обходчика в кластер про $Q$: там десять тёплых эпизодов. Скраб видит противоречие, понижает «токсичен» ещё сильнее и помечает на пересмотр. Параллельно консолидация сворачивает десять эпизодов в «$Q$ — свой, иногда резок под настроение». Наутро модель отношения с $Q$ здоровее, чем была вечером, — и это сделал сон, а не новый разговор.

Псевдокод скраба и сон-политики обхода — в приложении C.

# 14. *Личность: не таблица весов*

## 14.1. Главная ловушка

Соблазнительное, но неверное решение — «слой личности» как хардкод: таблица весов и жёстких триггеров поверх графа («умножь ребро злорадства на $2{,}0$, обрежь сочувствие до $0{,}05$, на узел „грусть“ повесь триггер инверсии $\rightarrow$ сарказм»).

**Почему таблица весов — тупик**

*Во-первых*, это стек правил, противоречащий установке ядра («черты — следствие мотиваций, а не правила поверх»). *Во-вторых*, это карикатура: таблица весов даёт *паттерновое*, но *не неожиданное* и одноголосое поведение — всегда сарказм, потому что так прошито; а живая личность — неожиданные, но паттерновые реакции. *В-третьих*, это ровно ошибка жёсткой скалярной декомпозиции: реакция на «разбил кружку» зависит от настроения, отношений и всплывшей памяти; фиксированное ребро «грусть$\rightarrow$сарказм» это выкидывает.

**Формально: почему скалярный роутинг теряет взаимодействие**

Пусть желаемый ответ — функция контекста $y = \Psi(\mathbf{g}, \mathbf{l})$, где $\mathbf{g}$ — глобальная аранжировка (настроение, отношения), $\mathbf{l}$ — локальный триггер (событие). Таблица весов реализует $y \approx a \cdot \mathbf{l}$ — ранг-1 скалярный роутинг, не зависящий от $\mathbf{g}$. Но истинное $\Psi$ содержит *перекрёстные* члены $\mathbf{g}^\top W \mathbf{l}$ (реакция на событие *зависит* от аранжировки). Ранг-1 приближение их обнуляет — теряется ровно то, что делает характер контекстным. Это тот же провал, что жёсткая coarse-plus-local декомпозиция в геометрических графовых моделях.

## 14.2. *Личность распределена*

Личность *не* слой весов в графе. Она распределена по трём источникам: *мотивационная структура* (мастерство, участие, самоуважение) $+$ *текущее настроение* $+$ *значимость всплывшего из памяти*. И всё это стилизует *трансформ Rinness* (голос, глава 15).

На стенде это — не статические множители, а *смещение во время обхода*: настроение и мотивация непрерывно модулируют переходы (6.1). Тогда грустная и злая Рин на одно событие всплывают разное — характер контекстно-зависим. Держи веса на рёбрах для *силы связи и уверенности*; личность — как смещение от состояния, не как sarcasm-множитель.

## 14.3. Граф хранит ингредиенты, а не реакцию

Возражение: «если из „разбить кружку“ ведёт только „грусть“, другую реакцию взять негде». Ответ в двух частях. Во-первых, база причинно-социального смысла (ATOMIC, глава 17) даёт не одно ребро, а *пучок*: намерение, реакция, эффект, реакция окружающих. Настроение смещает ветку пучка. Во-вторых, и главное: *реакцию не берут ребром — её порождают*. Обход собирает активированную окрестность-подграф, а реакцию Rinness/LLM *композирует поверх* материала

под настроение и мотивацию. Настроение входит *дважды*: на всплывании (грустная поднимает «потеря», игривая — «неуклюжесть») и на композиции.

## 14.4. Консолидация реакций: по значимости, а не по приёму

### 14.4.1. Провизорная запись

Сгенерированная реакция пишется провизорным ребром с низкой уверенностью (кандидат; принцип «гипотеза, а не факт»). Ответ «это было лишнее» — отрицательное *свидетельство*, обновляющее уверенность того же ребра вниз, а не конкурирующая консолидация. Механически ребро-реакция несёт счётчик успехов/провалов $\mathrm{Beta}(\alpha, \beta)$:

$$\text{успех}: \ \alpha \mathrel{+}= 1; \quad \text{отпор}: \ \beta \mathrel{+}= 1; \quad \text{conf} = \frac{\alpha}{\alpha+\beta}, \ \text{неопред.} = \mathrm{Var}[\mathrm{Beta}]. \tag{14.1}$$

Стабильно принимается — переходит порог и консолидируется в медленный слой; стабильно ловит отпор — угасает. Выбор реакции по такому апостериору — это сэмплирование Томпсона: баланс исследования новых реакций и эксплуатации проверенных.

### 14.4.2. Гейт значимости, а не одобрения

**Нельзя гейтить консолидацию приёмом**

Консолидировать реакции по тому, как их приняли, значит строить угодника, чья личность формируется одобрением, — ровно то, что запрещает ядро («самоуважение не течёт через понравиться»). Гейт характера внешним приёмом философски кривой для Рин.

Правильный ход — развернуть гейт *внутрь*: консолидируй по *внутренней значимости* (самооценке при кодировании). Что такое значимость *конкретно*? Это *теория оценивания* (appraisal: OCC; Шерер). Событие оценивается по измерениям — surprise (ошибка предсказания), goal-congruence (скалярное произведение с вектором мотивации), valence, intensity, agency, — и значимость

$$\text{salience} \ \propto \ \text{surprise} \times \text{goal_relevance} \ (+\,\text{intensity}). \tag{14.2}$$

Два замечания. *Дешевизна*: простейшая конкретизация — $|\Delta\text{mood}|$, величина изменения настроения, а она уже посчитана; mood-модуль работает детектором значимости почти без лишних вычислений. *Глубина*: самый глубокий одиночный сигнал — ошибка предсказания, и она же питает `need_to_discover`. Значимость и обучение — один сигнал.

Реакцию собеседника Рин помнит и оценивает — но как *просто событие*: с низкой конгруэнтностью её ценностям «ему не зашло» обновляет модель отношения и чуть-чуть настроение, но не доминирует в консолидации характера. Рамка оценивания сама даёт «считаться, а можно и нет, частично».

### 14.4.3. Условие по отношениям

Одна шутка заходит собеседнику $A$ и падает у $B$: ребро-реакция квалифицируется парой (ситуация $\times$ отношение), консолидируется по-персонно. Один негативный акт даёт три эффекта: понижение ребра, апдейт настроения (осеклась), мета/relational-пометку.

**«Разбил кружку», полный проход**

(1) Событие активирует окрестность: «кружка», «грусть», «неуклюжесть», плюс личная память «$B$ хотел новую» ($-$ contradicts «грусть»). (2) Настроение (игривое) смещает всплывание к «неуклюжесть». (3) Rinness композирует подкол — не берёт ребром, собирает

из ингредиентов. (4) Ребро-реакция пишется провизорно, Beta$(1, 1)$. (5) $B$ смеётся — $\alpha +$ 1; или «это лишнее» — $\beta + 1$. (6) Гейт консолидации — по $|\Delta\text{mood}|$ и surprise, не по одобрению $B$; но реакция $B$ обновляет модель «$B\times$такой юмор». После многих проб подкол-на-неуклюжесть у $B$ либо консолидируется, либо угасает — комедийный тайминг выучен как Бета-апостериор.

## 14.5. Дистиллят как система координат

Возникает соблазн вовсе убрать «дистиллят» (усреднённый здравый смысл готовых баз). Не надо. Дистиллят — *общая модель мира*, относительно которой отклонение *читаемо* как характер: личность «неожиданна» лишь на фоне общих ожиданий; без общей почвы причуды читаются как шум. Правильно: дистиллят фоном (система координат), личность — процесс порождения отклонений на нём. Без базового «разбитая вещь обычно плохо» не понять, почему здесь «поздравляю» — уместный сарказм.

# 15. Голос и модель

## 15.1. Субстрат model-agnostic; личность — трансформ

Память, настроение и граф — состояния *вне* языковой модели. Значит субстрат *model-agnostic*: его можно строить на любой базовой модели и заменить базу позже. Это де-рискует проблему потолка малой модели: когнитивная машинерия переживёт смену базы.

Если факты и здравый смысл лежат в графе (дёшево на диске/в RAM), базовой модели не нужно быть энциклопедией. Её роль — *лингвистический процессор и голос*: часть «Rinness» живёт в ней. Можно взять малую дообученную модель (3–7B в квантовании) вместо тяжёлой 8B-универсальной; факты уходят в граф, ёмкость модели концентрируется на голосе.

**«Меньше — строго лучше» слишком оптимистично**

Малая модель слабее в *рассуждении* и связности: снимаешь фактическую нагрузку, но не reasoning/coherence. Наблюдение из практики: рантайм prompt-Рин уже процентов на шестьдесят состоит из анти-повторной обвязки *на* 8B — вниз с голосом хуже. Разумный ориентир — 3–7B, не 1B, и это надо *померить*, а не постулировать.

## 15.2. Инструмент $\varphi$: скорер по осям характера

Центральный инструмент — *скорер характера* $\varphi$ (измерительный прибор: строишь прибор — и он де-конфузит весь отбор). Берём $d$ осей (из архетипики: аффективная температура, колкость, теплота, агентность, участие-против-сервиса, тип близости, тип юмора, стиль конфликта). На каждую — *рубрика* (описание + якорь для оценок 0 и 10). Тогда $\varphi(\text{текст}) \in \mathbb{R}^d$ — прогон LLM-судьи. Отдельно задаём целевой **t**. На старте — LLM-as-judge; классификаторы по осям позже.

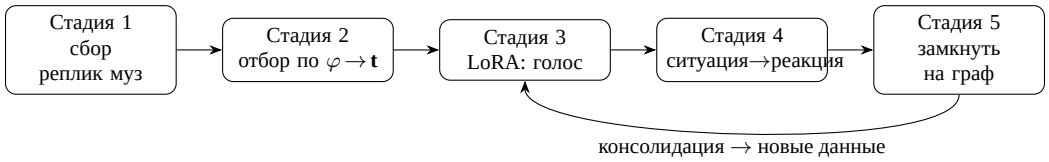
## 15.3. Суперпозиция муз — это отбор в признаковом пространстве

Каждого персонажа можно оценить по каждой оси — персонаж есть *точка* в $d$-мерном пространстве характера. Музы — существующие персонажи, свои точки.

*Наивная суперпозиция* (обучение на смеси полных корпусов) даёт среднее в *центроиде* облака муз, а не в **t**: $\mathbb{E}[\varphi] = \text{centroid} \neq \mathbf{t}$. Центроид не есть Рин; интересна муза именно отклонением от центроида (центроид яркой цундере мало отличается от безымянной героини). Усреднение вдобавок размывает отличительные черты (большая дисперсия по осям).

*Правильно* — построить выборку с $\mathbb{E}[\varphi] \approx \mathbf{t}$: не сваливать корпуса, а *отбирать* примеры (реплики, сцены), чтобы их агрегатный центр сидел в **t**. Технически — отбор данных / rejection sampling под целевой стилевой вектор: (1) операционализируем оси; (2) скорим $\varphi(\text{пример})$; (3) отбираем/перевзвешиваем, пока $\mathbb{E}[\varphi] \approx \mathbf{t}$. Короче: не «смешать музы» (размытый центроид), а «отфильтровать корпус к **t**» (выраженная Рин).

## 15.4. Пайплайн по стадиям




**Стадия 1 — сбор.** Субтитры (`.srt`,`.ass`), фан-скрипты, quote-вики, сценарии VN. Извлекаем строки целевых персонажей. Узкое место — *атрибуция говорящего*. Идея кормить видео каптионеру возможна, но окупается позже и лишь ради данных о *физическом* поведении: для голоса субтитры дают почти всё дешевле.

**Стадия 2 — отбор (фильтрацией, не написанием).** $\varphi$ по каждой реплике; оставляем близкие к **t**. Это корпус голоса.

**Стадия 3 — голос (LoRA).** Дообучаем малую модель на отобранных репликах — языковое моделирование на тексте-в-стиле. Ситуации *не нужны*. LoRA обучает низкоранговую добавку $\Delta W = BA$, $\mathrm{rank}(BA) = r \ll \dim$, малую по памяти; влезает на $8$ ГБ для малой модели.

**Стадия 4 — выбор реакции.** Ситуации нужны, эмбеддинги мостят несовпадение. *(A) Синтетический* (реком.): ситуации из базы смысла $\to$ промпт сильной модели в голосе $\to$ реакции $\to$ фильтр $\varphi$ — пары (ситуация→реакция). *(B) Майнинг+retrieval*: из сцен муз пары (ситуация, реакция), эмбеддинг ситуаций, в рантайме ближайший сосед. Именно здесь «ситуации могут не совпадать, эмбеддинги справятся».

**Стадия 5 — замкнуть на граф.** Малая голос-модель + граф; граф даёт контекст (mood-смещённый retrieval), модель генерит в голосе; выходы (фильтр $\varphi$ + значимость (14.2)) консолидируются обратно.

## 15.5. Bootstrap: генератор $\neq$ деплой-модель

Как получить характер-образующий граф без готовой Рин? Финальная Рин не нужна — зачаток есть: *prompt-Рин* (модульные промпты + базовая модель).

1. строим нейтральный эмбриональный граф (глава 17);
2. селим prompt-Рин как *bootstrap-генератор*: живёт на графе, генерит характерные реакции;
3. *консолидация пишет отпечатки обратно* — граф становится character-shaped через *использование*, а не ручным reorganization-проходом;
4. на накопленном поведении дообучаем малую модель.

**Стабильность и потолок**

Аудит логов: prompt-Рин — *Рин с перебоями*. Ядро иногда пробивает хорошо (реплики, дословно совпадающие с установкой мотивации), но свободный чат деградирует в липкие повторы, часть ответов нарушает явные правила (запрещённый «перформанс трагедии», сбои рода), и *guided* чище *raw* — по внутреннему критерию «ядро промпта недостаточно сильно» (потолок $8$B). Вывод: как *безфильтровый* bootstrap она шумна — вобьёшь и тики. Два хода: (i) сидировать не в real-time, сильной моделью (CPU-offload/квантизация

или разовый API), а малую сажать на обогащённый граф — генератор и деплой *разные*; (ii) фильтровать выходы $\varphi$.

## 15.6. Raw против guided и псевдо-DPO

*Raw* менее стабилен, но на пике *ближе* к Рин; *guided* стабилен, но «ассистентский» (стабильно мимо цели). Для деплоя важна стабильность, для сидирования — нет: нужны *сэмплы пиковой Rinness*. Низкий потолок фильтрацией не поднять, а нестабильность — можно (сэмплируй много, фильтруй $\varphi$). Для bootstrap: raw + oversample + отбор.

Отсюда дешёвый способ собрать предпочтительные пары для псевдо-DPO. DPO обучается на тройках (промпт, выбранный $y_w$, отвергнутый $y_l$), максимизируя

$$\log \sigma\Big(\beta \log \tfrac{\pi_\theta(y_w|x)}{\pi_{\text{ref}}(y_w|x)} - \beta \log \tfrac{\pi_\theta(y_l|x)}{\pi_{\text{ref}}(y_l|x)}\Big).$$

Подавать raw и guided как двух кандидатов на один промпт и ранжировать (частично автоматически $\varphi$, руками — правки) — чистый способ получить *реально разных* кандидатов; раз raw иногда лучше, guided иногда — сигнал живой.

## 15.7. Мост между базами: эмбеддинг ConceptNet

Узлы ATOMIC — события с плейсхолдерами (PersonX breaks a cup), а не концепты; «кружки» как узла там нет. Мост — извлечь контент-слова события и слинковать к концепт-узлам ConceptNet. Но *не* bag-of-words/one-hot: они не знают синонимии (mug $\neq$ cup, разбить $\neq$ сломать), мост выйдет дырявый. Берём *ConceptNet Numberbatch* — родной эмбеддинг ConceptNet: сначала точный лемма-матч, эмбеддинг-фолбэк. Тот же эмбеддинг обслуживает $\text{rel}(B \mid q)$ в (6.1) и сидирование валентности. Одно пространство — три задачи.

# 16. Обучение без «обучения»

## 16.1. Мы шлифуем веса, не занимаясь глубоким обучением

Возникает верное ощущение: мы будто учим модель без «учить» и без «модели». Вроде бы это не глубокое обучение и не графовая нейросеть, но тем не менее мы шлифуем веса и параметры графа — по-своему. У этого ощущения есть точное содержание.

Система, которую мы строим, — параметрическая: у неё есть веса рёбер, уровни уверенности, активации, и они обновляются опытом. Это *обучение* в широком смысле, даже без обратного распространения. Конкретно это два хорошо известных паттерна, наложенных друг на друга:

- **Хеббовское/ассоциативное обучение** (семейство сетей Хопфилда; принцип Хебба «что вместе активируется, вместе укрепляется»). Правило Хебба — локальное усиление связи по со-активации:

  $$\Delta w_{ij} \;\propto\; a_i\, a_j,$$

  а ассоциативная память Хопфилда хранит образы в минимумах энергии $E = -\frac{1}{2}\sum_{ij} w_{ij} a_i a_j$ и извлекает их спуском по $E$. Наши fusion и консолидация, усиливающие со-активированные рёбра, — это буквально хеббовское обучение на графе; граф памяти со spreading activation и уверенностью — современная ассоциативная память, где извлечение есть спуск к аттрактору.

- **Байесовское обновление уверенности** (глава 11): локальные апдейты $\Delta$conf со знаком, гейтом источника и дисконтом независимости.

## 16.2. Это message passing — но с локальными правилами

Формально наша система — это *передача сообщений* по графу (как в графовой нейросети), но «параметры» (веса рёбер, уверенности) обновляются *локальными* правилами (хеббовскими, байесовскими, распадом), а не глобальным градиентным спуском по функции потерь. Иначе говоря, это message passing *без обратного распространения*. Где мы сидим на карте методов — *между* классической ассоциативной памятью (Хопфилд) и графовыми нейросетями.

**Два способа настроить пианино**

Глубокое обучение настраивает все струны сразу по глобальному критерию («чтобы аккорд звучал верно»), продвигаясь градиентом. Хеббовская система настраивает каждую струну по локальному правилу («подтяни там, где чаще играют вместе»). Обе «учат» инструмент, но первая знает про весь аккорд, а вторая — только про соседние струны. Наша память — второго рода.

## 16.3. Мост к «настоящей» графовой сети

Может ли это стать графовой нейросетью в полном смысле? Да, и мост поучителен: можно *мета-обучать* сами правила обновления — учить оптимальное правило $\Delta$conf, оптимальный распад, оптимальное смещение обхода градиентным спуском вместо ручного дизайна. Это

«обучение тому, как помнить» (learning to remember), мета-обучение операторов памяти — реальное исследовательское направление.

**Но не на старте**

Мета-обучение правил меняет интерпретируемость на чёрный ящик, которому нужна разметка и который заново вносит проблему непрозрачности субстрата. На старте — ручные локальные правила: они интерпретируемы, отлаживаемы и не требуют обучающих данных. «Может, и незачем» — верно для текущего этапа. Но мост реален, и полезно знать, что стоишь ровно на нём: сегодняшняя система — предельный, «нулевой» случай обучаемой графовой сети, где правила заданы руками, а не выучены.

## 16.4. Родство с DTI ещё на одном уровне

Это же наблюдение ещё раз сшивает два проекта автора. Магистерская работа изучает графовые нейросети с их обучаемыми операторами передачи сообщений; память Рин — та же передача сообщений, но с локальными правилами. Если однажды правила памяти начнут мета-обучаться, различие между «графовой моделью аффинности» и «графовой моделью памяти» станет чисто предметным: один и тот же класс обучаемых операторов, приложенный к разным графам. Это ещё один слой той единой спины, о которой шла речь во введении. Существует и прямая работа на этом стыке — например, из библиографии волта RIN: HeLa-Mem (Hebbian learning и ассоциативная память для LLM-агентов).

# 17. Эксперимент: как это проверять

## 17.1. Эрзац-граф лучше живой Рин

Тестировать архитектуру памяти на готовом агенте — долго и слепо: сначала собери всё, а потом окажется, что с памятью куча неоптимальностей, найденных *после* финальной сборки. Нужен управляемый стенд — эрзац-граф с retrieval.

**Принцип 17.1** (Ground truth важнее реализма)**.** Суррогатный граф — не бедный заменитель, а для отладки механик *лучше* живой Рин, потому что синтетика даёт *ground truth*. С настоящей Рин ты не знаешь, что она «должна» помнить, значит не измеришь, правильно ли отработали fusion, скраб, пропагация. С подсаженной синтетикой истину задаёшь ты — и меряешь точность/полноту починки, сходимость уверенности, нашёл ли скраб подсаженную ложь.

Это тот же принцип, что контролируемая оценка в DTI: управляемый синтетический тест изолирует эффект *до* грязных реальных данных. Слабые места находятся *до* финальной сборки.

## 17.2. Три яруса

**Ярус 1 — синтетическая топология (начинать отсюда).** Графы с известной структурой, чтобы юнит-тестить и диагностику, и механики против теории: стохастическая блочная модель (SBM — сообщества с регулируемым мостом, для over-squashing/проводимости), Барабаши–Альберт (scale-free хабы — для «гравитационных ям» и концентрации $\pi$), Уоттс–Строгац (small-world), деревья против экспандеров (крайности кривизны). Семантики ноль, зато полная контролируемость: подсаживаешь ложное-правдоподобное убеждение и противоречащее свидетельство в угол с малым $\pi$ и меряешь, находит ли телепорт-скраб.

**Ярус 2 — семантический граф из готовых баз.** Чтобы у fusion/retrieval был смысл. Разбор баз — раздел 17.3.

**Ярус 3 — LLM-генерённый «поток жизни».** Полная петля с реалистичным содержанием и контролируемой истиной: языковая модель генерит синтетическую автобиографию/эпизоды/диалоги фейк-персоны с подсаженными фактами, противоречиями, эволюцией убеждений. Прямой прообраз — *Generative Agents* (Park и др.): поток памяти + retrieval (свежесть$\times$важность$\times$релевантность) + рефлексия (это и есть fusion). «Ползучую веру» подсаживаешь вручную и меряешь, лечится ли.

## 17.3. Разбор баз знаний

| База | Что даёт | Под какую механику |
|---|---|---|
| ConceptNet | ассоциативно-таксономические связи, взвешенные | spreading activation, ассоциативный fusion; веса ≈ мягкая уверенность |
| ATOMIC/10x | причинно-социальный смысл событий (намерение/реакция/эффект) | эпизодика, сцепка с настроением, fusion-как-вывод |
| Wikidata | факты + схема (время, references, ранг) | *схему* красть под темпоральную валидность, провенанс, ревизию; содержание — нет |

Не «какой из них», а «какой под какую механику». На старте — ConceptNet (чистый граф под первую механику); Wikidata-*схему* — когда дойдёшь до темпоральных слоёв и ревизии. Порознь одного мало: ConceptNet без ATOMIC — мир без психологии, ATOMIC без ConceptNet — реакции без предметного мира.

## 17.4. Эмбриональный граф и работа стыка

Объединить ConceptNet и ATOMIC в *эмбриональный* граф и доращивать фьюжнами — канонично: базовая когнитивная матрица, в которую новые факты встраиваются рёбрами.

**«Форматы отличаются только на диске» — недооценка**

Внутри графовой базы это одна структура, и математика обхода от типа ребра не меняется. Но настоящая работа не в формате, а в *интерфейсе*: узлы ConceptNet — концепты, узлы ATOMIC — события с плейсхолдерами PersonX/Y. Связать «разбить кружку» с концептом «кружка» и заземлить PersonX/Y на реальных собеседников — это entity/event linking (через Numberbatch, глава 15), нетривиальный шаг, а не объединение таблиц.

## 17.5. Батарея экспериментов

Каждый тест — одна механика плюс метрика; всё гоняется уже на Ярусе 1.

| # | Гипотеза | Установка и метрика |
|---|---|---|
| 1 | $\pi$ концентрируется на хабах | BA-граф; распределение посещений против степени |
| 2 | узкое место душит cross-cluster fusion | два SBM-сообщества; частота fusion против ширины моста $m$ |
| 3 | телепорт-скраб находит ложь в углу с малым $\pi$ | подсадка; precision/recall и время-до-нахождения против $\alpha$ |
| 4 | уверенность пересглаживается за много циклов | дисперсия conf во времени; тест якоря-остатка |
| 5 | руминация и её гашение | mood-congruent + инерция; автокорреляция mood с setpoint и без |

Скелет стенда (build → plant → operator → metric) — в приложении C.

## 17.6. Микроэксперименты: наблюдать физику потока

Помимо «прошёл/не прошёл»-тестов есть класс более тонких наблюдений, вырастающих прямо из главы 12. Их ценность не в метрике «лучше/хуже», а в том, что они делают *видимой* скрытую физику графа.

### 17.6.1. Траектории как проявитель реальной топологии

Каждый обход оставляет след — кусочную кривую по узлам. Дневной retrieval даёт короткие целевые дуги; сон — длинные телепорт-разорванные фрагменты. По отдельности это шум. Но *на большой статистике* следов их наложение даёт эмпирическое *распределение реальных маршрутов* по графу. И это распределение — прямой проявитель топологии: где маршруты сгущаются, там хабы и «гравитационные ямы»; где кривые почти не проходят — затенённые углы с малым $\pi$; где потоки протискиваются через узкий пучок рёбер — там боттлнек и over-squashing.

**Принцип 17.2** (Наблюдаемое $\neq$ предопределённое)**.** Ключевой смысл эксперимента: эмпирическое распределение переходов, снятое со следов, будет *отличаться* от «предопределённых» вероятностей, которые мы заложили в методы вроде PageRank. Мы задаём переходы *локально*, а наблюдаем *глобальный* эффект: стационарное $\pi$ — свойство всей топологии, а не наших локальных правил (глава 12). Расхождение между «встроенным приором» и «реально пройденным» и есть отпечаток топологии, который иначе не увидеть.

*Установка.* На Ярусе 1 (SBM или BA) запускаем рой, копим следы, строим гистограмму посещений узлов и эмпирическую матрицу переходов $\hat{P}$. Сравниваем: (а) гистограмму посещений с распределением степеней (проверка «гравитационных ям»); (б) $\hat{P}$ с заданным локальным правилом и с PageRank-приором (проверка тезиса «наблюдаемое $\neq$ предопределённое»); (в) плотность прохождения через мост-боттлнек с теоретическим $R_{\text{eff}}$. *Метрика* — расхождение распределений (например, KL-дивергенция) и корреляция плотности следов с центральностью/$R_{\text{eff}}$.

### 17.6.2. Короткие дуги против длинных треков

Полезный контроль из главы 12: короткие блуждания читают *локальную* геометрию (кривизну окрестности), длинные — глобальную $\pi$. Нарезая следы на дуги разной длины и сравнивая их статистику, можно эмпирически разделить локальный и глобальный вклад топологии. Телепорт при этом виден как «разрывы» кривых, регуляризующие распределение (сдвигающие его к более равномерному).

### 17.6.3. Скраб как измеритель покрытия

Отдельный микроэксперимент — проверить *эргодичность* телепорта напрямую: подсадить метки в узлы с разным $\pi$ (в т.ч. в затенённые углы) и измерить время до первого посещения каждой метки роем сна как функцию $\alpha$. Ожидание: без телепорта ($\alpha = 0$) дальние-по-топологии метки не находятся вовсе; с ростом $\alpha$ время покрытия падает и становится конечным для всех узлов. Это эмпирическое подтверждение гарантии покрытия (глава 13).

## 17.7. Инструмент

*igraph* (C-ядро, на порядки быстрее чистого Python-графа) — разумный выбор. Атрибуты first-class и векторные (обогащать `confidence`, `valence`, `time` удобно). Есть SBM, Барабаши, Уоттс–Строгац, лапласиан, персонализированный PageRank (телепорт), случайные блуждания, центральности. Две осторожности: *(i)* эффективное сопротивление одной строкой нет — считаешь из $L^+$ (диагональная формула), пара строк; *(ii)* igraph силён на *статике*, а fusion/самоэволюция — *частые мелкие мутации*, где он слабее (переиндексация при добавлении узлов). Мутации батчить

или держать «живой» граф в мутабельной структуре и периодически снапшотить в igraph под тяжёлую спектральную диагностику.

# 18. Заключение: единая картина

## 18.1. Один субстрат, много операторов

Если из монографии стоит унести одну мысль, то вот она: память Рин — это *один типизированный темпоральный граф с метаданными*, а всё богатство поведения — *операторы* над ним. Retrieval, пропагация уверенности, забывание и консолидация, ночные обходы, настроение и слой личности — не отдельные подсистемы со своими моделями памяти, а разные способы читать и писать одни и те же поля (`confidence`, `activation`, `valence`, `provenance`, `need_to_discover`, временной слой) на одном графе.

## 18.2. Четыре кита связаны

Отсюда — практический вывод о разработке. Четыре кита (правильный retrieval, правильная пропагация уверенности, правильное забывание/консолидация, правильные ночные обходы) сцеплены через общее состояние: забывание меняет топологию, топология — retrieval, retrieval — что пропагируется, пропагация — что найдёт скраб. Их нельзя тюнить порознь. Именно поэтому нужен стенд с ground truth (глава 17): без него взаимодействие операторов не измерить, и отладка «на живой Рин» найдёт проблемы слишком поздно.

## 18.3. Сквозные принципы

Несколько идей проходят через всю монографию и заслуживают повторения:

- **Гипотеза, а не факт.** Всё, что порождено выводом (fusion, реакции), пишется провизорно, с низкой уверенностью и провенансом; управление — на границе коммита. Это защищает от превращения обаятельной ассоциативности в фабрику ложных убеждений.
- **Внутрь, а не наружу.** Значимость (гейт консолидации характера) берётся из само-оценивания, а не из внешнего одобрения; иначе строится угодник, что противоречит ядру личности.
- **Ингредиенты, а не реакции.** Граф хранит материал; реакция композируется под настроение и мотивацию, а личность — смещение во время обхода, а не таблица весов.
- **Континуум, а не бинарность.** Врождённое/приобретённое, семантическое/эпизодическое, стабильное/пластичное — это оси глубины консолидации, а не выключатели.
- **Топология незрима, но правит.** Любой локальный процесс на графе наследует спектрально-топологический транспорт; телепорт-скраб — не украшение, а необходимая эпистемическая гигиена с доказуемой гарантией покрытия.

## 18.4. Единая спина двух проектов

И последнее — то, ради чего стоило смотреть память рядом с DTI. Консолидация есть огрубление графа; тот же вопрос «что выживает при переходе fine $\to$ coarse» стоит и там, и там. Over-squashing, спектр лапласиана, эффективное сопротивление, персистентный лапласиан, обучаемые

операторы передачи сообщений — инструменты, работающие в обе стороны. Память Рин — «грязный», богатый испытательный стенд для тех же операторов огрубления, где нет чистых меток; DTI — их «чистая» лаборатория с измеримой истиной. Отрефлексировать это явно значит получить не два проекта, а один с двумя приложениями.

## 18.5. Что делать дальше

Порядок разработки, вытекающий из монографии: сначала прибить *схему субстрата* (узел/ребро, метаданные, что значит коммит и кто его гейтит); затем собрать Ярус-1 стенд и погнать батарею тестов, начиная с самого дешёвого (концентрация $\pi$ на хабах — сразу показывает, что диагностика жива); затем локальное правило $\Delta$conf (знак, гейт источника, дисконт независимости), поверх которого пороги и ветвящийся коэффициент навешиваются тривиально; параллельно — построить $\varphi$-скорер как измерительный прибор для отбора голоса и фильтрации выходов. Настроение, сон и слой личности — усилители поверх субстрата, которому сначала надо стать доверенным.

# A. Нотация

Сводка обозначений, используемых по тексту.

| Символ | Смысл |
|---|---|
| $G = (V, E)$ | граф памяти: узлы $V$, направленные типизированные знаковые рёбра $E$ |
| $v$, $u$ | узлы (воспоминания, факты, сущности, концепты) |
| $\mathcal{N}(A)$ | окрестность узла $A$ (соседи, фронт распространения) |
| $\mathbf{x}_v \in \mathbb{R}^d$ | векторное представление содержания узла (эмбеддинг) |
| $c_v = \text{conf}(v) \in [0, 1]$ | уверенность в узле как в убеждении |
| $a_v$ | транзиентная активация узла при обходе |
| $r_{uv}$ | тип отношения на ребре $u \to v$; знак $\pm$ |
| $w_{uv}$ | вес (эвиденциальная сила) ребра |
| $m_{u \to v}$ | сообщение, передаваемое по ребру: $m_{u \to v} = \phi_{r_{uv}}(h_u, h_v, e_{uv})$ |
| $\tau$ | постоянная времени слоя (интегратора) |
| $B_v$ | базовая активация ACT-R узла $v$ |
| $\pi$ | стационарное распределение случайного блуждания |
| $P$ | матрица переходов блуждающего агента; $P, Q$ — операторы проекции/поднятия при огрублении |
| $\alpha$ | доля телепортов (рестартов) в блуждании |
| $L$, $L^+$ | лапласиан графа и его псевдообратный |
| $R_{\text{eff}}(i, j)$ | эффективное сопротивление между узлами $i, j$ |
| $\sigma$ | ветвящийся коэффициент лавины пропагации |
| $\theta_{\text{emergent}}, \theta_{\text{temp}}$ | верхний и нижний пороги распространения (гистерезис) |
| $\Delta\text{conf}(B \mid A)$ | локальное изменение уверенности соседа $B$ под влиянием факта $A$ |
| $\text{mood}_t \in \mathbb{R}^k$ | вектор настроения в момент $t$ (аффективное пространство) |
| $\varphi(\cdot) \in \mathbb{R}^d$ | скорер по осям характера |
| $\mathbf{t}$ | целевые координаты Рин в пространстве характера |
| $\text{Beta}(\alpha, \beta)$ | апостериорное распределение успешности реакции |
| $\eta$ | темп обновления (learning rate) локального правила |

# B. Глоссарий внешних идей

Краткие описания инженерных и научных идей, на которые опирается монография, чтобы читатель не был вынужден держать в голове внешний контекст. Порядок — тематический.

### Память и активация

**Базовая активация ACT-R.** В когнитивной архитектуре ACT-R (Anderson) сила следа в памяти есть функция *частоты* и *свежести* обращений со степенным затуханием: $B_v = \ln \sum_k t_k^{-\alpha}$, где $t_k$ — давность $k$-го обращения. Следствие: частые и *разнесённые во времени* обращения укрепляют след сильнее массовых (эффект распределённого повторения).

**Spreading activation.** Модель ассоциативного припоминания (Collins–Loftus): активация растекается от активированного узла по рёбрам, затухая с расстоянием. Формальная реализация — случайные блуждания и персонализированный PageRank.

**Сети Хопфилда, обучение Хебба.** Ассоциативная память как граф со взвешенными связями и динамикой активации, сходящейся к аттрактору (энергетический минимум). Правило Хебба: связь между совместно активными узлами усиливается («что вместе активируется, вместе укрепляется»). Наши fusion/консолидация — это хеббовское обучение на графе.

### Убеждения и истинность

**Труд-система поддержки истинности (TMS/ATMS).** Механизм (Doyle; de Kleer), хранящий *обоснования* выводов: для каждого производного убеждения записано, из каких посылок оно получено. При ретракции посылки её обоснованные следствия автоматически помечаются на пересмотр. Лечит «ползучую веру».

**Недоопределённость (underdetermination).** Тезис Дюэма–Куайна: данные не определяют теорию однозначно — одни и те же наблюдения совместимы с разными гипотезами. Когнитивное проявление — преждевременный коллапс: ум схлопывает суперпозицию совместимых гипотез в одну слишком рано.

**Belief perseverance.** Устойчивость убеждения к опровержению его основания: даже после опровержения посылки её следствия продолжают влиять.

**Петлевое распространение (loopy belief propagation).** Распространение уверенности по циклическому графу может привести к тому, что убеждение подтверждает само себя по петле (эхо-камера), искусственно раздувая уверенность. Лечится дисконтом по общей родословной свидетельств.

### Динамика и критичность

**Самоорганизованная критичность (SOC).** Класс систем (Bak–Tang–Wiesenfeld; образ — куча песка), самонастраивающихся к критической точке, где отклики следуют степенному закону: почти все малы, изредка случаются крупные лавины. Нейронные лавины (Beggs–Plenz) — проявление SOC в мозге.

**Ветвящийся коэффициент $\sigma$.** Среднее число узлов, активируемых одним активным. $\sigma < 1$ — субкритично (затухает), $\sigma = 1$ — критично, $\sigma > 1$ — суперкритично (runaway). Управляющий параметр лавины пропагации.

**Гистерезис (триггер Шмитта).** Схема с двумя порогами (включения и выключения), не дающая системе «дребезжать» у единственного порога.

### Графы: спектр, поток, топология

**Стационарное распределение $\pi$.** Долгосрочная частота посещений узлов случайным блужданием; глобальный объект (перронов собственный вектор матрицы переходов), а не локальные вероятности.

**Время перемешивания (mixing time).** Скорость сходимости блуждания к $\pi$; управляется спектральным зазором матрицы переходов.

**PageRank / персонализированный PageRank / RWR.** Случайное блуждание с телепортом (рестартом): с вероятностью $\alpha$ прыжок в узел из распределения рестарта. Телепорт делает блуждание эргодическим — гарантирует посещение всех узлов.

**Эффективное сопротивление $R_{\text{eff}}$.** Мера «электрической» удалённости узлов, если рёбра — резисторы: $R_{\text{eff}}(i,j) = (e_i - e_j)^\top L^+ (e_i - e_j)$. Большое $R_{\text{eff}}$ между узлами ограничивает передачу влияния между ними.

**Проводимость / константа Чигера.** Мера «узости» перешейков графа; неравенство Чигера связывает её со спектральным зазором. Малая проводимость = узкое место.

**Over-squashing.** Удушение дальней связи: информация от экспоненциально растущей окрестности сжимается в вектор фиксированной размерности, проходя через узкое место графа; влияние дальних узлов затухает.

**Over-smoothing.** Пересглаживание: при многократной диффузии представления узлов сходятся к низкоразмерному консенсусу, теряя различимость.

**Кривизна графа (Оливье, Форман).** Дискретные аналоги кривизны; отрицательно искривлённые рёбра — мосты между сообществами, места over-squashing. Полезны как локатор узких мест.

**Анти-энтропийный скраб.** Приём из распределённых хранилищ (ZFS scrub; Merkle-based anti-entropy gossip): фоновая случайная перепроверка всего хранилища, поскольку неизвестно, какая запись повреждена.

**Огрубление графа (graph coarsening), coarse-to-local.** Замена мелкого графа крупным с сохранением релевантных свойств (спектра, разрезов, потоков). Центральный вопрос — какой сигнал выживает при переходе от мелкого масштаба к крупному; в памяти это консолидация.

**Персистентный лапласиан, TDA.** Топологический анализ данных: как меняются топологические признаки (числа Бетти, спектр лапласиана) при изменении масштаба (фильтрации). Персистентный лапласиан — спектральное обобщение персистентной гомологии.

### Выразительность и обучение

**WL-тест, GIN.** Тест Вейсфейлера–Лемана — предел различающей способности обычной передачи сообщений; GIN (Xu и др.) достигает этого предела инъективной агрегацией. PNA — многостатистическая агрегация (сумма/среднее/макс/дисперсия).

**Передача сообщений (GNN).** Параметрическая функция на графе, обучаемая градиентным спуском: узел обновляется агрегированными сообщениями соседей. Наша память — та же передача сообщений, но с локальными (не обучаемыми градиентом) правилами.

**LoRA.** Дешёвое дообучение: вместо всех весов обучается низкоранговая добавка $\Delta W = BA$ (ранг $r \ll$ размерности), малая по памяти.

**DPO (Direct Preference Optimization).** Дообучение под предпочтения без отдельной модели вознаграждения: оптимизация на тройках (промпт, выбранный ответ, отвергнутый ответ).

### Эмоции и данные

**Теория оценивания (appraisal): OCC, Шерер.** Эмоция как результат оценки события по измерениям: релевантность/новизна (ошибка предсказания), конгруэнтность целям, валентность, интенсивность, атрибуция причины (agency).

**Предиктивная обработка, ошибка предсказания.** Взгляд (Friston и др.), по которому мозг минимизирует ошибку предсказания; величина ошибки — естественная мера значимости события.

**ConceptNet / Numberbatch.** Ассоциативно-таксономический граф здравого смысла (взвешенные типизированные рёбра) и его родной эмбеддинг Numberbatch.

**ATOMIC / ATOMIC10x.** Граф причинно-социального здравого смысла (если субъект делает $Y$, то намерение/реакция/эффект). ATOMIC10x — крупная версия, дистиллированная языковой моделью и отфильтрованная критиком.

**Wikidata.** Фактологическая база с моделью утверждения: квалификаторы (время), references (провенанс), ранг (недеструктивная ревизия). Ценна схемой, не содержанием.

**Generative Agents.** Симуляция агентов с потоком памяти, retrieval по свежести$\times$важности$\times$релевантности и рефлексией (порождением обобщений); прообраз субстрата.

**Распределение Бета, сэмплирование Томпсона.** Сопряжённый апостериор для доли успехов; удобно моделирует «успешность реакции» (успехи $\alpha$, провалы $\beta$) и баланс исследования/эксплуатации.

# C. Сводка алгоритмов

Псевдокод ключевых операторов, собранный в одном месте для удобства. Это скелеты, а не финальные реализации: они фиксируют логику, обсуждённую в главах, но опускают инженерные детали (батчинг мутаций, кэширование $\pi$, индексы эмбеддингов).

## C.1. Единый блуждающий агент (три политики)

```
def walk(G, start_nodes, mode, steps, mood, query=None):
    # mode задаёт политику через параметры: bias перехода, alpha телепорт(),
    # bias_uncertainty. Один движок — три режима глава( про обход).
    if mode == ”retrieval”:   alpha, bu = 0.0, 0.0
    if mode == ”curiosity”:   alpha, bu = 0.05, 1.0     # тянет к need_to_discover
    if mode == ”sleep”:       alpha, bu = 0.30, 0.0     # телепортскраб–

    active = set(start_nodes); visited = Counter()
    for _ in range(steps):
        A = sample(active)
        if random() < alpha:                 # телепорт рестарт()
            B = random_node(G)
        else:
            # P(A → B) ∝ w_AB · rel(B|query) · moodcong(B|mood) · unc(B)^bu
            B = sample_neighbor(G, A, weights=transition_scores(
                    G, A, query, mood, bias_uncertainty=bu))
        visited[B] += 1
        maybe_fire_operations(G, B, mode)    # retrieval / fusion / inspect
        active = frontier(active, B)
    return visited
```

## C.2. Локальное правило и лавинная пропагация

```
def propagate(G, A, sigma_target=0.9):
    # Пропагация нового факта A как затухающей лавины с контролем ветвления.
    frontier = link_initial(G, A)            # A –> N(A), напр. последние top–k
    while frontier:
        next_frontier = []
        # нормировка под целевой ветвящийся коэффициент sigma < 1
        gain = branching_normalizer(frontier, sigma_target)
        for B in frontier:
            d = delta_conf(G, A, B) * gain    # см. ниже: знак, источник, независимость
            G.confidence[B] = clip(G.confidence[B] + d, 0, 1)
            th_e = theta_emergent(G, B)       # растёт с глубиной консолидации
            if abs(d) > th_e:                 # крупная переоценка –> в ширину
                next_frontier += neighbors(G, B)
            elif abs(d) > THETA_TEMP:         # промежуточная зона –> пометить
                mark(G, B, ”need_to_revise”)
            # else: глохнет здесь
```

```
        frontier = next_frontier

def delta_conf(G, A, B):
    sign      = edge_sign(G, A, B)            # supports (+) / contradicts (−)
    strength  = edge_weight(G, A, B)
    gate      = G.confidence[A] * source_trust(G, A)   # карантин нового факта
    indep     = independence_discount(G, A, B)         # антиэхо− по провенансу
    return ETA * sign * strength * gate * indep * G.confidence[A]
```

## С.3. Забывание, прунинг, консолидация

```
def nightly_maintenance(G):
    for v in G.nodes:
        G.strength[v] = act_r_base_level(G.access_log[v])   # частота + свежесть
    for v in low_activation(G):
        if importance(G, v) low and confidence(G, v) low:
            drop(G, v)                                       # редкоеиневажное−−
    for cluster in redundant_episodic_clusters(G):
        merge_to_semantic(G, cluster)   # огрубление: эпизоды −> обобщение
    # эмбриональным узлам − меньшая скорость распада континуум( глубины)
```

## С.4. Телепорт-скраб (анти-энтропия)

```
def scrub(G, budget):
    # Случайная инспекция: гарантия покрытия за счёт эргодичности телепорта.
    for _ in range(budget):
        v = random_node(G)                    # рестарт куда угодно
        for w in local_walk(G, v, depth=k):
            if contradicts_any(G, w):         # столкновение −> ревизия
                demote(G, w); mark(G, justificands(G, w), "need_to_revise")
            if flagged(G, w, "need_to_discover"):
                maybe_fetch_external(G, w)     # любопытствовнешний/ вход
```

## С.5. Настроение и монитор руминации

```
def mood_update(mood_layers, event):
    # Стек текущих интеграторов с разными tau; актуальное = суперпозиция.
    for L in mood_layers:                     # session, day, ..., life
        mood_L = (1 − 1/L.tau) * mood_L + (1/L.tau) * appraise(event)
    mood_now = sum(w_L * mood_L for L in mood_layers)
    if autocorr(history(mood_now)) > RUMINATION_TH:   # залипла валентность
        trigger(one_of=["reframe", "attention_shift", "invoke_sleep"])
    return mood_now
```

## С.6. Оценивание, значимость и консолидация реакции

```
def encode_event(G, event, mood_prev, mood_now):
    ap = appraisal(event)                     # surprise, goal_congruence, valence...
    salience = ap.surprise * ap.goal_relevance
    #  дешёвый прокси значимости, почти бесплатный:
    salience_cheap = abs(mood_now − mood_prev)
    consolidate(G, event, weight=salience)    # гейт значимости, НЕ одобрения
```

```
    if ap.surprise high: mark(G, event, ”need_to_discover”)

def update_reaction(G, situation, user, reaction, received_ok):
    e = reaction_edge(G, situation, user, reaction)   # условь по ситуация(, отношение)
    if received_ok: e.beta.alpha += 1
    else:           e.beta.beta  += 1                 # угасание, не второй коммит
    e.confidence = e.beta.alpha / (e.beta.alpha + e.beta.beta)
    if e.confidence > CONSOLIDATE_TH: promote_to_slow_layer(G, e)
```

## С.7. Скорер характера и отбор голоса

```
def phi(text, axes):                          # LLMсудья– по рубрикам осей
    return [judge(text, rubric_a) for rubric_a in axes]   # вектор в R^d

def select_voice_corpus(candidates, target_t, axes):
    scored = [(c, phi(c, axes)) for c in candidates]
    # отборперевзвешивание/, чтобы среднее выборки приблизилось к target_t
    return greedy_match_mean(scored, target_t)   # не усреднять муз, а фильтровать
```

## С.8. Стенд эксперимента

```
def run_experiment(build_graph, plant, operator, metric):
    G = build_graph()          # ярус 1: SBM/BA/WS + подсаженные сценарии
    truth = plant(G)           # ground truth: что должно произойти
    operator(G)                # walker / propagate / scrub / decay ...
    return metric(G, truth)    # precision/recall починки, сходимость, покрытие
```

# D. Будущее: стоит ли переходить на гиперграфы

Это приложение — рассуждение о структурном направлении, а не готовая рекомендация к внедрению. Вопрос: логично ли в будущем сделать память Рин *гиперграфом*, а не обычным графом.

## D.1. Проблема, которая это мотивирует

Обычный граф связывает узлы *попарно*. Но вывод часто *n-арен*: он рождается только при одновременном присутствии нескольких посылок, и ни одно подмножество не достаточно. Канонический пример (глава 7):

$$A = \text{«живёт в Португалии»}, \quad B = \text{«есть коты»}, \quad C = \text{«едет с пар»},$$

$$X = f(A, B, C) = \text{«купи котам корм по пути из универа»}.$$

Ни $A \wedge B$, ни $B \wedge C$, ни $A \wedge C$ не дают $X$. Попарные рёбра между посылками могут вообще отсутствовать: «Португалия» и «коты» напрямую не связаны.

## D.2. Почему симплексы — плохой ответ

Первое, что приходит в голову, — симплициальные комплексы: тройка $\{A, B, C\}$ как 2-симплекс (треугольник). Но у симплициального комплекса есть жёсткое требование *downward closure*: если есть 2-симплекс $\{A, B, C\}$, то обязаны быть и все его грани — рёбра $A-B$, $A-C$, $B-C$. А в нашем случае этих попарных связей *нет и не должно быть*: «Португалия» и «коты» не связаны. Симплициальная память вынудила бы нас проводить *ложные* попарные рёбра ради формальной корректности структуры. Это плохой обмен.

## D.3. Гиперребро — прямой ответ

*Гиперребро* связывает *множество* узлов сразу: $e = \{A, B, C\}$, и оно *не требует* существования попарных рёбер между ними. Это ровно та семантика, что нужна n-арному выводу: «эти три вместе порождают это», без обязательства, что они связаны попарно.

**Гиперграф против графа**

В графе «дружба» — всегда пара. В гиперграфе можно сказать «эти пятеро были в одной поездке» одним ребром, не утверждая, что каждый дружит с каждым. Для памяти это разница между «связь между двумя воспоминаниями» и «условие из нескольких воспоминаний, порождающее вывод».

## D.4. Ключевое наблюдение: мы уже наполовину гиперграф

Важно не пропустить: **текущая схема Рин уже кодирует гиперрёбра** — просто не называя их так. Когда fusion порождает узел $X$ с провенансом $\{A, B, C\}$ (глава 7), это *factor-graph*-кодировка

гиперребра $\{A, B, C\} \to X$: сам вывод $X$ становится узлом, а его рёбра-обоснования указывают на посылки. Попарных рёбер между $A, B, C$ при этом не требуется.

Значит «переход на гиперграфы» — это не «переписать всё», а более узкий вопрос: *делать ли гиперрёбра первоклассными объектами* (со своим обходом и спектральной теорией), или достаточно узла-фактора.

## D.5. Первоклассные гиперрёбра: за и против

**За.** Появляются *гиперграф-нативные* операции: обход/spreading activation, уважающий *совместность* срабатывания (гиперребро «зажигается», когда активны *все* его узлы, а не любой один); гиперграфовые лапласианы и спектральная диагностика (аналоги главы 12 для n-арной структуры). Это может точнее моделировать «условие из нескольких посылок».

**Против.** Алгоритмика гиперграфов менее зрелая и дороже графовой. На практике гиперграф часто *сводят* к графу — clique-expansion (заменить гиперребро кликой, что как раз возвращает ложные попарные рёбра!) или star-expansion (ввести узел-фактор — то есть ровно наша factor-кодировка). Есть спектральная теория гиперграфов (нормализованный гиперграфовый лапласиан; тензорные методы), но она сложнее и вычислительно тяжелее, а динамический мутирующий гиперграф — тем более.

## D.6. Рекомендация

**Принцип D.1** (Гиперграф — да, но постепенно)**.** Ближний горизонт: оставить *factor-узлы* (вывод $X$ с провенансом-множеством). Это уже даёт n-арную семантику без гиперграфовой машинерии и без ложных попарных рёбер. Средний горизонт: сделать гиперрёбра первоклассными *только там*, где нужны гиперграф-нативные операции — совместное срабатывание при обходе и n-арная спектральная диагностика. Симплициальные комплексы обходить стороной: их downward closure противоречит разреженности реальных выводов.

Заметим, что star-expansion (факторные узлы) и первоклассные гиперрёбра — это два взгляда на одно и то же; переход между ними инкрементален, а не революционен. Полное же объединение узлов, рёбер и выводов в объекты одного рода разной размерности — это уже клеточные комплексы (приложение E).

# E. Будущее: память на клеточных комплексах

Это приложение — про наиболее амбициозное структурное направление. Оно серьёзнее гиперграфов (приложение D) и относится к области R&D, но обсудить его стоит, потому что оно даёт *единую* картину.

## E.1. Идея: всё — объекты одного рода, разных размерностей

В обычном графе узлы и рёбра — сущности *разной* природы. Идея клеточного комплекса: сделать их сущностями *одного* рода, но разной *размерности*. *Клетки*: 0-клетки — узлы (воспоминания, концепты), 1-клетки — рёбра (связи), 2-клетки — выводы из нескольких посылок, и так далее. Все они — «клетки», просто живущие на разных этажах.

Связывает этажи *граничный оператор* $\partial$: у каждой $k$-клетки есть *граница* — набор $(k-1)$-клеток, на которых она «натянута». Граница 1-клетки (ребра) — два её узла; граница 2-клетки (вывода) — цикл/цепочка из посылок.

**Вывод рождается, когда построена его граница**

Твоя формулировка точна: вывод *рождается*, когда его граница построена на посылках. В терминах комплекса это *приклеивание* $k$-клетки по её границе: как только в памяти есть подходящая цепочка посылок (граница), поверх неё можно «натянуть» клетку-вывод. Узел-вывод — это заполненная область, чей контур — посылки.

## E.2. Почему это решает возражение к симплексам

Здесь ключевой технический факт. Симплициальные комплексы требуют downward closure (все грани обязаны существовать) — и потому плохи для разреженных n-арных выводов (приложение D). *Клеточные* (CW) комплексы этого **не** требуют: $k$-клетку можно приклеить к границе *произвольным* приклеивающим отображением, не заполняя все промежуточные симплексы. То есть клеточные комплексы *снимают* ровно то возражение, из-за которого симплексы не подходят, — и при этом дают единую алгебраическую структуру. Это делает их более принципиальным ответом на n-арность, чем и симплексы, и даже голые гиперрёбра.

## E.3. Ходж-лапласианы: пропагация между этажами

Граничные операторы $\partial_k$ порождают *Ходж-лапласианы* на каждой размерности:

$$L_k = \partial_{k+1}\partial_{k+1}^{\top} + \partial_k^{\top}\partial_k.$$

Это обобщение графового лапласиана (случай $k = 0$) на клетки высших размерностей. Оно даёт *принципиальную* диффузию не только между узлами, но и между рёбрами, между выводами, а также *между этажами* (вверх и вниз по $\partial$). Иначе говоря, вся динамика уверенности и активации (главы 11, 12) получает единое спектральное описание, охватывающее и выводы как полноправные объекты.

## E.4. Прямая связь с чтением по DTI

Это не абстрактная экзотика: ровно эта математика лежит в статьях, которые уже есть в DTI-волте проекта. Bodnar и др. «WL Go Cellular» и «WL Go Topological» — передача сообщений на клеточных и симплициальных комплексах; sheaf-лапласианы (cellular sheaf) — их обогащение. Таким образом «память на клеточных комплексах» — очередной мост между двумя проектами автора: инструменты топологического и клеточного обучения из магистерской работы напрямую применимы к структуре памяти Рин.

## E.5. Честная оценка: северная звезда, не ближний шаг

**Принцип E.1** (Клеточные комплексы — направление, а не спринт)**.** Это самая красивая и самая объединяющая картина: один род объектов, разные размерности; вывод — высшая клетка; пропагация — Ходж-лапласиан по этажам. Но выигрыш над прагматичной factor-кодировкой (приложение D) пока *не доказан*, а цена высока: динамические клеточные комплексы с приклеиванием и отклеиванием клеток на мутирующей памяти, эффективные Ходж-лапласианы в реальном времени — всё это серьёзный R&D. Разумный порядок: ближний горизонт — factor-узлы; средний — первоклассные гиперрёбра при необходимости; дальний/R&D — клеточные комплексы ради единого алгебраического описания.

**Как это выглядело бы у Рин**

Узлы «Португалия», «коты», «универ» — 0-клетки. Вывод «купи корм по пути» — 2-клетка, приклеенная к границе из этих трёх посылок (без требования, чтобы посылки были связаны попарно). Позже, если посылка «есть коты» опровергается, граница 2-клетки рушится — и вывод *автоматически* теряет опору (ретракция как разрушение границы). Ходж-лапласиан при этом единообразно описывает, как понижение уверенности течёт с этажа посылок на этаж вывода. Красиво — и именно поэтому стоит держать это как цель, к которой архитектура может дозреть.

# Литература

Ниже — работы, на которые опирается монография, в согласованном формате. Для препринтов и внутренних материалов проекта (библиографии волтов RIN и RIN–DTI) в конце записи в скобках указан локатор во внутренней библиографии; это указание на местоположение источника, а не замена выходных данных.

# Литература


[1] J. R. Anderson, D. Bothell, M. D. Byrne и др. An Integrated Theory of the Mind. *Psychological Review*, 111(4), 2004. (Базовая активация ACT-R; см. также Anderson & Schooler, 1991.)

[2] A. M. Collins, E. F. Loftus. A Spreading-Activation Theory of Semantic Processing. *Psychological Review*, 82(6), 1975.

[3] D. O. Hebb. *The Organization of Behavior*. Wiley, 1949.

[4] J. J. Hopfield. Neural Networks and Physical Systems with Emergent Collective Computational Abilities. *PNAS*, 79(8), 1982.

[5] J. S. Park, J. C. O’Brien, C. J. Cai и др. Generative Agents: Interactive Simulacra of Human Behavior. *UIST*, 2023.

[6] J. Doyle. A Truth Maintenance System. *Artificial Intelligence*, 12(3), 1979.

[7] J. de Kleer. An Assumption-Based TMS. *Artificial Intelligence*, 28(2), 1986.

[8] W. V. O. Quine. Two Dogmas of Empiricism. *The Philosophical Review*, 60(1), 1951. (Тезис недоопределённости Дюэма–Куайна.)

[9] L. Ross, M. R. Lepper, M. Hubbard. Perseverance in Self-Perception and Social Perception. *J. Personality and Social Psychology*, 32(5), 1975. (Belief perseverance.)

[10] P. Bak, C. Tang, K. Wiesenfeld. Self-Organized Criticality. *Physical Review Letters*, 59(4), 1987.

[11] J. M. Beggs, D. Plenz. Neuronal Avalanches in Neocortical Circuits. *J. Neuroscience*, 23(35), 2003.

[12] L. Page, S. Brin, R. Motwani, T. Winograd. The PageRank Citation Ranking: Bringing Order to the Web. Stanford InfoLab Technical Report, 1999.

[13] H. Tong, C. Faloutsos, J.-Y. Pan. Fast Random Walk with Restart and Its Applications. *ICDM*, 2006.

[14] D. A. Spielman. *Spectral and Algebraic Graph Theory* (лекционные заметки), Yale University.

[15] A. Ortega, P. Frossard, J. Kovačević и др. Graph Signal Processing: Overview, Challenges, and Applications. *Proceedings of the IEEE*, 106(5), 2018.

[16] J. Topping, F. Di Giovanni, B. P. Chamberlain и др. Understanding Over-Squashing and Bottlenecks on Graphs via Curvature. *ICLR*, 2022. (Волт RIN–DTI, поз. 148.)

[17] M. Black, Z. Wan, A. Nayyeri, Y. Wang. Understanding Oversquashing in GNNs through the Lens of Effective Resistance. *ICML*, 2023. (Волт RIN–DTI, поз. 183.)

[18] T. K. Rusch, M. M. Bronstein, S. Mishra. A Survey on Oversmoothing in Graph Neural Networks. arXiv:2303.10993, 2023. (Волт RIN–DTI, поз. 170.)

[19] C. Bodnar, F. Frasca, N. Otter и др. Weisfeiler and Lehman Go Cellular: CW Networks. *NeurIPS*, 2021. (Волт RIN–DTI, поз. 185.)

[20] C. Bodnar, F. Frasca, Y. Wang и др. Weisfeiler and Lehman Go Topological: Message Passing Simplicial Networks. *ICML*, 2021. (Волт RIN–DTI, поз. 186.)

[21] C. Bodnar, F. Di Giovanni, B. P. Chamberlain и др. Neural Sheaf Diffusion. *NeurIPS*, 2022.

[22] R. Wang, D. D. Nguyen, G.-W. Wei. Persistent Spectral Graph. *Int. J. Numerical Methods in Biomedical Engineering*, 2020. (TDA/персистентный лапласиан для биомолекул; ср. TopologyNet, Cang & Wei, 2017. Волт RIN–DTI, поз. 100, 103, 104, 144.)

[23] A. Ortony, G. L. Clore, A. Collins. *The Cognitive Structure of Emotions*. Cambridge University Press, 1988. (OCC-модель оценивания; ср. компонентная модель K. Scherer.)

[24] K. Friston. The Free-Energy Principle: A Unified Brain Theory? *Nature Reviews Neuroscience*, 11(2), 2010. (Ошибка предсказания как сигнал значимости.)

[25] R. Speer, J. Chin, C. Havasi. ConceptNet 5.5: An Open Multilingual Graph of General Knowledge. *AAAI*, 2017. (Включая эмбеддинги Numberbatch.)

[26] M. Sap, R. Le Bras, E. Allaway и др. ATOMIC: An Atlas of Machine Commonsense for If-Then Reasoning. *AAAI*, 2019.

[27] J. D. Hwang, C. Bhagavatula, R. Le Bras и др. (Comet-)ATOMIC 2020: On Symbolic and Neural Commonsense Knowledge Graphs. *AAAI*, 2021.

[28] P. West, C. Bhagavatula, J. Hessel и др. Symbolic Knowledge Distillation: from General Language Models to Commonsense Models. *NAACL*, 2022. (ATOMIC10x.)

[29] D. Vrandečić, M. Krötzsch. Wikidata: A Free Collaborative Knowledgebase. *Communications of the ACM*, 57(10), 2014.

[30] K. Xu, W. Hu, J. Leskovec, S. Jegelka. How Powerful are Graph Neural Networks? *ICLR*, 2019. (GIN; волт RIN–DTI, поз. 68.)

[31] G. Corso, L. Cavalleri, D. Beaini и др. Principal Neighbourhood Aggregation for Graph Nets. *NeurIPS*, 2020. (Волт RIN–DTI, поз. 178.)

[32] E. J. Hu, Y. Shen, P. Wallis и др. LoRA: Low-Rank Adaptation of Large Language Models. arXiv:2106.09685, 2021.

[33] R. Rafailov, A. Sharma, E. Mitchell и др. Direct Preference Optimization. *NeurIPS*, 2023.

[34] D. Zhou, J. Huang, B. Schölkopf. Learning with Hypergraphs: Clustering, Classification, and Embedding. *NeurIPS*, 2006. (Гиперграфовый лапласиан.)

[35] L.-H. Lim. Hodge Laplacians on Graphs. *SIAM Review*, 62(3), 2020. (Ходж-лапласианы и высшие размерности.)

[36] J. Zhu, J. Li, C. Zhang и др. HeLa-Mem: Hebbian Learning and Associative Memory for LLM Agents. Препринт, 2026. (Внутренняя библиография волта RIN, поз. 53.)

[37] Библиография памяти LLM-агентов из волта RIN: APEX-MEM, TRACE, SYNAPSE, GAAMA, MRMS, Zep/Graphiti, Persistent Sycophancy, LifeSide, LoCoMo и др. (Внутренние материалы проекта; полные выходные данные — в `99 Sources/1. Bibliography (RIN)`.)

[38] Материалы проекта RIN: модульные системные промпты (`prompts/global_core/*`), persona-тесты и логи Stage 0 (`logs/rin_stage0.jsonl`), Ринциклопедии (`docs/rincyclopedia_*`).